

第I部 機械学習の仕組み


第Ⅰ部で扱うタスク（知的な仕事）の類型

第Ⅰ部では，最も基本的な，予測系タスクと分析・発見系タスクを学ぶ

予測系タスク



分析・発見系タスク



■ ここでいうタスクとは仕事のこと

- 人が行うような知的なタスクをコンピューターに肩代わりさせたい

【補足】画像の一部は，人工知能学会「AIマップβ2.0（2023年5月版）」（<https://www.ai-gakkai.or.jp/aimap/>）から抜粋・改変したもの。一部の文献では，上に挙げたような「データの背後の規則性を発見したり，それを利用して分類などの行動を取ったりする自動化された処理」はパターン認識と総称される


タスク（知的な仕事）の種類

コンピューターで実行できると嬉しい知的なタスクには様々な種類がある

予測系タスク



分析・発見系タスク



生成系タスク




推定系タスク



行動・制御系タスク



合意形成タスク



推薦・検索系タスク



他にもまだ色々な
タスクがある

【補足】画像の一部は、人工知能学会「AIマップβ2.0（2023年5月版）」（<https://www.ai-gakkai.or.jp/aimap/>）から抜粋・改変したもの。一部の文献では、上に挙げたような「データの背後の規則性を発見したり、それを利用して分類などの行動を取ったりする自動化された処理」はパターン認識と総称される

予測系タスク

このパートで学ぶこと




以下の内容を，以下の順番で学びます


- まずは，予測系タスクの基本的な考え方
- 続いて，教師付き学習という方法論
- そして，簡単な具体例として線型最小二乗回帰

コンピューターで実現できたら嬉しいタスク


迷惑メールのフィルタリング


“Re:私の遺産を受け取っていた…”


“Re:先日はお越しいただき…”


“日程調整について…”

自動で振り分ける




コンピューターで実現できたら嬉しいタスク

手書き文字の読み取り



手書きした文字を撮影して
画像データとして保存




コンピューターで扱える
テキストや数値に変換

0, 0, 4, 1
0, 2, 3, 5

コンピューターで実現できたら嬉しいタスク

録音した音声の文字起こし



予測系タスク (Prediction task)

これらは抽象化すると「入力 x に対して正しい y を出力する」タスク

- 予測系タスク (prediction task) という




予測系タスク＞例

以下のようなタスクは予測系タスクの例

- 音声の文字起こし（入力：音声の波形を数値化したもの，出力：英単語1つ）



- 迷惑メールのフィルタリング（入力：テキスト，出力： $\{\bigcirc, \times\}$ どちらか）



理解の確認＞関数

「入力を受け取って、何か計算して、出力を返す、一定の処理」を関数という

- 入力 x を受け取って、 x から計算した何らかの値を出力するものが関数



- 例) 入力を2乗して出力する関数 $f(x) = x^2$



【細かい補足】「関数」は、数学では出力が数であるような写像を指すが、プログラミング等では入力を受け取って出力を返すような処理の固まりを指す。なお、出力を「返す (return)」というのはプログラミング系の用語。

予測系タスク

コンピュータで予測系タスクを解きたい

■ 予測系タスクを解くとはつまり……

- コンピューターにできる四則演算や条件分岐などの計算で表せる関数，かつ
- 色々な x を入力すると，それに対応して丁度正しい y が出てくる関数を作ること
とと言い換えられる



四則演算や条件分岐など
コンピューターにできる計算

予測系タスク＞用語

入力は**特徴量**，予測に使う関数は**予測器**，予測したい変数は**ラベル**と総称



【細かい補足】 予測というと未来の出来事に対する予言のような表現だが，それ以外の場合にも慣習的に「予測」という．特徴量・予測器・ラベルは，それぞれ分野や文脈によって様々な名前と呼ばれる．特定の状況でのみ使われる用語も多く，例えば「クラス」は，分類問題の場合におけるラベルの呼び名である．

【特徴量の別名】 予測変数 (predictor variable)，説明変数 (explanatory variable)，独立変数 (independent variable)，共変量 (covariate)，パターン (pattern)，

【予測器の別名】 回帰関数 (regression function)，分類器 (classifier)，識別器 (discriminator)，識別関数 (discriminant function)，判別関数 (discriminant function)

【ラベルの別名】 目標変数 (target variable)，目的変数 (objective variable)，応答変数 (response variable)，結果変数 (outcome variable)，被説明変数 (explained variable)，従属変数 (dependent variable)，クラス (class)，カテゴリー (category)


予測系タスク＞用語

ラベルの種類によって呼び分けられている

回帰タスク (regression task)

量的なラベル（正の実数など）を予測するタスク


- 例）動物の画像から体重を予測



分類タスク (classification task)（識別／判別／パターン認識タスクともいう）

質的なラベル（{1,2,...,C}など）を予測するタスク

- 例）動物の画像を「犬/犬以外」に分類
- 分類ラベルはクラスやカテゴリーともよぶ



【補足】上記の区分でははっきり分けられない予測系タスクもある（例：ラベルが順序尺度や、グラフ構造や、画像や、文字列の場合など）。

予測系タスク＞例

ワインの化学的な計測データから、ブドウ品種を当てたい

- 特徴量：アルコール濃度や色相などの13個の数値
- ラベル：葡萄の品種名（Barolo, Barbera, Grignolino）



Alcohol	Malicacid	Magnesium	...	Flavanoids	Hue		class
13.64	3.10	116	...	3.03	0.96	→	Barolo
14.21	4.04	111	...	2.65	0.87	→	Barolo
12.93	2.81	96	...	0.50	0.77	→	Barbera

【参考】 Forina, M., Armanino, C., Castino, M., Ubigli, M., 1986. Multivariate data analysis as a discriminating method of the origin of wines. VITIS - Journal of Grapevine Research 25, 189–189. <https://doi.org/10.5073/vitis.1986.25.189-201>


予測系タスク＞例

このタスクの場合の特徴量は，13次元のベクトル

- データを分析するとき，大体的場合は特徴量は1つではなく複数の数値からなるので，1つ1つのデータ点は数が幾つか並んだものになる




計測



アルコール度数：13.64
リンゴ酸：3.10
マグネシウム：116
⋮
フラボノイド：3.03
色：0.96


並べる


$$\begin{bmatrix} 13.64 \\ 3.10 \\ 116 \\ \vdots \\ 3.03 \\ 0.96 \end{bmatrix} \left. \vphantom{\begin{bmatrix} 13.64 \\ 3.10 \\ 116 \\ \vdots \\ 3.03 \\ 0.96 \end{bmatrix}} \right\} \text{13次元ベクトル}$$

- このように数値を並べたものをベクトルと呼ぶ． d 個の数が並んだベクトルは d 次元ベクトルという．

予測系タスク > 予測器


予測器 = 正しいラベル番号を出力できる（できそうな）計算式を作りたい



- ラベル番号は予め「Baroloは0, Barberaは1, Grignolinoは-1」などと決めておく
- 13個の数値を代入すると正しい品種番号が出てくる計算式を作れという問題

予測系タスク > 予測器の一例

例えばこんな関数も予測器



- $f(\mathbf{x}) = \text{sign}(3x_1 - x_2x_3 + x_3^3)$ (正なら1, 負なら-1, 零なら0)
- これでも立派な予測器
 - ただし, 適当に思いついた数式を書いただけなので全然当たらない

よく当たる予測器を作るには



「良い予測器」の数式を思いつくのは至難のわざ

- エキスパートでも，アルコール濃度や色相などの数値から，どういう数式を立てれば正しい品種を当てられるかを考えることは流石に困難だろう
- 多くの予測タスクでこの状況になる
 - 人間なら感覚的に上手くできるタスクも，いざコンピューターでできる計算に落とし込もうとすると，どうすればいいか分からない

よく当たる予測器を作るには



ここまでのスライドの中に、使えそうなものがあった

- 正しい入出力をペアにした過去の事例データは収集できる

Alcohol	Malicacid	Magnesium	...	Flavanoids	Hue	class
13.64	3.10	116	...	3.03	0.96	Barolo
14.21	4.04	111	...	2.65	0.87	Barolo
12.93	2.81	96	...	0.50	0.77	Barbera

- ここから特徴量とラベルの関係について推測できれば、予測器を作れるかも

教師付き学習 (supervised learning)

正しい入出力をペアにしたラベル付きデータから予測器を作る

- ラベル付きデータ $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$: 特徴量 x と正解ラベル y のペアを沢山集めたもの

例) ブドウ品種分類

特徴量: ワインの化学計測値13個

ラベル: 葡萄の品種名

データセット:

Alcohol	Malicacid	Magnesium	...	Flavanoids	Hue	class
13.64	3.10	116	...	3.03	0.96	Barolo
14.21	4.04	111	...	2.65	0.87	Barolo
12.93	2.81	96	...	0.50	0.77	Barbera

例) スパムメールを分類

特徴量: メール of 文字列

ラベル: spam (1) or not (0)

データセット:

(“Re:私の遺産を受け取って...”, 1)
(“Re:先日はお越しいただき...”, 0)
(“日程調整について...”, 0)
(“はじめまして...”, 1)

例) 手書き数字認識

特徴量: 画像 (28 × 28個 of 画素値)

ラベル: 0~9 of 整数値

データセット:

(, 0) (, 2) (, 0)
(, 0) (, 3) (, 4)
(, 1) (, 5)

【用語】ラベル付きデータ (labeled data) は, 別名「教師データ」ともいう (一般に「学習データ」「訓練データ」とも)。データに基づいて望ましい予測器を作ることを「学習」という。【補足】入力 (= テストの問題) と, 正しい出力 (= テストの正解) を教えるので, あたかも教師が付いているかのようだという比喻で「教師付き」という。

教師付き学習＞人力では難しい

データの助けがあったとしても、人手で高度な計算式を思いつくことは難しい

- 予測器を思いつくために過去のデータを眺める
→ アルコール濃度が13.00以上，色相も0.85以上ならBarolo？

Alcohol	Malicacid	Magnesium	...	Flavanoids	Hue	class
13.64	3.10	116	...	3.03	0.96	Barolo
14.21	4.04	111	...	2.65	0.87	Barolo
12.93	2.81	96	...	0.50	0.77	Barbera

- データ量は何万件になることも．13次元もある特徴量を全て考慮するのも困難.
 - 数百万件のデータ，数百次元の特徴量という応用もちらほらある.

データから予測器を作るには



データは集めた。さあ、ここからどうやって予測器を作るか？

- ラベル付きデータを沢山集めた。これは上手く使えば役に立つはず

Alcohol	Malicacid	Magnesium	...	Flavanoids	Hue	class
13.64	3.10	116	...	3.03	0.96	Barolo
14.21	4.04	111	...	2.65	0.87	Barolo
12.93	2.81	96	...	0.50	0.77	Barbera

- ここから以下を説明
 - どうやって望ましい予測器を手に入れるか？
 - 望ましい予測器とは？