

予測系タスクのための学習

データから予測器を作るには



データは集めた。さあ、ここからどうやって予測器を作るか？

- ラベル付きデータを沢山集めた。これは上手く使えば役に立つはず

Alcohol	Malicacid	Magnesium	...	Flavanoids	Hue	class
13.64	3.10	116	...	3.03	0.96	Barolo
14.21	4.04	111	...	2.65	0.87	Barolo
12.93	2.81	96	...	0.50	0.77	Barbera


- ここから以下を説明
 - どうやって望ましい予測器を手に入れるか？
 - 望ましい予測器とは？

ここから1次元入力の場合で説明




ここからしばらく、図で説明しやすいように、単回帰の場合で説明

- 特徴量が1次元の場合の回帰を単回帰という。



- この場合、一つ一つの予測器は次のように曲線のグラフで図示できる



【注意】 当たり前だが、実用上は、特徴量が1次元ということはほとんどない。

まずは予測器とする関数の候補を決めることから



関数を作るといっても、何から始めればいい？

- 思いつくかぎり色々な式を考えて行っても埒が開かなそう

$$f(x) = x^2 + 2x + 10$$

$$f(x) = x \log x$$

$$f(x) = \frac{1}{1 + x^2}$$




$$f(x) = e^{\cos x}$$

モデルとパラメーター＞例

まず、調整可能な**パラメーター**のついた関数（モデルという）を用意する

■ 例：100次多項式 $f_{\theta}(x) = \theta_0 + \theta_1 x + \dots + \theta_{100} x^{100}$

- 以下は全て100次多項式のグラフだが、異なる $\theta_0, \dots, \theta_{100}$ の値に対するもの



■ パラメーターとは、上の θ のように調整可能で、値を変えると関数に変化する変数

【実験ソースコード】 [番号] _model_introduction.ipynb

【補足】 モデルにも色々な種類があり、上のように有限個のパラメーターだけを持つモデルは「パラメトリックモデル」という。詳しくは後述。

モデルとパラメーター

一般には，予測器の候補を集めた関数の集合をモデルという

■ モデル（モデルクラス）

$$\mathcal{M} := \{f_{\theta} | \theta \in \Theta\}$$

- 候補となる予測器の集合（関数を集めた集合）
- θ を決めると関数 f_{θ} が1つ定まるので，調整可能なパラメーター θ が付いた関数「 f_{θ} 」と解釈することもできる

■ 例)

- r 次多項式モデル，決定木モデル，ニューラルネットワークモデル，……

【用語】主に統計的機械学習の理論分野では，1個1個のモデルのことを仮説（hypothesis），モデル集合のことを仮説クラス（hypothesis class）や仮説集合（hypothesis set）と呼ぶこともある。また，モデルクラスから選んだ1個の関数のこともモデルということがある。

次は望ましい予測器について






モデルのパラメーターを調整して，色々な関数を表現できる

- モデルのパラメーターをうまく調整することにより，色々な予測器を作ることができそうだ。
- どんな予測器にすればよいか分かれば，それに合うパラメーターを探索すれば良さそう。
- では，パラメーターの値をいくらにすればよいのか？

望ましい予測器とは

手元のデータで正しい出力をできる関数は無数に考えられる

- 6個のラベル付きデータが手元に得られたとする。
- 次の3つの予測器はどれも、手元にあるデータに対して正しく予測を出せる



- 3つのうち、どれが良いか？


望ましい予測器とは

予測器の良さは、未知のデータに対する性能で考える


■ 良い予測器とは、**汎化性能（generalization performance）**が高い予測器

- 手元のデータのみならず、**初見の入力でも予測がよく当たる**ということ


■ 手元のデータで正しいラベルを出力できるだけではダメ



↑
大きく外れた



↑
当たった



↑
少し外れた

何が入力されるかは分からない



何が入力されるか分からないのに、予測を外すなというのは、流石に無理

- 後出しだからなんとでも言える？その通り.
- 実際、これから渡される未知の入力について我々は何も知らない
 - ✗ あらゆる入力で正確な予測を目指す
- そこで、次善策として、次を目指すことにする.

○ 未知のデータが色々と入力される中で、

平均的には正確な予測を目指す

重要な考え方

データは、背後にある生成分布からランダムに出てくると考える

- データは確率変数であり、背後にある生成分布からサンプリングされる



- そして、これからサンプリングされる未知のデータに対して、平均的に良い性能を目指す = 期待予測誤差が小さい予測器を作ることを目指す

$$\mathbb{E}_{X,Y} [\text{予測誤差}]$$

【補足】 多くの場合、図のような有限母集団からのサンプリングではなく、無限にサンプルを取れることを仮定する。細かいが、上をさらに正確に言えば「データは確率変数の実現値である」と仮定する。なお、生成分布そのものは未知でよいし、具体的な分布族も分からないものとする。

損失関数

予測誤差を定義するために、まずは損失関数を選ぶ

- 予測誤差の定義として用いる関数を**損失関数 (loss function)** という

$$\ell(y, y')$$

- 正解ラベルが y のデータで、予測器の出した予測が y' だった場合の誤差評価値
- 分析者自身が、何を誤差の定量的な指標としたいか考えて選ぶ

- 例

- **二乗損失関数** : $\ell(y, y') = (y - y')^2$ (回帰タスクでの定番)
- **0/1-損失** : $\ell_{0/1}(y, y') = \mathbf{1}\{y \neq y'\}$ (分類タスクでの定番)

リスク関数

予測器 f の良し悪しをこれから現れるデータに対する期待損失で定義する

- リスク関数 (risk) : 損失関数の期待値 (期待損失ともいう)

$$R(f) := \mathbb{E} [\ell(Y, f(X))] = \int \ell(y, f(x)) p(x, y) dx dy$$

- 例) 損失関数として二乗損失を選んだ場合

$$R(f) := \mathbb{E} [(Y - f(X))^2] = \int (y - f(x))^2 p(x, y) dx dy$$

統計的学習におけるゴール

モデルのパラメーターを調節し、リスクの値が小さい予測器を作りたい

$$R(f_{\theta}) := \mathbb{E} [\ell(Y, f_{\theta}(X))] \rightarrow \text{小さくしたい}$$

- リスクは「予測の外れ度合いの指標」なので、これを小さくするようにモデルのパラメーター θ を調節したい

ゴール設定の変化



期待値で誤差を測ると決めたことによって、何が変わったか？

- あらゆる入力で完璧な予測を出すことは諦めた
- 損失の期待値
 - 出現確率が高い入力 → 予測を外すと期待値に大きく影響
 - 出現確率が低い入力 → 多少おろそかにしても影響は軽微（重みが小さい）
- 全てを完璧に打ち返せなくてもいいので、総じて平均的には高性能になるように頑張ろうという現実的な目標になった

ゴール設定の落とし穴



リスク関数を最小化すればいいのね！

- 落とし穴：データ (X, Y) の生成分布 $p(x, y)$ は未知

$$R(f) := \int \ell(y, f(x)) \underset{\substack{\uparrow \\ \text{未知}}}{p(x, y)} dx dy$$

- よって、 $R(f_\theta)$ が小さくなるようにパラメーターを探すどころか、1つの予測器 f_θ に対する $R(f_\theta)$ の値を求めることすらできない
- 「 $R(f_\theta)$ が小さくなるようにパラメーター θ を調節」はあくまで仮想的な目標であり、そのまま実現はできない

ではどうすればよいか



期待値は，標本平均で近似できる．例えば， $\mathbb{E}[X]$ を $\frac{1}{n} \sum_{i=1}^n X_i$ で近似．

- 手持ちのデータが一定の条件を満たすならば，データ量が増えれば標本平均は期待値の良い近似であることが期待できる（cf. 大数の法則や中心極限定理）
- そこで，手持ちのデータを使って， $R(f)$ を標本近似することにする．

訓練標本に関する仮定

手持ちのデータで、リスク関数を標本近似することにする

- そのための**仮定**：訓練データは、テストデータと同じ分布から取ったIIDサンプル

$$\{(X_i, Y_i)\}_{i=1}^n \stackrel{\text{i.i.d.}}{\sim} p$$

- ここで、 p はデータの生成分布（手持ちのデータとテストデータで共通）
- 手持ちのデータのことを、訓練標本ともよぶ

リスクの標本近似

$R(f)$ を手持ちの標本で近似する

- (期待) リスク

$$R(f) := \mathbb{E} [\ell(Y, f(X))]$$

……期待値

- 経験リスク (empirical risk)

$$\hat{R}(f) := \frac{1}{n} \sum_{i=1}^n \ell(y_i, f(x_i))$$

……標本平均

【補足】 区別のために、リスクのことを期待リスクや母集団リスク (population risk) ということもある。特に断らなければ、「期待」と言わなくてもリスクは損失の期待値のことを指す。

最も素朴な教師付き学習法

経験リスクであればデータから計算できるので、これを最小化する

- 経験リスク最小化 (empirical risk minimization, ERM)
 - 経験リスクが最小になるようにパラメーターを決めるという手法

$$\hat{R}(f_{\theta}) := \frac{1}{n} \sum_{i=1}^n \ell(y_i, f_{\theta}(x_i)) \rightarrow \text{最小化}$$

- このように、何らかの基準で最適なモデルのパラメーターを、データに基づいて決める、という過程を**学習 (learning)** あるいは**訓練 (training)** と呼ぶ

これまでのあらすじ

- 予測器を作りたい（特徴量を代入するとラベルの予測値が出てくる関数）



- モデル f_{θ} を選び、損失関数 ℓ を決め、期待損失が小さいパラメーター θ を探す

$$R(f_{\theta}) := \mathbb{E} [\ell(Y, f_{\theta}(X))] \leftarrow \text{計算不可能だが小さくしたい}$$

- 現実的には、損失のサンプル平均の最小化なら実行できることを紹介

$$L(\theta) := \hat{R}(f_{\theta}) := \frac{1}{n} \sum_{i=1}^n \ell(y_i, f_{\theta}(x_i)) \rightarrow \text{Minimize}$$

- 具体例は次のセクション