

予測系タスク① 回帰タスク

経験リスク最小化＞線型単回帰の場合

入力が1次元であるような回帰（単回帰；simple regression）

- ここでは、モデルは1次多項式だけを考えることにする


$$f_{w,b}(x) = wx + b \quad (w, b \in \mathbb{R})$$

- 損失関数は二乗損失とする

$$\ell(y, y') = (y - y')^2$$

- この場合のリスクは期待二乗誤差 → この値が小さい (w, b) を求めたい

$$R(f_{w,b}) := \mathbb{E} [\ell(Y, f_{w,b}(X))] \rightarrow \text{計算できない}$$



【補足】 モデルが1次関数の場合なので、これは線型単回帰（simple linear regression）という。


【用語】 この b は数学では切片（intercept）と呼ばれるが、機械学習の用語では「バイアス」（bias）と呼ばれることも多い。

単回帰＞最小二乗法によるモデルの学習

経験リスク最小化は、この場合、平均二乗誤差の最小化

- そこで代わりに、**最小二乗法 (ordinary least squares, OLS)** では、訓練データ $\{(x_i, y_i)\}_{i=1}^n$ に対する平均二乗誤差、つまり次の $L(w, b)$ を最小化する

$$L(w, b) := \frac{1}{n} \sum_{i=1}^n (y_i - f_{w,b}(x_i))^2 \rightarrow \text{最小化}$$



【補足】 言い換えると、訓練標本での平均二乗誤差 (mean squared error) が最小になるようにパラメーターを調整する。

基本知識の確認＞最適化問題

目的に対して最適な選択肢を求める問題

- **最小化問題 (minimization problem)** (本講義では最小化問題だけ扱う)

「 $L(\theta) \rightarrow$ 最小化 ($\theta \in \Theta$, θ に関する制約条件)」 や

「 $\text{Min}_{\theta \in \Theta} L(\theta)$ subject to θ に関する制約条件」 と表す

- 用語

- 最適化対象の関数 L を **目的関数 (objective function)** という
- L の値を最小にする入力 θ を **解 (solution)** や **最小化元 (minimizer)** という
- 解の候補とできる θ に何らかの **制約条件 (constraints)** が課されている場合がある (例: $\theta > 0$ など)

【補足】 L は実数値関数 $L: \Theta \rightarrow \mathbb{R}$. 最大化問題は $-f(x)$ を最小化すれば等価なので、基本的に最小化問題だけで説明する。

基本知識の確認＞最適化問題

最小二乗法によるモデルの学習を，最小化問題として表記

- いま解きたい問題は，最適化問題として改めて表記すると

$$\text{Min}_{(w,b) \in \mathbb{R}^2} L(w, b)$$

- ここで，目的関数は $L(w, b) = \frac{1}{n} \sum_{i=1}^n (y_i - wx_i - b)^2$
- (w, b) には実数である以外に特別な条件はないので，制約なし最適化問題

基本知識の確認＞最適化の一階の条件

制約なし最小化の場合，解は「微分して0」を満たす（必要条件）

■ 最適化の一階の条件（first-order condition）

- θ^* が $\text{Min}_{\theta \in \mathbb{R}} L(\theta)$ （制約条件なし）の解ならば， $\frac{dL}{d\theta}(\theta^*) = 0$ が成立

■ 例）二次関数の最小化

- $f(\theta) = \theta^2 + 2\theta + 1$ の場合， $\frac{df}{d\theta}(\theta) = 2\theta + 2$ なので最小化の解は $\theta = -1$ を満たす

【注意】説明のために省略しているが，正確には， L が連続微分可能であるなど，適当な仮定を満たす場合にのみ上記が成立する。

【補足】制約付き最適化の場合は，一階の条件として「微分して0」の代わりに，KKT条件（Karush–Kuhn–Tucker conditions）というものがある。

基本知識の確認＞偏微分

偏微分とは、多変数関数を特定の1変数だけで微分する操作

■ 偏微分とは

- 多変数関数を (例) $f(x, y) = x^2 + xy - y^2$
- 特定の変数で (例) x で
- 微分すること (例) $2x + y$

y は本来は変数だが、 x で偏微分するときは定数とみなして扱う

■ 記号

- 偏微分した関数を $\frac{\partial f}{\partial x}$, $\frac{\partial f}{\partial y}$ などで表す

基本知識の確認＞最適化の一階の条件＞多変数の場合

多変数の場合にも一般化される（必要条件）

■ 最適化の**一階の条件**（first-order condition）

- θ^* が $\text{Min}_{\theta \in \mathbb{R}^d} L(\theta)$ （制約条件なし）の解ならば、 $\frac{dL}{d\theta}(\theta^*) = \mathbf{0}$ が成立
- ここで、 $\frac{dL}{d\theta}$ は偏微分を並べた横ベクトル：

$$\frac{dL}{d\theta} = \left[\frac{\partial L}{\partial \theta_1} \quad \frac{\partial L}{\partial \theta_2} \quad \cdots \quad \frac{\partial L}{\partial \theta_d} \right]$$

- つまり、**各変数について同時に「微分して0」**の条件が成立

単回帰 > 最小二乗法 > 最適化手法

実際に最適なパラメーターを求めてみよう

- 最小化問題「 $\text{Min}_{(w,b) \in \mathbb{R}^2} L(w,b)$ 」の一階の条件

$$\frac{\partial L(w,b)}{\partial w} = 0, \quad \frac{\partial L(w,b)}{\partial b} = 0 \Leftrightarrow \begin{cases} (1/n) \sum_i 2(wx_i + b - y_i)x_i = 0 \\ (1/n) \sum_i 2(wx_i + b - y_i) = 0 \end{cases}$$

- これを解いて、解 $(\hat{w}, \hat{b})$ は、

$$\begin{pmatrix} \hat{w} \\ \hat{b} \end{pmatrix} = \begin{pmatrix} \sum_i x_i^2 & \sum_i x_i \\ \sum_i x_i & n \end{pmatrix}^{-1} \begin{pmatrix} \sum_i x_i y_i \\ \sum_i y_i \end{pmatrix}$$

単回帰 > 最小二乗法

一度まとめておく

■ 回帰タスクのための、最小二乗法による教師付き学習（線型単回帰の場合）


- モデルは $f_{w,b}(x) = wx + b$ ($w, b \in \mathbb{R}$) とする.
- パラメーターは、目的関数 $L(w, b) := \frac{1}{n} \sum_{i=1}^n (y_i - f_{w,b}(x_i))^2$ の最小化により選ぶ.
 - ▶ 今回の場合、最小化の解は次の式で求められる

$$\begin{pmatrix} \hat{w} \\ \hat{b} \end{pmatrix} = \begin{pmatrix} \sum_i x_i^2 & \sum_i x_i \\ \sum_i x_i & n \end{pmatrix}^{-1} \begin{pmatrix} \sum_i x_i y_i \\ \sum_i y_i \end{pmatrix}$$


- 学習法：訓練データからこれを計算して、 $f_{\hat{w},\hat{b}}(x) = \hat{w}x + \hat{b}$ を予測器として使う

単回帰 > 最小二乗法 > 訓練の実行例

左：訓練前の予測器， 右：訓練後の予測器（青点が訓練データ）



最小二乗法で
パラメーターを
調整




ランダムに決めたパラメーター

最小二乗法で得たパラメーター

単回帰＞最小二乗法＞訓練済みの予測器

とりあえず予測器を学習することまではできた

- しかし、ゴールは、未知データに対する性能が良い予測器を手に入れること
- この訓練済みモデルで、未知データでの予測は、どれくらい当たるのか？




訓練済みモデル

訓練と評価

モデルを訓練するデータと、性能評価に用いるデータは別にする

- 適切な評価をするには、モデルが訓練時に見ていないデータを用いる必要がある



- データを分けるのは、実際の使用場面になるべく近い性能を推定したいため

【補足】データを取り置くなどの工夫を凝らしたとしても、あくまでも最終ゴールは実際の使用場面で高い性能を発揮するモデルを得ることであって、評価用データでの性能はそのための推定値に過ぎない。


訓練と評価＞置き置き法（holdout method）

大原則は「最終的な性能の近似としてなるべく良い方法」を評価に使うこと

- 無作為分割（random split）（例）訓練用:評価用=7:3で置き置く



- 時系列分割（time-series split）（例）最新1ヶ月のデータを評価用に置き置く




【用語】置き置き法は、文字通り、あとで用いるデータを学習前に置き置いておく方法の総称だが、特に断りがなければ無作為分割を指すことも多い。なお、置き置き法という訳語は（優れていると思うが）浸透しているわけではない。日本語でも外来語としてホールドアウト法と呼ばれることが多い。

【補足】置き置き法以外にも、交差検証法や情報量規準など、最終的な性能を推定するための手法は数多く存在する。


訓練済みモデルによる予測の実行例

人工データで実験（評価用データとそれに対する予測値の図）

★：正解ラベル y
●：予測ラベル $\hat{y}$



学習後のモデルによる、
評価用データに対する予測




参考：

学習前のモデルによる予測

最小化問題

「目的関数 $L(\theta)$ を, $\theta \in \Theta$ の範囲で, 最小化する」という問題



- ゴールは, **最小化元 (minimizer)** を見つけること
 - 「 $L(\theta)$ が最小になる入力 θ 」のこと. **解 (solution)** と呼ぶ.

最小化問題＞その他の記号

「目的関数 $L(\theta)$ を, $\theta \in \Theta$ の範囲で, 最小化する」という問題

- この講義では, $\text{Min}_{\theta \in \Theta} L(\theta)$ の代わりに, 次のようにも書くことがある

$L(\theta) \rightarrow$ 最小化 ($\theta \in \Theta$, θ に関する制約条件)

- 「最小化問題」は（大文字で） $\text{Min}_{\theta \in \Theta} L(\theta)$ と書いたが,
 - 小文字で $\min_{\theta \in \Theta} L(\theta)$ と書いたら, 最小値（最小のときの $L(\theta)$ の値）を表す
 - $\arg \min_{\theta \in \Theta} L(\theta)$ と書いたら, 最小化元（一つとは限らない）の集合を表す

-
- データは、次の記号で表す

$$\{(x_i, y_i)\}_{i=1}^n$$

- 今回は、単回帰なので、 $x_i \in \mathbb{R}$, $y_i \in \mathbb{R}$.
- これは、予測タスクを実際に行う際に出てくる未知データと同じ生成分布からの i.i.d. サンプルだと仮定しておく

-
- このデータを次のように使って目的関数を定義する

$$L(w, b) = \frac{1}{n} \sum_{i=1}^n (y_i - f_{w,b}(x_i))^2$$


- これが小さいパラメーターを求めることによる学習法が「経験リスク最小化」

$$\text{Min}_{(w,b) \in \mathbb{R}^2} L(w, b)$$

- この場合は、結果として「二乗誤差の平均の最小化により学習を行う」という手法になっているので、**最小二乗法 (ordinary least squares)** と呼ばれる

この場合の最適化問題：この目的関数を最小化する点 (w, b) を見つけたい

$$L(w, b) = \frac{1}{n} \sum_{i=1}^n (y_i - f_{w,b}(x_i))^2$$



この曲面の底にあたる
 $(\hat{w}, \hat{b})$ が最適解

この最小化元を見つけるには？

- 一階の条件（必要条件）

$$\nabla L(w, b) = \mathbf{0}$$

- 勾配（gradient）：偏微分を並べた縦ベクトル（パラメーター数と同じ次元）

$$\nabla L(\boldsymbol{\theta}) = \begin{pmatrix} \frac{\partial}{\partial \theta_1} L(\boldsymbol{\theta}) \\ \vdots \\ \frac{\partial}{\partial \theta_r} L(\boldsymbol{\theta}) \end{pmatrix}$$

【補足】一階の条件が「勾配 = 0」となるのは、制約なし最適化だからである。制約付き最適化の場合は、代わりにKKT条件（Karush–Kuhn–Tucker conditions）と呼ばれる条件が一階の条件になる。もちろん、制約なし最適化の場合の「勾配 = 0」という条件は、KKT条件の特殊ケースである。

手元でやってみよう

- 目的関数

$$L(w, b) := \frac{1}{2} \sum_{i=1}^n (y_i - (wx_i + b))^2$$

- 勾配を定義から計算しよう

$$\nabla L(w, b) := \begin{pmatrix} \frac{\partial}{\partial w} L(w, b) \\ \frac{\partial}{\partial b} L(w, b) \end{pmatrix} = \begin{pmatrix} ? \\ ? \end{pmatrix}$$

- そこから、一階の条件 $\nabla L(w, b) = \mathbf{0}$ を次の形に式変形しよう

$$\begin{pmatrix} ? \\ ? \end{pmatrix} \begin{pmatrix} w \\ b \end{pmatrix} = \begin{pmatrix} ? \end{pmatrix}$$