

線型モデル

基本知識の確認＞ベクトルの内積

同じ位置の成分同士を掛けて、足し上げた値を内積（inner product）という

■ ベクトルの内積 $\langle \mathbf{a}, \mathbf{b} \rangle$

$$\mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_d \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_d \end{bmatrix} \text{ に対して, } \langle \mathbf{a}, \mathbf{b} \rangle := a_1 b_1 + \cdots + a_d b_d$$

■ 別の表記法 $\mathbf{a}^\top \mathbf{b}$ （ $1 \times d$ 行列と $d \times 1$ 行列の積とみなして計算）

$$\mathbf{a}^\top \mathbf{b} = [a_1 \ a_2 \ \cdots \ a_d] \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_d \end{bmatrix} = a_1 b_1 + \cdots + a_d b_d$$

【補足】 $\mathbf{a}^\top \mathbf{b}$ という表記は、内積の記号 $\langle \cdot, \cdot \rangle$ を定義するまでもなく伝わりが多いので、ある意味スマートな表記である。

基本知識の確認＞ベクトルの内積

内積の主な出番は3つ

- 重み付き和を簡潔に表す（成分ごとの重み $\mathbf{w} = (w_1, \dots, w_d)$ ）


$$\mathbf{w}^T \mathbf{x} = w_1 x_1 + \dots + w_d x_d$$

- 2つのベクトルの向き of 揃い具合（同じ向きで最大，逆向きで最小）

$$\langle \nearrow, \searrow \rangle = -1, \quad \langle \nearrow, \nearrow \rangle = 0, \quad \langle \nearrow, \nwarrow \rangle = 1 \quad (\text{長さ1の場合})$$

- 特定の方向の成分の抽出（ベクトル $\mathbf{a}$ の「ベクトル $\mathbf{b}$ 方向成分」）

$$\mathbf{a} = \frac{\langle \mathbf{a}, \mathbf{b} \rangle}{\langle \mathbf{b}, \mathbf{b} \rangle} \mathbf{b} + (\mathbf{b} \text{ に直交する成分})$$



【補足】 同じ向きを向いている場合に内積が最も大きくなるという主張はコーシー・シュワルツの不等式から従う。ここでベクトルの長さは $\|\cdot\| = \sqrt{\langle \cdot, \cdot \rangle}$ で測る。

最後の $\mathbf{a} = (\langle \mathbf{a}, \mathbf{b} \rangle / \langle \mathbf{b}, \mathbf{b} \rangle) \mathbf{b} + (\mathbf{b} \text{ に直交する成分})$ という分解は、 $\langle \mathbf{a} - (\langle \mathbf{a}, \mathbf{b} \rangle / \langle \mathbf{b}, \mathbf{b} \rangle) \mathbf{b}, \mathbf{b} \rangle = \langle \mathbf{a}, \mathbf{b} \rangle - (\langle \mathbf{a}, \mathbf{b} \rangle / \langle \mathbf{b}, \mathbf{b} \rangle) \cdot \langle \mathbf{b}, \mathbf{b} \rangle = 0$ により確かめられる。

基本知識の確認＞ベクトルの内積の基本性質

内積は線型性と対称性をもつ

■ 線型性 (linearity) : $\langle \mathbf{x}, \alpha \mathbf{y} + \beta \mathbf{z} \rangle = \alpha \langle \mathbf{x}, \mathbf{y} \rangle + \beta \langle \mathbf{x}, \mathbf{z} \rangle$

- 一般に, 左側についても同時に線型 (双線型)

$$\langle a\mathbf{x} + b\mathbf{y}, c\mathbf{z} + d\mathbf{w} \rangle = ac\langle \mathbf{x}, \mathbf{z} \rangle + ad\langle \mathbf{x}, \mathbf{w} \rangle + bc\langle \mathbf{y}, \mathbf{z} \rangle + bd\langle \mathbf{y}, \mathbf{w} \rangle$$

- これは括弧の分配法則の一般化 $(a + b)(c + d) = ac + bd + bc + bd$
- 特に今回は「重みに関する線型性」という形で関係 : $(\mathbf{v} + \mathbf{w})^\top \mathbf{x} = \mathbf{v}^\top \mathbf{x} + \mathbf{w}^\top \mathbf{x}$


■ 対称性 (symmetry) : $\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle$

- 転置で表記すると少しだけ意外に見える : $\mathbf{w}^\top \mathbf{x} = \mathbf{x}^\top \mathbf{w}$


もっと複雑なモデル

もっと表現能力が高い複雑なモデルを使いたい

- 入力に対して非線型なモデルも使いたい（例：多項式回帰）



線型単回帰



非線型単回帰

- 画像／テキストなどを入力にする回帰モデルも作りたい



f_{θ}



7

キュウリの品質

“こんな映画には
滅多に出会えない”



f_{θ}



4.9

レーティング予測

線型モデル

特徴量 $\phi(x)$ とパラメーター θ の内積を使って表されるモデル

■ パラメーター線型モデル (linear-in-parameter model)

$$f_{\theta}(x) := \theta^{\top} \phi(x) \quad \left(= \sum_{b=0}^B \theta_b \phi_b(x) \right)$$

$$x \in \mathcal{X}, \phi_b(x) : \mathcal{X} \rightarrow \mathbb{R}$$

$$\phi(x) = \begin{pmatrix} \phi_0(x) \\ \vdots \\ \phi_B(x) \end{pmatrix} : \text{変換された特徴量}$$

- ここで, $\phi = (\phi_b)_{b=0}^B$ は任意の関数であり, 特徴写像 (feature map) と呼ぶ.
- $\theta \in \mathbb{R}^{B+1}$ は係数 (coefficient) や重み (weight) と呼ぶことがある.

【補足】ただし, $(\phi_b)_{b=0}^B$ は線型独立であることを仮定する. 仮に線型独立でなければ, 最初から従属なものを除外しておいても表現力は変わらない. 任意の関数と書いたが理論解析の際には多少の正則条件は課される. 【用語】 $(\phi_b)_{b=0}^B$ は基底関数 (basis functions) とも呼ばれるが, これは数学の「基底」とは違う意味なので注意.

線型モデル > 注意

線型といってもパラメーター θ に関して線型であればよい

$$f_{\theta}(x) = \theta^{\top} \phi(x)$$

- 特徴量変換 ϕ は非線型でもよい，つまり一般に入力 x に関しては非線型.
 - 特に， x に対しても線型なモデル $f_{\theta}(x) = \theta^{\top} x$ は，データ線型モデル（linear-in-data model）と呼んで区別する
- この講義で単に線型モデルといったときは，パラメーター線型モデルを指す.

線型モデルの例＞多項式モデル

入力に対しては非線型でも、パラメーターに対しては線型


- r 次多項式モデル (r -th order polynomial model)

$$f_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \dots + \theta_r x^r$$

- 多項式の次数 r を上げれば複雑なモデルを表現できる

- これは、特徴写像を次のように定義すれば、 $f_{\theta}(x) = \boldsymbol{\theta}^{\top} \boldsymbol{\phi}(x)$ と表せる

$$\boldsymbol{\phi}(x) = \begin{bmatrix} 1 \\ x \\ \vdots \\ x^r \end{bmatrix}$$



【補足】ストーン・ワイエルシュトラスの定理 (Stone-Weierstrass theorem) により、多項式モデルで任意の連続関数を近似することができる (任意の有界区間で任意の精度まで、一様ノルムでの近似が、十分に大きい k を用いれば成立)

線型モデルの例＞三角多項式モデル

色々な特徴写像がある

- 三角多項式 (trigonometric polynomial) モデル

$$\phi(x) = \begin{bmatrix} 1 \\ \sin(x) \\ \cos(x) \\ \vdots \\ \sin(kx) \\ \cos(kx) \end{bmatrix}$$

- 一定間隔で特徴量が同じ値になるので、周期性をもったモデルになる

$$f_{\theta}(x) = \theta_0 + \theta_{1s} \sin(x) + \theta_{1c} \cos(x) + \cdots + \theta_{ks} \sin(kx) + \theta_{kc} \cos(kx)$$

【補足】 ストーン・ワイエルシュトラスの定理 (Stone-Weierstrass theorem) により、三角多項式モデルで任意の連続関数を近似することができる (任意の有界区間で任意の精度まで、一様ノルムでの近似が、十分に大きい k を用いれば成立) (Powell, 1981, Theorem 13.1).

線型モデルの例＞多変数多項式モデル

色々な特徴写像がある

■ 多変数の多項式

$$\phi(x, y) := (1, \underbrace{x, y}_{\text{degree 1}}, \underbrace{x^2, xy, y^2}_{\text{degree 2}}, \dots, \underbrace{x^r, x^{r-1}y, \dots, xy^{r-1}, y^r}_{\text{degree } r})^\top$$

- あらかじめ交差項をこのように入れておけば, 多変数の多項式でも表せる

$$f_{\theta}(x, y) = \theta_0 + \theta_{1,0}x + \theta_{1,1}y + \theta_{2,0}x^2 + \theta_{2,1}xy + \theta_{2,2}y^2 + \dots + \theta_{r,0}x^r + \dots + \theta_{r,r}y^r$$

線型モデルの例＞Bag-of-words特徴量＋線型モデル

色々な特徴画像がある

- まず、語彙一覧 (vocabulary) を用意しておく

演奏, 演技, 演歌, 漢方, 漫画, ……

- 続いて、語彙に含まれる単語全ての出現回数をカウントして、特徴量として使う

入力


本日、老舗の演歌歌手が伝統と革新を融合させた舞台上、情感あふれる演技とともに演歌の名曲を披露し、観客から熱い拍手を浴びました。

→ {演奏: 0, 演技: 1, 演歌: 2, 漢方: 0, 漫画: 0, ……} なので, $\phi(x) = \begin{bmatrix} 0 \\ 1 \\ 2 \\ 0 \\ 0 \\ \vdots \end{bmatrix}$

線型モデルの例＞HOG特徴量＋線型モデル

色々な特徴写像がある

- HOG (Histogram of Oriented Gradients) 記述子
 - 画像の輝度勾配ヒストグラムを元にした特徴量（仕組みの説明は省略）



- 写真に人が写っているか否かの判定など

【実験コード】 [番号]_feature_map_HOG.ipynb 【画像出典】 <https://www.flickr.com/photos/nasacommons/16504233985/>

【参考】 Dalal, N., & Triggs, B. (2005). Histograms of oriented gradients for human detection. 2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05), 1, 886–893 vol. 1. <https://doi.org/10.1109/CVPR.2005.177>

特徴量エンジニアリング



特徴量変換器を実際の応用に合わせて作ることは非常に重要

- 特徴量変換の作り込みを特徴量エンジニアリング (feature engineering) という
 - 応用ごとに作り込みを行うもの。性能にも寄与することがよくある。
 - 職人芸な面がある
- 一方、自前の特徴量変換器を作らなくてもよい場合が増えている
 - 事前学習済みの特徴量抽出器をダウンロードして使えば、基本的なタスクは解けることがある

予測タスクにおける線型モデルの恩恵



パラメーター線型モデルは扱いやすい道具として今でも使われることがある


■ 線型だと何が良いか？

- 理論的な取り扱いが簡単
- 最適化が簡単にできる場合も多い
- ϕ が（今のタスクを解くために）優れていれば、これだけで十分な表現力あり

■ 弱点

- モデルの性能限界がすべて ϕ に懸かっているので、 ϕ によっては高性能が出ない

線型モデルの例としては、多項式モデルなどがある




- こんなに曲がっているのに線型とはどういうこと？

多項式モデルも線型モデルであるとは？

- 次のように特徴写像を定義すればよい

$$\boldsymbol{\phi}(x) = \begin{bmatrix} 1 \\ x \\ \vdots \\ x^r \end{bmatrix}$$



- そうすると，これを特徴写像として使う線型モデル $f_{\boldsymbol{\theta}}(x) = \langle \boldsymbol{\theta}, \boldsymbol{\phi}(x) \rangle$ は，

$$\langle \boldsymbol{\theta}, \boldsymbol{\phi}(x) \rangle = \theta_0 + \theta_1 x + \theta_2 x^2 + \cdots + \theta_r x^r$$

- なので，確かに r 次の多項式モデルになった！