

線型モデルの最小二乗法


線型モデルでの最小二乗法の解

一般の線型モデルでの最小二乗法の解を求めてみよう

- 線型モデル $f_{\theta}(x) = \theta^{\top} \phi(x)$ の場合に、最適化問題

$$\text{Min}_{\theta \in \mathbb{R}^{B+1}} \frac{1}{2} \sum_{i=1}^n (y_i - f_{\theta}(x_i))^2$$

を解き、解となるパラメーター $\hat{\theta}$ を求めよ.



線型モデルでの最小二乗法の解

解の求め方の流れ

1) 目的関数は $L(\boldsymbol{\theta}) = \frac{1}{2} (\boldsymbol{\Phi}\boldsymbol{\theta} - \mathbf{y})^\top (\boldsymbol{\Phi}\boldsymbol{\theta} - \mathbf{y})$ と書き直せることを確認せよ。ここで,

$$\boldsymbol{\Phi} := \begin{pmatrix} \boldsymbol{\phi}(\mathbf{x}_1)^\top \\ \vdots \\ \boldsymbol{\phi}(\mathbf{x}_n)^\top \end{pmatrix} = \begin{pmatrix} \phi_0(\mathbf{x}_1) & \cdots & \phi_B(\mathbf{x}_1) \\ \vdots & \ddots & \vdots \\ \phi_0(\mathbf{x}_n) & \cdots & \phi_B(\mathbf{x}_n) \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}$$

2) $\text{Min}_{\boldsymbol{\theta} \in \mathbb{R}^{B+1}} L(\boldsymbol{\theta})$ を解け。ただし, $(\boldsymbol{\Phi}^\top \boldsymbol{\Phi})^{-1}$ が存在することを仮定する。

【用語】 この $\boldsymbol{\Phi}$ を計画行列 (design matrix) とよぶ。 ヒント: $\nabla_{\boldsymbol{\theta}}(\boldsymbol{\theta}^\top \mathbf{A} \boldsymbol{\theta}) = 2\mathbf{A}\boldsymbol{\theta}$, $\nabla_{\boldsymbol{\theta}}(\mathbf{b}^\top \boldsymbol{\theta}) = \mathbf{b}$ を使う。

【参考】 自力で解いてみる場合, Petersen, K. B., & Pedersen, M. S. (2012, November). The Matrix Cookbook. Technical University of Denmark. <http://www2.compute.dtu.dk/pubdb/pubs/3274-full.html> を片手に取り組むとよい。

線型モデルでの最小二乗法の解

必要条件である一階の条件を適用する

- **勾配 (gradient)** : 偏微分を並べた縦ベクトル (パラメーター数と同じ次元)

$$\nabla_{\boldsymbol{\theta}} L(\boldsymbol{\theta}) = \begin{pmatrix} \frac{\partial L(\boldsymbol{\theta})}{\partial \theta_0} \\ \vdots \\ \frac{\partial L(\boldsymbol{\theta})}{\partial \theta_B} \end{pmatrix}$$

- 最適解の必要条件として、一階の条件がある

- 制約なし最適化の場合 : $\nabla L(\boldsymbol{\theta}) = \mathbf{0}$

今回はこちら

- 制約付き最適化の場合 : KKT条件 (Karush–Kuhn–Tucker conditions)

線型モデルでの最小二乗法の解

最適解が満たす方程式（一階の条件）：勾配が0となる点を探す

$$\nabla_{\boldsymbol{\theta}} L(\boldsymbol{\theta}) = \begin{pmatrix} \frac{\partial L}{\partial \theta_0} \\ \vdots \\ \frac{\partial L}{\partial \theta_B} \end{pmatrix} = \boldsymbol{\Phi}^\top \boldsymbol{\Phi} \boldsymbol{\theta} - \boldsymbol{\Phi}^\top \mathbf{y} = \mathbf{0}$$

- これを解いて

$$\hat{\boldsymbol{\theta}} = (\boldsymbol{\Phi}^\top \boldsymbol{\Phi})^{-1} \boldsymbol{\Phi}^\top \mathbf{y}$$



- 最適解が閉じた形式で求まった

【用語】線型最小二乗回帰における $\nabla_{\boldsymbol{\theta}} L(\boldsymbol{\theta}) = \mathbf{0}$ という式を正規方程式（normal equation）という。正規方程式という用語の由来：方程式 $\boldsymbol{\Phi}^\top (\boldsymbol{\Phi} \boldsymbol{\theta} - \mathbf{y}) = \mathbf{0}$ は、 $(\boldsymbol{\Phi} \boldsymbol{\theta} - \mathbf{y})^\top \boldsymbol{\Phi} = \mathbf{0}^\top \Leftrightarrow \langle \boldsymbol{\Phi} \boldsymbol{\theta} - \mathbf{y}, \boldsymbol{\Phi}(\cdot) \rangle = 0$ ，すなわち $(\boldsymbol{\Phi} \boldsymbol{\theta} - \mathbf{y}) \perp \text{range}(\boldsymbol{\Phi})$ と同値。つまり、 $\text{range}(\boldsymbol{\Phi})$ に対する法線ベクトル（normal vector）になっていることを表す方程式なので、上記の名前になっている。閉じた形式（closed-form）は、四則演算や指数・対数、冪乗（べき乗）等の「よく知られた」関数で表される式を指す通称。

線型モデルでの最小二乗法 > 実行例

三角多項式モデル $f_{\theta}(x) = \theta^{\top} \phi(x)$ を最小二乗法で学習した結果

- ここで, $\phi(x) = (1, \sin(x), \cos(x), \sin(2x), \cos(2x), \dots, \sin(15x), \cos(15x))^{\top}$.



- 評価データによる予測性能評価も妥当

過適合 (過学習)

これまでのあらすじ

- 予測器を作りたい



- モデル f_{θ} を選び、損失関数 ℓ を決め、期待損失が小さいパラメーター θ を探す


$$R(f_{\theta}) := \mathbb{E} [\ell(Y, f_{\theta}(X))] \leftarrow \text{計算不可能だが小さくしたい}$$

- 現実的には、損失のサンプル平均の最小化なら実行できることを紹介

$$L(\theta) := \hat{R}(f_{\theta}) := \frac{1}{n} \sum_{i=1}^n \ell(y_i, f_{\theta}(x_i)) \rightarrow \text{Minimize}$$

経験リスク

経験リスクは、リスク関数をサンプル近似したもの



経験リスク最小化 (Empirical Risk Minimization)

経験リスクを（何も手を加えずそのまま）目的関数として学習する

- 経験リスクそのものを目的関数として設定して最小化

$$L(\theta) = \hat{R}(f_{\theta}) \rightarrow \text{Minimize } \theta \in \Theta$$

- リスクのサンプル近似を最小化しているので、妥当そうではある
- しかし、愚直にこれだけを実行すると、過適合することがある

経験リスク最小化の限界




特に複雑なモデルでは、過適合・過学習という問題が起きるようになる

- 経験リスク最小化は、 $R(f_\theta)$ が小さくなることを願って、 $\hat{R}(f_\theta)$ を最小化する手法
 - しかし、狙い通りに $R(f_\theta)$ が小さくなるかどうかは別問題
 - 上手くいくときはうまくいくが、思惑通りにはいかないことの方が多い
- 特に、過適合・過学習という問題が生じる場合があることが知られている

経験リスク最小化

多項式モデルの最小二乗法での学習の成功例

- 4次関数でうまく予測できるような生成分布のデータで実験
 - 4次関数モデルを最小二乗法で学習した結果, よいモデルができた




4次関数モデル

過適合（過学習）

パラメーターが多いモデルを単なるERMで学習させると、**過適合**が生じがち

- **過適合（overfit）**：経験リスクは小さくなったが、リスクが小さくない状態
 - つまり、見かけ上の学習はしているが、汎化しないモデルになっている状態



16次関数モデル


【用語】 過適合という訳のほうが英語とうまく対応するが、日本語では過学習という用語も浸透している。外来語としてオーバーフィットということもある。

【実験ソースコード】 [番号]_overfit_linear_model.ipynb

過少適合

パラメーターが少なすぎるモデルだけでやりくりするのも難しい

- **過少適合 (underfit)** : 最適化後でも経験リスクが大きいままの状態
 - つまり, モデルの柔軟さが足りず, そもそも学習が十分に進まない状態




2次関数モデル

【用語】 外来語としてアンダーフィットということも多い.

【実験ソースコード】 [番号]_overfit_linear_model.ipynb

過適合現象（Overfitting）＞ 模式図によるまとめ


モデルの複雑度を上げていくと，リスクの値が再び上昇する現象



過適合現象（Overfitting）＞学習曲線（Learning Curve）

実験：多項式モデルの最小二乗回帰で次数を上げていった結果

- 横軸：多項式の最大次数，縦軸：損失値として，訓練・評価の損失を描いた図




【実験ソースコード】 [番号]_learning_curve_overfitting.ipynb

【用語】 横軸が何らかのモデル複雑度，縦軸が何らかの指標値として，訓練と評価の結果をそれぞれプロットした曲線のことを，学習曲線という。

過適合現象（Overfitting） > 学習曲線（Learning Curve）

- 評価損失が最良だったモデル




モデルの複雑度と正則化

多項式モデルの過適合とパラメーターの大きさ

上下に激しく変動する関数はパラメーターの絶対値が大きくなって発生

- 入力の微小な差に大きく反応 = パラメーターの絶対値が大きい
- 訓練データ点を通過するように辻褄を合わせていると考えられる



	r=2	r=4	r=16
θ_0	8.0	-1.8	-87.1
θ_1	-23.4	112.3	10466.1
θ_2	7.3	-327.4	-487005.0
θ_3		219.0	12103103.6
θ_4		-1.2	-180067412.9
θ_5			1723030777.0
θ_6			-11159264579.3
θ_7			50782142907.2
θ_8			-166670522119.7
θ_9			400990179401.2
θ_{10}			-712278442253.3
θ_{11}			932198468910.3
θ_{12}			-887330785442.5
θ_{13}			597242347925.3
θ_{14}			-269343089344.4
θ_{15}			73003666266.9
θ_{16}			-8989291594.0

基本知識の確認＞ベクトルの大きさ（ノルム）

ベクトルの大きさ（長さ）はノルムで測る

■ ノルム (norm) $\|x\|$

- 性質： $\|x\| \geq 0$, かつ, $(\|x\| = 0) \Leftrightarrow (x = \mathbf{0})$
- 性質： $\|\alpha x\| = |\alpha| \cdot \|x\|$ （斉次性）, $\|x + y\| \leq \|x\| + \|y\|$ （三角不等式）

■ 内積から誘導されるノルム $\|x\|_{\ell^2}$ （2-ノルム）

$$\|x\|_{\ell^2} = \sqrt{\langle x, x \rangle} = \sqrt{x_1^2 + x_2^2 + \cdots + x_d^2}$$

- 最も有名なノルム（断りがなければこれ）


正則化 > L2正則化付き経験リスク最小化

2-ノルムを用いた罰則項を目的関数に追加して，過適合を防止

■ L2正則化 (L2 regularization)

$$L(\boldsymbol{\theta}) := \underbrace{\hat{R}(f_{\boldsymbol{\theta}})}_{\text{損失項}} + \underbrace{\lambda \cdot \|\boldsymbol{\theta}\|^2}_{\text{正則化項}} \rightarrow \text{最小化}$$

- $\lambda \geq 0$ は**正則化係数 (regularization coefficient)** という (学習時には固定)




線型モデルでのL2正則化付き最小二乗法の解

一般の線型モデルでのL2正則化付き最小二乗法の解を求めてみよう

- 線型モデル $f_{\theta}(x) = \theta^{\top} \phi(x)$ の場合に、最適化問題

$$\text{Min}_{\theta \in \mathbb{R}^{B+1}} \frac{1}{2} \sum_{i=1}^n (y_i - f_{\theta}(x_i))^2 + \frac{\lambda}{2} \|\theta\|^2$$



を解き、解となるパラメーター $\hat{\theta}$ を求めよ。

- 記号として以下を使う

$$\Phi := \begin{pmatrix} \phi(x_1)^{\top} \\ \vdots \\ \phi(x_n)^{\top} \end{pmatrix} = \begin{pmatrix} \phi_0(x_1) & \cdots & \phi_B(x_1) \\ \vdots & \ddots & \vdots \\ \phi_0(x_n) & \cdots & \phi_B(x_n) \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}$$

正則化＞線型モデルのL2正則化付き最小二乗法

正則化無しの場合と同じ方法で最適解の公式を得られる

- 正則化付きの目的関数は、 $\lambda\|\boldsymbol{\theta}\|^2 = \lambda\boldsymbol{\theta}^\top\boldsymbol{\theta} = \boldsymbol{\theta}^\top(\lambda\boldsymbol{I})\boldsymbol{\theta}$ に注意すると、

$$L(\boldsymbol{\theta}) = \frac{1}{2}(\mathbf{y} - \boldsymbol{\Phi}\boldsymbol{\theta})^\top(\mathbf{y} - \boldsymbol{\Phi}\boldsymbol{\theta}) + \boldsymbol{\theta}^\top\left(\frac{\lambda}{2}\boldsymbol{I}\right)\boldsymbol{\theta}$$

- 一階の条件




$$\nabla_{\boldsymbol{\theta}}L(\boldsymbol{\theta}) = (\boldsymbol{\Phi}^\top\boldsymbol{\Phi} + \lambda\boldsymbol{I})\boldsymbol{\theta} - \boldsymbol{\Phi}\mathbf{y} = \mathbf{0}$$

- よって、最適解の公式として次を得られる。

$$\hat{\boldsymbol{\theta}} = (\boldsymbol{\Phi}^\top\boldsymbol{\Phi} + \lambda\boldsymbol{I})^{-1}\boldsymbol{\Phi}^\top\mathbf{y}$$

正則化＞線型モデルのL2正則化付き最小二乗法＞実行例

L2正則化の強さを操作することで、過適合をコントロールできる



正則化無し 0 $\xrightarrow{\lambda}$ 正則化強

- 正則化係数 λ の大きさによって、正則化の強さを調整し、過適合を抑制できる

【補足】 正則化が強すぎると $\lambda \rightarrow +\infty$ で $\theta \simeq 0$ が解となり、例えば線型モデルなら定数関数になってしまう。

【実験ソースコード】 [番号]_l2_regularized_linear_regression.ipynb

正則化 (Regularization)

より単純なモデルが学習されるようにする仕掛けのこと

- 意図して組み込む明示的な正則化と、意図せず機能する暗黙的な正則化がある

明示的な正則化 (explicit regularization)

- 最適化問題の目的関数や制約式に手を加えるなど
- 例) L2正則化

暗黙的な正則化 (implicit regularization)

- 選んだ最適化法の傾向など明示的でない全ての正則化
- 例) 確率的勾配法の性質

過適合の防止



過適合を防止するには、モデルを適切に制限する必要がある

- モデルの複雑度を抑えるためには、いくつかの方法がある
 - モデルや学習過程の**正則化**を行う
 - モデルに固有の、複雑度を調整できる方法もある（例：多項式回帰の次数）
- どのぐらいの正則化を施せばよいか