


前回の振り返り

ロードマップ




【補足】 ちなみに、この画像は生成画像です。

最小二乗法による単回帰タスクの線型モデルの学習

手計算できるぐらいの例で一旦説明

- 単回帰タスクを使って説明
 - 入力される特徴量 x は1次元の実数
 - 予測したいラベル y も1次元の実数



データ収集状況

ラベル付きデータを収集して、それが手元にあるとする

- ラベル付きデータ $\{(x_i, y_i)\}_{i=1}^n$ が訓練用データとして得られている

特徴量	ラベル
x_1	y_1
x_2	y_2
$\vdots$	$\vdots$

- 今回は、単回帰なので、 $x_i \in \mathbb{R}$, $y_i \in \mathbb{R}$
- これは、予測タスクを実際に行う際に出てくる未知データと同じ生成分布からの i.i.d. サンプルだと仮定しておく

損失関数の選択

ゴールを定式化するための損失関数を選ぶ

- 損失関数は、回帰の場合の定番である二乗誤差関数としておく

$$\ell(y, y') := (y - y')^2$$

- つまり、予測器の良し悪しは、二乗誤差の期待値というリスクで評価

$$R(f_{\theta}) := \mathbb{E} [\ell(Y, f_{\theta}(X))] = \mathbb{E} [(Y - f_{\theta}(X))^2]$$


- ゴールは、このリスクが小さい予測器を作ること

モデルの選択

手計算できるぐらいの例として、モデルは1次多項式モデルとしておく

- 今回はパラメーターが少ないほうが説明しやすいので、1次多項式モデルとする

$$f_{w,b}(x) = wx + b \quad (w, b \in \mathbb{R})$$



学習の方法

目的関数を定義し，その最小化を通じて間接的にパラメーターを決める

- 学習 = パラメーターの決定は，経験リスク最小化により行うことにする

$$\text{Min}_{(w,b) \in \mathbb{R}^2} \hat{R}(f_{w,b})$$

- 今考えている場合，損失関数は二乗誤差としていたので，目的関数は，訓練標本上の平均二乗誤差（これが今回の経験リスク）

$$L(w, b) = \hat{R}(f_{w,b}) = \frac{1}{n} \sum_{i=1}^n (y_i - f_{w,b}(x_i))^2$$


- **最小二乗法 (ordinary least squares)** = 上記の最小化問題を通じて学習を行う

つまり

$$\text{Min}_{(w,b) \in \mathbb{R}^2} \frac{1}{n} \sum_{i=1}^n (y_i - (wx_i + b))^2 \quad \text{による学習}$$

最小化問題


「目的関数 $L(\theta)$ を, $\theta \in \Theta$ の範囲で, 最小化する」という問題



- ゴールは, **最小化元 (minimizer)** を見つけること
 - 「 $L(\theta)$ が最小になる入力 θ 」のこと. **解 (solution)** と呼ぶ.

最小二乗法（線型単回帰の場合）

この場合の目的関数 $L(w, b)$ のグラフ



この曲面の底にあたる
 $(\hat{w}, \hat{b})$ が最適解

最小二乗法（線型単回帰の場合）

この $L(w, b)$ の最小化元 $(\hat{w}, \hat{b})$ をを見つけるには？

- まずは「微分して0」という **一階の条件**（必要条件）から考える
- 今回の場合（多変数関数の制約なし最適化の場合）の一階の条件は,

$$\nabla L(w, b) = \mathbf{0}$$

- ここで、 $\nabla L(w, b)$ は、**勾配 (gradient)**：偏微分を並べた縦ベクトル

$$\nabla L(\boldsymbol{\theta}) = \begin{pmatrix} \frac{\partial}{\partial \theta_1} L(\boldsymbol{\theta}) \\ \vdots \\ \frac{\partial}{\partial \theta_r} L(\boldsymbol{\theta}) \end{pmatrix}$$

【補足】一階の条件が「勾配 = 0」となるのは、制約なし最適化だからである。制約付き最適化の場合は、代わりにKKT条件（Karush–Kuhn–Tucker conditions）と呼ばれる条件が一階の条件になる。もちろん、制約なし最適化の場合の「勾配 = 0」という条件は、KKT条件の特殊ケースである。

最小化問題を解く（最小化元を見つける）

手元でやってみよう（自宅で）

- 目的関数は何だったか思い出すと、次の通りだった

$$L(w, b) := \frac{1}{n} \sum_{i=1}^n (y_i - (wx_i + b))^2$$

- 一階の条件 $\nabla L(w, b) = \mathbf{0}$ を使うので、まずは勾配を定義から計算しよう

$$\nabla L(w, b) := \begin{pmatrix} \frac{\partial}{\partial w} L(w, b) \\ \frac{\partial}{\partial b} L(w, b) \end{pmatrix} = \begin{pmatrix} ? \\ ? \end{pmatrix}$$

最小化問題を解く（最小化元を見つける）

この場合の最適解は，比較的簡単に求めることができる

- そこから，一階の条件 $\nabla L(w, b) = \mathbf{0}$ を書き下して，次の形に式変形しよう

$$\begin{pmatrix} ? \\ ? \end{pmatrix} \begin{pmatrix} w \\ b \end{pmatrix} = \begin{pmatrix} ? \\ ? \end{pmatrix}$$

- さらに，これを解くことで，解の公式を作ることができる

$$\begin{pmatrix} \hat{w} \\ \hat{b} \end{pmatrix} = \begin{pmatrix} ? \\ ? \end{pmatrix}^{-1} \begin{pmatrix} ? \\ ? \end{pmatrix}$$


- **これが「学習」と呼ばれる過程**

- データを集める → 最適化問題を解いてパラメーターを決定して覚えておく

単回帰タスクの実行


学習をしたあとは、そのパラメーターでのモデルを予測器として使用

- これは学習後の「推論」フェーズとも呼ばれる
 - 新たなデータ x を渡されるたび、学習済みパラメーター $(\hat{w}, \hat{b})$ を使って予測



$$f_{\hat{w}, \hat{b}}(x) = \hat{w}x + \hat{b}$$

ロードマップ



線型モデル

1次関数よりは複雑なモデル

■ 線型モデル


$$f_{\theta}(x) = \langle \theta, \phi(x) \rangle$$

- この ϕ は入力された特徴量 x を変換する**特徴写像**（特徴量変換器）という
- ϕ の設計次第で、それなりに複雑な関数を表せる

線型モデル

線型モデルは、いかほどのものか？

- 多項式関数などは、線型モデルとして表すことができる




- こんなに曲がっているのに線型とはどういうこと？

線型モデル

多項式モデルも線型モデルであるとは？

- 次のように特徴写像を定義すればよい

$$\boldsymbol{\phi}(x) = \begin{bmatrix} 1 \\ x \\ \vdots \\ x^r \end{bmatrix}$$



- そうすると、これを特徴写像として使う線型モデル $f_{\boldsymbol{\theta}}(x) = \langle \boldsymbol{\theta}, \boldsymbol{\phi}(x) \rangle$ は、

$$\langle \boldsymbol{\theta}, \boldsymbol{\phi}(x) \rangle = \theta_0 + \theta_1 x + \theta_2 x^2 + \cdots + \theta_r x^r$$

- なので、確かに r 次の多項式モデルになった！

線型モデルの最小二乗法による学習

回帰タスクのための，線型モデルの最小二乗法による学習

- 線型モデル $f_{\theta}(x) = \langle \theta, \phi(x) \rangle$ の場合の，最小二乗法による回帰タスクの学習


$$\text{Min}_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n (y_i - f_{\theta}(x_i))^2$$

- この最小化問題でも，解の公式を作ることができる
 - とある行列 Φ を用いて，

$$\hat{\theta} = (\Phi^{\top} \Phi)^{-1} \Phi^{\top} y$$

【補足】 Φ は，訓練データの特徴量たち $\{x_i\}$ と ϕ から決まる行列．上の公式は，線型単回帰の場合と全く同じように，一階の条件から求められる．


ロードマップ



過適合

経験リスクは低くても，リスクが高い状態のこと

- 手元のデータでは正しい出力をしながらも，未知のデータには使い物にならない代物が学習されることがある



- 特に，モデルの自由度が高いほど，過適合の余地が大きいので対策が必要

過適合の対策：正則化

基本的には、モデルが単純なものになるような誘導を加える

- 正則化 (regularization)

- 自由度の高いモデルの中でも、結果として「より単純なモデルが学習されるように」仕向けるための工夫
- 色々なものがある

- 実践的には、最初から表現力が低いモデルを使うよりも、

- 経験リスクを小さくできる程度には自由度の高いモデルを使いながら、
- 正則化によって、必要以上に複雑なモデルにならないように工夫する


過適合現象

リスクの最小化というゴールに近づくための手段は数々考えられる

■ 経験リスク最小化 (ERM)

$$\min_{\theta \in \Theta} \hat{R}(f_{\theta})$$

- 自由度が高いモデルをERMで学習させると過適合しがち






L2正則化あり

リスクの最小化というゴールに近づくための手段は数々考えられる

■ L2正則化付き経験リスク最小化 (L2-regularized ERM)

$$\min_{\theta \in \Theta} \hat{R}(f_{\theta}) + \lambda \cdot \|\theta\|^2$$

- 過適合を抑制するためにパラメーターの大きさの罰則項を付けた
- 罰則の強さは、正則化係数 λ で調整



0

λ

ロードマップ

