




モデル選択（ハイパーパラメーター選択）

正則化係数の選び方

L2正則化を使うとき、 λ の値はどのように決めればよいのか？

- 正則化係数 λ の大きさによって、正則化の強さを調整し、過適合を抑制できる



正則化無し 0 $\xrightarrow{\lambda}$ 正則化強

用語＞ハイパーパラメーター (Hyperparameters)


正則化係数の他にも、決めなくてはならないものは色々ある

■ ハイパーパラメーター (hyperparameters)

- モデルの訓練前に選んで固定するパラメーターのこと

■ 例

- モデルの複雑さに関わるもの（多項式モデルの最大次数 r など）
- 正則化に関わるもの（L2正則化の正則化係数 λ など）
- 最適化手法に関わるもの（勾配法の学習率 η など）
- そもそもどのようなモデルを使うか（モデル選択）
- そもそも特徴量として何を含めて何を含めないか（変数選択）



モデル選択（ハイパーパラメーター選択）

ハイパーパラメーター選択は、何らかのモデル選択規準を用いて行う

■ モデル選択規準（model selection criteria）

- モデルが複数あるとき、その中で最良のものを選択するための数値的指標
- 例）取り置き法（holdout method）、交差検証（cross-validation）、エビデンス（evidence）、情報量規準（information criteria）など


■ 共通する考え方（予測タスクの場合）

- 未知データで上手く予測できるモデルを作りたい、という基本に立ち返る

モデル選択規準＞検証データの取り置き法

基本の考え方

- まずはモデルの訓練時に使わない**検証データ（validation data）**を取り分ける




【用語】 検証用データのことを、開発用データ（development data）と呼ぶこともある。


モデル選択規準＞検証データの置き置き法

ハイパーパラメーターを固定 → モデルを学習 → 検証用データで評価

- ハイパーパラメーターを固定し，モデルを学習




- 取り分けておいた検証用データで，性能を評価



モデル選択規準＞検証データの置き置き法

収集した検証評価結果をもとに，ハイパーパラメーターを選択する

- λ を変えながら，これを繰り返して，検証データでの評価結果を記録していく



記録
▶

λ	検証評価値
λ_1	10.5
λ_2	3.8
$\vdots$	$\vdots$

- 検証評価値が最小（最大）だった λ を，最適な λ だと考える
- こうして選んだ λ でのモデルを使う 


モデル選択規準＞置き置き法 (holdout method)

検証データの置き置きは、実際の性能のなるべく良い近似となるように行う

- 無作為分割 (random split) (例) 訓練用:検証用:評価用=8:1:1で置き置き



- 時系列分割 (time-series split) (例) 最新1ヶ月のデータを評価用に、その前の1ヶ月のデータを検証用に置き置き




モデル選択規準＞K分割交差検証法

データが少ない場合の工夫

■ K分割交差検証 (K-fold cross validation)

取り置き法の分割を複数パターン行い，最終的には性能の平均などを用いる


訓練用で学習，検証用で評価



モデル選択規準 > 1つ抜き交差検証法

検証用データサイズを1にして交差検証（つまり n 分割交差検証）

■ 1つ抜き交差検証（Leave-one-out CV, LOOCV）



【補足】 この場合， どの順番で検証用になるかは関係ないので， シャッフルしてもしなくても結果は同じになる。

モデル選択規準＞その他の検証・交差検証法

ケースバイケースで「適切な評価方法」が工夫される

■ 大原則は「最終的な性能の近似としてなるべく良い方法」を検証に使うこと

■ 他の分割方法

- 層化K分割交差検証（stratified K-fold CV）：クラス比率を保つように分割
- Kグループ抜き交差検証（leave-K-groups-out CV）：元々データにある何らかの集団の単位でデータを分割

モデル選択規準 > その他のモデル選択規準

一部のリスク関数や問題設定では、それに特化したモデル選択規準が開発

■ 情報量規準 (information criteria)

- AIC, BIC, WAIC, WBIC, TIC, ……といったものがある
- 基本的に、特定の種類のリスク関数（など）に対して導出される
- 例）AICは、KLダイバージェンスをリスクとする場合のモデル選択規準

■ 情報量規準では、訓練後の訓練損失値を補正して使うという方針が特徴的

- 検証データを取り置く方法との対比で言えば、訓練データ上での性能値を再利用する手法となっている

【用語】 AICは元々、An Information Criterionの略称だったが、後に提案者の赤池先生の名前で呼ばれるようになった（AICという略称は同じ）。

【補足】 情報量規準の中には、ここまで説明した機械学習の枠組みとは異なる目標の定式化に対して開発されているものもある。

モデル選択規準

どのモデル選択規準を使えばよいか？

- 仮定や目的によって異なる
 - それぞれ導出の仮定や妥当性の根拠が異なるので、仮定や目的によって異なる
- 予測タスクの教師付き学習の場合、検証データの置き換え法の汎用性が高い
 - リスク以外の評価指標にも簡単に適用しやすい（補助的な指標の併用など）
- 近年では……
 - データ量が少なければK-fold CVかLOOCVを用い、
 - データ量が多ければ、検証データの置き換え法で済ませてしまうことが多い

【補足】 検証データでの評価値という単純かつ妥当な方法が使えるのは、予測タスクの教師付き学習の場合だからである。他のタスクや学習戦略になると、話はそう単純ではない。

ハイパーパラメータ選択



ここまでで説明した，いずれかのモデル選択規準の値の大小で選べばよい

- 言い換えれば，ハイパーパラメータ選択という最適化問題を解けばよい


$$\underset{\lambda \in \Lambda}{\text{Min Criterion}}(\lambda)$$

- ここで $\text{Criterion}(\lambda)$ はハイパーパラメータ λ を用いて学習～検証を行なって得られるモデル選択規準の値．ここでは，小さいほど良い指標とする．
- $\text{Criterion}(\lambda)$ は，1つの λ に対して値を計算するために1回学習～検証をするので，大きな計算時間と計算費用がかかる傾向にある．

モデル選択 > 検証曲線 (Validation Curve)

ハイパーパラメーターを1つ選ぶだけならば，色々試してプロットすればよい

- **検証曲線**：ハイパーパラメーターの値に対して検証損失値をプロットしたもの




【補足】 もちろん，他のモデル選択規準を用いる場合は，その指標値をプロットして同様のことをすればよい。

モデル選択 > 検証曲線 (Validation Curve)

ハイパーパラメーターを1つ選ぶだけならば、色々試してプロットすればよい

- 実験 (50次多項式モデルによるL2正則化付き最小二乗回帰)
 - ハイパーパラメーター：正則化係数 λ ($\lambda \in \{10^{-5}, 10^{-4.9}, \dots, 10^{0.9}, 10^1\}$ を探索)




検証曲線


モデル選択 > 検証曲線 (Validation Curve)

ハイパーパラメーターを1つ選ぶだけならば、色々試してプロットすればよい

- 検証損失を用いて正則化係数を選択した結果、未知データでよく予測できている



検証曲線




未知データでの評価値
(リスク)

モデル選択＞複数ハイパーパラメーターの最適化

ハイパーパラメーターが複数ある場合、性能は組合せで決まる


- ハイパーパラメーターが複数ある場合、組合せとして最適なものを選びたい



モデル選択 > グリッドサーチ

多数のハイパーパラメーターを，愚直に総当たりで試すのは得策ではない

- グリッドサーチ（grid search）：全ての組み合わせを総当たりする方法
 - 少数なら実行可能だが，例えば5つのハイパーパラメーターを各8水準から探索するなら， $8^5 = 32,768$ 回の学習～評価を繰り返すことになり非現実的




モデル選択 > ランダムサーチ

総当たりできない場合のための様々な方法が研究されている

■ ランダムサーチ (random search)


- 何らかの確率分布でハイパーパラメーターをランダムにサンプリング
- グリッドサーチと比べて満遍なく全体をカバーしている



モデル選択 > ベイズ最適化

総当たりでできない場合のための様々な方法が研究されている


- ベイズ最適化 (Bayesian optimization)
 - モデル選択規準の値を目的関数として、最適化問題を解く方法
 - 計算済みの目的関数値の情報から、当たりをつけながら逐次的に探索する



モデル選択 > ハイパーパラメーター探索の実験

以下の関数を最小にする (λ_1, λ_2) を探索



- 関数 $\text{Criterion}(\lambda_1, \lambda_2)$ (値が小さいほど良い, 赤色で表示)
 - 少ない評価回数で, 効率よくハイパーパラメーター選択をしたい




モデル選択 > 実験結果

ランダムサーチやベイズ最適化を用いることで高効率に


- 手軽なのはランダムサーチ（並列化しやすい）
- 賢く実行する必要がある場合はベイズ最適化



グリッドサーチ：5.9848



ランダムサーチ：2.9773



ベイズ最適化：0.9219