

学習の枠組み（まとめ）

学習の枠組みまとめ



多くの手法に共通する基本概念が出揃ったので、ここで一度まとめておきます

- ここまで、**予測タスクのための教師付き学習**を説明してきた
- その中で、次のようなキーワードが出てきた

予測タスク 教師付き学習

モデル リスク 経験リスク 目的関数 最適化

過適合 正則化 モデル選択

学習の枠組み（まとめ） > ①タスクと学習戦略を設定

タスクを定めて，そのための学習戦略を決める（教師付き学習など）

- **タスク**を定める ←達成させたい仕事の言語化

「〇〇から△△を予測する，という予測タスクを実行したい」


- **学習戦略**を決める ←データの集め方や仮定・事前情報からなる問題設定

「ラベル付きデータを用意し，教師付き学習で学習（データはi.i.d.）」




学習戦略

=



集めるデータ

+




補助情報・事前知識

学習の枠組み（まとめ） > ②モデルと損失関数を選定

予測器の素材となるモデルを選び，良さの指標となるリスクを定義

- モデルを選ぶ ← 予測器の候補とする



- リスク（期待損失）を定義 ← 損失関数を選ぶことで定義される

$$R(f) := \mathbb{E}_{(X,Y) \sim p}[\ell(Y, f(X))]$$

データの生成分布による期待値

損失関数で予測誤差を測る

「二乗損失 $\ell(y, y') := (y - y')^2$ で予測誤差を定義する」

【補足】 損失関数は，一般化して，ラベル付きデータ $Z = (X, Y)$ と関数 f に対して $\ell(Z, f)$ とする場合もある。

学習の枠組み（まとめ） > ③ 目的関数を設計～最適化

目的関数を設計して（経験リスク＋正則化項など），最適化

■ 目的関数を設計 ← 学習結果が望ましいモデルになるようにうまく設計する

- 例 1）経験リスク最小化

$$L(\boldsymbol{\theta}) := \hat{R}(f_{\boldsymbol{\theta}})$$

- 例 2）正則化付き経験リスク最小化

$$L(\boldsymbol{\theta}) := \hat{R}(f_{\boldsymbol{\theta}}) + \lambda \cdot \Omega(\boldsymbol{\theta})$$

$$(\Omega(\boldsymbol{\theta}) = \|\boldsymbol{\theta}\|^2 \text{ など})$$

■ 目的関数の最適化を介してパラメーターを決定 ← この過程が学習


$$\text{Min}_{\boldsymbol{\theta}} L(\boldsymbol{\theta})$$

学習の枠組み（まとめ） > ④モデル選択と評価

正則化係数など、選ばなければならないハイパーパラメーターがあれば選択

■ ハイパーパラメーター選択（モデル選択）を行う ←モデル選択規準を使う

- 検証・交差検証なら，「学習→検証データで評価」をハイパーパラメーターの候補の数だけ繰り返す



- 最終的には，最良なハイパーパラメーターで学習した予測器を使用する

■ 最終性能評価も行う場合は，学習～検証に使わなかった評価用データで評価する

統計的機械学習 (Statistical Machine Learning)

データに潜む規則や構造を抽出するための、主要なアプローチの1つ

- **統計的機械学習**：データに潜む規則や構造を、**統計的な考え方に基づいて抽出**することによって、未知の現象に対する予測や現象の理解を行う技術
- データから規則性を見つけると言ったのはいいものの、はいこれを使ってねとデータを渡されたところで、そこからどう処理して、何の情報をどう抽出すればよいかわからない
- その答えの一つであり、現在至るところで成果が上がっているのが、統計的学習