


リスク最小化と近似ターゲット

基本知識の確認＞同時分布 (Joint Distribution)


多変数の確率分布を**同時分布**という

- 例えば, (X, Y) というペアの同時確率密度

$$p(x, y)$$



同時密度 $p(x, y)$



$p(x, y)$ を真上から見た等高線


【用語】 日英で対応する用語は, 同時確率分布 = simultaneous probability distributionと, 結合確率分布 = joint probability distributionだが, 英語ではjoint probability distribution, 日本語では同時確率分布ということが多い。 【実験ソースコード】 [番号]_preliminary_probability.ipynb

基本知識の確認＞周辺分布（Marginal Distribution）


多変数の一部だけを見た分布を**周辺分布**という

- 例えば、 X を無視して Y だけを見た周辺密度 $p(y)$ は、同時密度から次式で計算

$$p(y) = \int p(x, y) dx$$



同時密度 $p(x, y)$



同時密度 $p(x, y)$

周辺密度 $p(y)$

【補足】 どの変数の周辺分布かが分かるように $p_Y(y)$ と書く場合もある。 【用語】 上で入りきらなかったので略称にしたが、正式には当然、周辺確率分布（marginal probability distribution）という。 【実験ソースコード】 [番号]_preliminary_probability.ipynb

基本知識の確認＞条件付き分布（Conditional Distribution）


一部の変数の値が分かっているときの分布を**条件付き分布**という

- 例えば、 X で条件付けた Y の条件付き密度 $p(y|x)$ は、次式で計算


$$p(y|x) = \frac{p(x, y)}{p(x)}$$

y での積分が1になるように規格化


同時密度の断面の関数
(規格化すると条件付き密度になる)



同時密度 $p(x, y)$



同時密度 $p(x, y)$ のスライス



条件付き密度 $p(y|x)$

【補足】 上式の記法 $p(y|x)$ は見やすいが、分からなくなったら「事象 $X = x_0$ を条件付けた Y の分布が $p(y|x = x_0) = p(x_0, y) \left(\int p(x_0, y') dy' \right)^{-1}$ 」と理解しておけるとよい。

【実験ソースコード】 [番号]_preliminary_probability.ipynb

基本知識の確認 > 条件付き分布 > 基本性質

条件付き密度の便利な式変形

- 同時密度 $p(\mathbf{x}, y)$ から、条件付き密度 $p(y|\mathbf{x})$ へ

- 一部の変数を「条件部に移す」操作ができる

$$\underset{\substack{\text{ } \\ \xrightarrow{\text{ } \\ x \text{ を条件部にしたい}}}{p(\mathbf{x}, y)} = p(y|\mathbf{x}) \overset{\substack{\xrightarrow{\text{ }} \\ \text{周辺分布が外に繰り出された}}}{p(\mathbf{x})}$$

$\nwarrow$
 x が条件部になった

- 条件付き密度 $p(y|\mathbf{x})$ から、同時密度 $p(\mathbf{x}, y)$ へ

- 条件部と同じ周辺分布を掛けると、「条件部から戻す」操作ができる

$$p(y|\mathbf{x}) \cdot p(\mathbf{x}) = p(\mathbf{x}, y)$$

$\uparrow \quad \uparrow$
 $p(\mathbf{x})$ を掛けると条件部から戻せる

$\longleftarrow$ x が条件部から左に戻った

基本知識の確認 > 条件付き期待値 (Conditional Expectation)




条件付き分布による期待値を**条件付き期待値**という

- $X = x$ を所与とした Y の条件付き期待値は, $p(y|x)$ に関する期待値のこと

$$\mathbb{E}[Y|X = x] = \int y \cdot p(y|x) dy$$

- これは x の関数になっている (x ごとに1つの値が決まる)

各点 x ごとの期待値を
プロットしたものが
 $\mathbb{E}[Y|X = x]$




$X = 8$ の条件付き分布

基本知識の確認＞分位点 (Quantile)

全体のうち割合 α がこの値以下である，という点を α -分位点 という

■ Y の分布関数を $F(y) := \mathbb{P}(Y \leq y)$ とすると， Y の α -分位点 (α -quantile) は，

$$F^{\leftarrow}(\alpha) := \inf\{y \in \mathbb{R} \mid F(y) \geq \alpha\}$$



この点より左に
全体の95%が含まれる

【補足】 α -分位点の定義では $\inf$ が使われている。これは分布関数にジャンプがある場合を考慮したものである。正確には，「この点より大きい点であれば，左側に割合 α 以上が含まれる」という最も小さい値として定義されている。 【用語】 α をパーセントで表す場合，percentileという。

【実験ソースコード】 [番号]_preliminary_probability.ipynb

基本知識の確認＞条件付き分位点

条件付き分布における分位点を**条件付き分位点**という




- $X = x$ を所与とした Y の条件付き分布関数を $F(y|x) := \mathbb{P}(Y \leq y|x)$ とすると,
- $X = x$ を所与とした Y の**条件付き α -分位点** (**conditional α -quantile**) は,

$$F^{\leftarrow}(\alpha|x) := \inf\{y \in \mathbb{R} \mid F(y|x) \geq \alpha\}$$

- 例) 条件付き90%分位点

各点 x ごとの α -分位点を
プロットしたものが

$$F^{\leftarrow}(\alpha|x)$$




X = 8 の条件付き分布

基本知識の確認＞分位点と期待値の関係

期待値は，集団から離れた値に引っ張られやすい

$$\mathbb{E}[X] = \int x \cdot p(x) dx$$


(無視できない重み $p(x)$ をもつ)
大きな値が混ざっていると、
全体に大きな影響が残る



基本知識の確認＞分位点と期待値の関係

分位点は，期待値と比べて，離れた値に影響されにくい


- 中央値は期待値よりも外れ値に影響されにくい
 - 要約としては期待値よりも使いやすい場合がある（数個の分位点でもよい）



これまでの考え方

学習は、用意したモデルの中で最良のものを目指して行う

- まずは、予測器の雛形となるモデルを用意する
- そして、そのモデルのパラメーターの中で、リスクがなるべく小さいものを探す



近似ターゲットという考え方

「モデルの中」ではなく，あらゆる関数の中でリスク最小化を考えてみる

■ モデルの外部のことまで考えた話


- モデルの学習の目標は，**近似ターゲット (approximation target)** にできるだけ近い関数を手に入れること

あらゆる予測器

本当に
リスク最小の関数
(近似ターゲット)



A green arrow points from the text to a black dot labeled f^* .



【用語】 近似ターゲットという用語はこの講義内のもの。一般に浸透している用語ではないので注意（ただし分かりやすいと思う）。文脈によっては推定対象（estimand）と呼ぶこともある。【補足】 理論的に取り扱うときは，文字通りあらゆる関数ではなく，適当に滑らかな関数全体を考えるのが普通である。

近似ターゲットと関数近似器としてのモデル



リスク定義をした時点で、最適な予測器は決まっている


- 近似ターゲットは何によって決まるか？
 - リスク関数が定義された時点で決まる
 - つまり、損失関数とデータの生成分布によって決まっている
- この観点からは、**モデルは関数近似器**であるともいえる
 - モデルによって近似ターゲットをできるだけ近似しようとしている
 - （モデルが表現できる中で最も近いものを目指している）

近似ターゲット > 期待二乗誤差の場合

二乗誤差を損失関数とする場合の近似ターゲットは、**条件付き期待値関数**


- 二乗誤差 $\ell(y, y') = (y - y')^2$ の場合、リスク関数は期待二乗誤差

$$R(f) := \mathbb{E}(Y - f(X))^2$$



- この場合の近似ターゲットは、**条件付き期待値関数 (conditional expectation)**

$$f^*(x) := \mathbb{E}[Y|x]$$



近似ターゲットと損失関数の設計



これを逆に、欲しい関数が近似ターゲットにするように損失を設計することも


- ①先に使いたい損失関数／リスクが決まっている（これまで）
 - →何が近似ターゲットかは後から検討する

- ②逆に、近似したい関数が先に決まっている
 - →それが近似ターゲットになるよう損失関数を選ぶ／設計する

分位点回帰

次のようなデータの場合の、回帰タスクを考える


- 例) 主な予測対象の集団と、一部の外れた対象がいる
 - 下の集団を重視して予測器を作りたい



分位点回帰

条件付き期待値では，集団から離れた少数に引っ張られやすい

- 条件付き中央値のほうが，条件付き期待値よりも予測器として妥当な場合がある
 - モデルによって条件付き中央値を近似したい




近似ターゲット > 条件付き分位点

近似ターゲットを条件付き分位点にするために，ピンボール損失を使う

- 損失関数としてピンボール損失（pin-ball loss）を用いるとき，


$$\ell_{\alpha}(y, \hat{y}) := \begin{cases} (1 - \alpha) |y - \hat{y}| & (y - \hat{y} < 0) \\ \alpha |y - \hat{y}| & (y - \hat{y} \geq 0) \end{cases}$$



リスクは $R(f) = \mathbb{E}[\ell_{\alpha}(Y, f(X))]$ であり，

- 近似ターゲットは，条件付き α -分位点（conditional α -quantile）になる

$$f^*(x) = F^{\leftarrow}(\alpha | x)$$



【補足】 ここで $\alpha \in (0,1)$. 【用語】 ピンボール損失という名称は，ピンボールを打った軌道のような見た目から，チェックマークの形状のため，チェック損失ともいう．分位点損失（quantile loss）ともいう． 【参考】 Koenker, R., Bassett, G., Jr., 1978. Regression quantiles. *Econometrica* 46, 33–50.

近似ターゲット > 条件付き中央値

近似ターゲットを条件付き中央値にするためには，絶対誤差を使えばよい



- 絶対誤差（absolute error） $\ell(y, \hat{y}) = |y - \hat{y}|$ の場合，リスク関数は，

$$R(f) := \mathbb{E} |Y - f(X)|$$

- これは， $\alpha = 0.5$ のピンボール損失と等価

- この場合の近似ターゲットは， **条件付き中央値関数（conditional median）**

$$f^*(x) := \inf\{y \in \mathbb{R} \mid \mathbb{P}(Y \leq y \mid x) \geq 0.5\}$$




近似ターゲット > 分位点回帰 > 実験

人工データで分位点回帰の実験

■ L2正則化付き最小絶対誤差回帰 $L(\theta) = \sum_{i=1}^n |y_i - f_{\theta}(x_i)| + \lambda \cdot \|\theta\|^2 \rightarrow \text{Minimize}$

- モデルは20次多項式関数, λ は20個ほどの候補から検証損失値により選択



訓練データ


【実験ソースコード】 [番号]_quantile_regression.ipynb

【補足】最適化の手法の説明は省略するが, 線型計画問題 (linear programming problem) の汎用的な手法を用いて解ける.


近似ターゲット > 分位点回帰 > 実験

人工データで分位点回帰をした実験の結果

- 訓練済みモデルの近似ターゲットが、条件付き中央値になった様子が見てとれる



訓練データと訓練済みモデル



訓練データと訓練済みモデル

条件付き期待値

訓練済みモデル

真の条件付き中央値

リスク最小化と近似ターゲットまとめ



モデルは、最良の予測器に対する、関数近似器とみることも多い

同じ手法の異なる見方

(考えているモデルの中で)
リスクの値ができるだけ小さくなる
ようにパラメーターを調整



(あらゆる予測器の中で)
近似ターゲット
= リスク最小の理想的な予測器
をモデルで近似