

予測系タスク② 分類タスク

分類タスク



ここからは分類タスクと，そのための教師付き学習を説明します

- ここまでは主に回帰タスクを説明してきた
 - ここからは分類タスクのための教師付き学習を説明していく
- 分類タスク
 - 回帰では量的なラベルを予測した（例：3.5, -10.2, ……）
 - 分類では質的なラベルを予測する（例：イヌ, ネコ, ……）
 - 基本的な考え方は同じだが，予測対象が離散的なので少し複雑になる


分類タスク

質的なラベルを予測するタスク（ラベルの値は離散的かつ有限個）

■ 分類タスク（classification task）

- ラベルは $\{1, \dots, K\}$ のどれか1つ（ $1, 2, \dots, K$ の大小関係に特別な意味は無い）
- ラベルは、**クラス（class）** や、**カテゴリー（category）** と呼ぶ

■ 未知データも正しく分類できる**分類器（classifier）** を作りたい




分類タスク＞例

- 手書き文字の読み取り ($\mathcal{X} = \mathbb{R}_{\geq 0}^{20 \times 20}$, $\mathcal{Y} = \{0, 1, 2, \dots\}$)



- メールのスパム判定 ($\mathcal{X} = \text{Vocab}^*$, $\mathcal{Y} = \{\text{spam}, \text{not spam}\}$)



- 翌年の住宅価格が上がるか下がるかを予測 ($\mathcal{X} = \mathbb{R}_{\geq 0}^{12}$, $\mathcal{Y} = \{\uparrow, \downarrow\}$)



- 途中までの文章から次の単語を予測 ($\mathcal{X} = \text{Vocab}^*$, $\mathcal{Y} = \text{Vocab}$)



分類タスク > 用語 > 2クラス分類


2クラス分類の場合，次のように個別の用語がある

■ 2クラス分類，二値分類 (binary classification)

- クラスは $\{-1, +1\}$ とする場合と， $\{0, 1\}$ とする場合がある

■ 用語

- $y = +1$ や $y = 1$ は正ラベル (positive label) といい，
- $y = -1$ や $y = 0$ は負ラベル (negative label) という
- 正ラベル付きのデータ $(\mathbf{x}, +1)$ ， $(\mathbf{x}, 1)$ は正例 (positive example) といい，
- 負ラベル付きのデータ $(\mathbf{x}, -1)$ ， $(\mathbf{x}, 0)$ は負例 (negative example) という



【補足】 特別な用語があることから分かるように，2クラス分類だけでも多くの応用があり，詳しく研究されている。クラスを $\{\pm 1\}$ と $\{0, 1\}$ のどちらにするかは，式が簡単に書けるかどうか 【用語】 3クラス以上の分類タスクは，多クラス分類 (multi-class classification) という。

分類タスク > リスクの定義

分類の場合の予測誤差は、単に当たったか外れたかだけを考えることが多い

- 分類では損失関数として**0/1-損失 (zero-one loss)** $\ell_{0/1}$ を用いることが多い

$$\ell_{0/1}(y, y') := \mathbf{1}\{y \neq y'\} = \begin{cases} 1 & (y \neq y') \\ 0 & (y = y') \end{cases}$$

- この場合のリスクは**誤分類率 (misclassification rate)** となる

$$R(f) = \mathbb{E} [\ell_{0/1}(Y, f(X))] = \mathbb{P}(Y \neq f(X))$$

- このリスクが小さい分類器を得ることを目標と定める

【補足】 $R(f) = \mathbb{E} [\ell_{0/1}(Y, f(X))] = \int (\mathbf{1}\{y \neq f(x)\}) \cdot p(x, y) dx dy = \int_{\{y \neq f(x)\}} p(x, y) dx dy = \mathbb{P}(Y \neq f(X)).$

分類タスクの難しさ > ①非数値的な出力をするモデル



分類器を作るには、数値的ではないものを出力するモデルが必要


- モデルの数値的な出力を、最終出力である予測ラベルに変換する必要がある
- 回帰では量的なラベルを予測した（例：3.5, -10.2, ……）
- 分類では質的なラベルを予測する（例：イヌ, ネコ, ……）

分類タスク＞モデルの考え方

数値的ではないものを出力できるモデル

■ 一つの手段は2段階アプローチ

- モデルから「そのクラスである可能性の高さ」を表す**スコア (score)** を出力
- そのスコアから何らかの**決定規則 (decision rule)** によってラベルを選択



【参考】 Sammut, C., & Webb, G. I. (Eds.). (2017). Encyclopedia of Machine Learning and Data Mining. Springer US. p.210

【用語】 予測ラベルを出す前の内部的な出力値をスコア (score) と呼ぶ。なおスコアという用語は多義的に使われるので注意（一般に点数付けを指す）。決定規則も含めてモデルとみなせるが、スコアリングを行う部分までだけをモデルと呼ぶことも多い。また、逆に分類器全体を決定規則と呼ぶこともある。

【注意】 スコアリングモデル＋決定規則という形ではないモデルもある。


分類タスク > モデルの考え方 > 決定規則

決定規則の例としては、閾値処理関数などがわかりやすい

- 決定規則の例（ラベルを $\{-1, +1\}$ とする2クラス分類の場合）
 - モデルの出力スコアを $z = g_{\theta}(x)$ とするとき、その符号を予測ラベルにする

$$\tau(z) := \begin{cases} +1 & (z \geq 0) \\ -1 & (\text{otherwise}) \end{cases}$$

- この τ を **閾値処理 (thresholding)** 関数という。



分類タスクの難しさ > ②微分が役立たない損失関数




損失関数と予測器の離散的な性質から、最適化にも不都合が出てくる

- 0/1損失の場合の経験リスクは、訓練標本における誤分類率

$$\hat{R}(g) := \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{y_i \neq \tau(g(x_i))\}$$

- しかし、これをそのまま使って目的関数を作ると、実は最適化が困難になる



- 0/1損失でリスク定義をすることは問題ないが、肝心のモデルの学習には不適格

分類タスク > 2つのアプローチ

分類タスクの解き方は、大きく2つに分かれる

- 決定論的分類手法 (deterministic classification)
 - 目的関数の工夫などで最適化の難しさを乗り越える方針
 - リスクが小さいモデルを作ることを直接的に目指す
- 確率論的分類手法 (probabilistic classification)
 - 条件付き分布 $p(y|x)$ をモデルで学習し、そこから予測器を作る方針
 - リスク最小化という目標は同じだが、一旦 $p(y|x)$ の良い近似をサブ目標にする

【用語】 決定論的分類は「『確率論的分類』ではないものの総称」と考えると分かりやすい。


【補足】 正確には、決定論的分類手法の中には、必ずしもリスク関数の最小化を学習の第一目標としていないものもあるが、この講義ではあくまでリスクが小さい予測器を作ることをゴールとして扱う。決定論的と呼ばれる手法であっても、データの分布などを考えているものは、本来の意味では確率論的ともいえる。

決定論的分類アプローチ




この講義では、決定論的分類アプローチの説明は割愛

- 決定論的アプローチでは、直接的に $R(f)$ が小さいモデルを目指す
- 雰囲気だけ説明しておくとして、最適化が難しい0/1損失の経験リスクの代わりに、最適化しやすくてかつ $R(f)$ が下がる方向に働く代理損失を使うなどする



リスク定義の損失関数
(0/1-損失)



学習用の代理損失

- サポートベクトルマシン (support vector machines, SVM) などはこの系譜.

分類タスクの解き方の分類＞確率論的分類手法


確率論的分類手法では $p(y|x)$ を一旦推定する. というのも……

- リスク関数として誤分類率 (misclassification rate) を使うとき,

$$R(f) := \mathbb{E}[\mathbf{1}\{Y \neq f(X)\}]$$

- 近似ターゲットは, 「 $p(y|x)$ が最も大きいクラスを出力する」 予測器

$$f^*(x) = \arg \max_{k \in \{1, \dots, K\}} p(y = k | x)$$



- 最大事後確率分類器 (maximum a-posteriori probability classifier) という
- ベイズ分類器 (Bayes classifier) ともいう

- つまり, 最良の予測器 f^* は $p(y|x)$ を用いて表せることが分かっている

【用語】 ベイズ分類器という用語は, ベイズ統計とは無関係に使われている.

【補足】 複数のクラスが同時に確率最大の場合 (1位タイ) は, それらのいずれかを任意に選ぶことによりタイブレイクすることによっておけばよい.

分類タスク > 費用感応的な損失

0/1損失の代わりに，費用感応的な損失を使いたい場合もある

- 費用感応的な損失（cost-sensitive loss）

$$\ell_c(y, \hat{y}) := c_{y, \hat{y}}$$

- どのクラスをどのクラスと取り違えたかによって損失が異なる

		$\hat{y}$		
		Class 1	Class 2	Class 3
y	Class 1	0	0.8	1
	Class 2	5	0	3
	Class 3	0.6	0.2	0

近似ターゲット > 費用感応的な損失


近似ターゲットは，条件付き期待コスト最小のクラスを返す予測器になる

- 費用感応的な損失 $\ell_c(y, \hat{y}) := c_{y, \hat{y}}$ の場合のリスクは

$$R(f) := \mathbb{E}[\ell_c(Y, f(X))]$$

- この場合の近似ターゲットは，「条件付きリスク最小のクラスを返す」予測器

$$f^*(x) = \arg \min_{k \in \{1, \dots, K\}} \sum_{j=1}^K c_{j,k} p(y = j | x)$$



条件付きリスク

$$\mathbb{E}[c_{Y,k} | x] := \sum_{j=1}^K c_{j,k} p(y = j | x)$$

- この場合も，最良の予測器 f^* は $p(y|x)$ を用いて表せる

【用語】 これもベイズ分類器 (Bayes classifier) という。条件付きリスク (conditional risk) とは $\mathbb{E}[c_{Y,k} | x]$ のこと。

分類タスクの解き方の分類＞確率論的分類手法

近似ターゲットの見地から、確率論的分類手法では $p(y|x)$ を一旦推定する

■ 分類タスクでの最良の関数

- 0/1損失でのリスク（誤分類率） $\rightarrow f^*(x) = \arg \max_{1 \leq k \leq K} p(y = k|x)$
- 費用感応的な損失でのリスク $\rightarrow f^*(x) = \arg \min_{1 \leq k \leq K} \sum_{j=1}^K c_{j,k} p(y = j|x)$

■ どちらも、まず $p(y|x)$ をモデルで近似しておけば、そこから簡単に作れる

- 確率論的分類では $p(y|x)$ を **クラス事後確率（class posterior）** と呼ぶ
- どうすればクラス事後確率をモデルで近似できるか？
 $\rightarrow$ **近似ターゲットが $p(y|x)$ になるような（都合のよい）損失関数を使う**

分類タスク > 概要のまとめ



分類タスクではラベルが離散的なため、モデルにも最適化にも工夫が必要になる

- 分類タスクの特有の用語がある
- モデルは、スコアリング + 決定規則という形のものが多い
- 決定論的・確率論的という2つのアプローチがある
 - 決定論的アプローチでは、目的関数の工夫などで $R(f)$ が小さいモデルを目指す
 - 確率論的アプローチでは、一旦 $p(y|x)$ の良い近似を目指す
 - ▶ 回り道ともいえるが、多クラス分類にも自然に対応できることなどのメリットから、近年はこちらが多い

ロードマップ

