

リスク最小化と近似ターゲットの証明

近似ターゲットの証明アウトライン



ここまでに出てきた最適性の証明のあらすじを掲載しておく

- (注意) これは証明のアウトラインであり，厳密な証明ではない
- (参考) 厳密な証明にするために，少なくとも必要な修正
 - 特徴量空間・ラベル空間がどのようなものか定義
 - 「あらゆる関数」ではなく可測性などを満たす関数で考える
 - 結論は「確率 1 で等しい」などの形で書き直す

基本知識の確認＞条件付き期待値の性質

$\mathbb{E}[Y|x]$ と $\mathbb{E}[Y|X]$ という2つの異なる記号が出てくることがある

- $\mathbb{E}[Y|x]$ は $p(y|x)$ による条件付き期待値
 - これは、 x を決めるごとに値が決まるので、 $f(x) := \mathbb{E}[Y|X = x]$ という関数
- $\mathbb{E}[Y|X]$ は、関数 $\mathbb{E}[Y|x]$ に X を代入したもの（ X に由来して確率変数になる）
 - つまり $f(X)$ という新たな確率変数

基本知識の確認＞条件付き期待値の性質

条件付き期待値の条件部について，重ねて期待値をとるとどうなるか

■ 繰り返し期待値の公式 (law of iterated expectations)

$$\mathbb{E}[Y] = \mathbb{E}[\mathbb{E}[Y|X]]$$

■ 詳しく書くなら，

$$\underbrace{\int y \cdot p(x, y) dx dy}_{\mathbb{E}[Y]} = \int \left(\int y \cdot p(y|x) dy \right) p(x) dx = \int \underbrace{(\mathbb{E}[Y|X=x]) \cdot p(x) dx}_{\mathbb{E}[\mathbb{E}[Y|X]]}$$

【用語】 これには複数の呼び名があり，タワー性質 (tower property) や全期待値則 (law of total expectation) ともよばれる。

【補足】 ここで， $p(y|x)p(x) = p(x, y)$ を使った。

近似ターゲット > 期待二乗誤差の場合 > 証明

期待二乗誤差は、条件付き期待値関数によって最小化される

- 一般の多次元の場合 ($\mathcal{Y} = \mathbb{R}^d$) で示す. $f^*(x) := \mathbb{E}[Y|x]$ とする.

$$\begin{aligned}\mathbb{E}\|Y - f(X)\|^2 &= \mathbb{E}\|Y - f^*(X) + f^*(X) - f(X)\|^2 \xrightarrow{\|a+b\|^2 = \|a\|^2 + \|b\|^2 + 2\langle a, b \rangle} \\ &= \mathbb{E}\|Y - f^*(X)\|^2 + \mathbb{E}\|f^*(X) - f(X)\|^2 + 2\mathbb{E}\langle Y - f^*(X), f^*(X) - f(X) \rangle\end{aligned}$$

- ここで, $\mathbb{E}\langle Y - f^*(X), f^*(X) - f(X) \rangle = \mathbb{E}_X[\mathbb{E}[\langle Y - f^*(X), f^*(X) - f(X) \rangle | X]]$ であり,

$$\begin{aligned}\mathbb{E}[\langle Y - f^*(x), f^*(x) - f(x) \rangle | x] &= \langle \mathbb{E}[Y|x] - f^*(x), f^*(x) - f(x) \rangle \quad (\because \text{線型性}) \\ &= \langle \mathbf{0}, f^*(x) - f(x) \rangle = 0\end{aligned}$$

- よって, $\mathbb{E}\|Y - f(X)\|^2 = (\text{const.}) + \mathbb{E}\|f^*(X) - f(X)\|^2$ であり, 最小化は $f = f^*$ と等価

【補足】 上記は証明のあらすじ. 数学的に厳密に示すには, $L^2(p_X)$ 空間などで証明する. また, 結論部の正確な主張は $f = f^*$ (a.s.- p_X) である. 非負可測関数 f について, $\mathbb{E}[f(X)] = 0 \Leftrightarrow f(x) = 0$ (a.s.- x) (Çinlar, 2011, Proposition 4.13など).

近似ターゲット > 誤識別率の場合 > 証明

誤識別率を最小化するのは、最大条件付き確率則という予測器

- $f^*(x) := \arg \max_{k \in \{1, \dots, K\}} \mathbb{P}(Y = k | x)$ と定義していた。このとき、以下が成立。

$$R(f) = \mathbb{E}[\mathbf{1}\{Y \neq f(X)\}] = \mathbb{E}_X[1 - \mathbb{E}[\mathbf{1}\{Y = f(X)\} | X]] = \mathbb{E}_X[1 - \mathbb{P}(Y = f(X) | X)]$$

$$R(f^*) = \mathbb{E}[\mathbf{1}\{Y \neq f^*(X)\}] = \mathbb{E}_X[1 - \mathbb{E}[\mathbf{1}\{Y = f^*(X)\} | X]] = \mathbb{E}_X[1 - \max_k \mathbb{P}(Y = k | X)]$$

- 辺々引き算して、 $R(f) - R(f^*) = \mathbb{E}_X[\max_k \mathbb{P}(Y = k | X) - \mathbb{P}(Y = f(X) | X)]$ を得る。
- いま、 $\max_k \mathbb{P}(Y = k | X) - \mathbb{P}(Y = f(X) | X) \geq 0$ より、 $R(f) - R(f^*)$ の最小値は 0 で、
最小化の達成条件は $\max_k \mathbb{P}(Y = k | \cdot) - \mathbb{P}(Y = f(\cdot) | \cdot) = 0$ と等価。
さらにこれは、 $f = f^*$ と等価（仮に $f \neq f^*$ なら $R(f) - R(f^*)$ が正の値になる）。

【注意】 上記は証明のあらすじ。正確には結論は $f = f^*$ (a.s.- p_X) になる。複数のクラスが同時に最大確率となる場合は、例えばクラス番号が最も小さいものを予測値とするなど、タイブレイクのルールを任意に決めておく。 【補足】 非負可測関数 f について、 $\mathbb{E}[f(X)] = 0 \Leftrightarrow f(x) = 0$ (a.s.- x) (Çinlar, 2011, Proposition 4.13など)

近似ターゲット > 交差エントロピーの場合 > 証明

交差エントロピーを最小化するのは、条件付き確率。

- 交差エントロピーとKLダイバージェンスは最小化において等価なのでKLで議論。

$$H(p, q) = \text{KL}(p \| q) + (\text{constant})$$

- KLダイバージェンスに対して、Jensenの不等式を用いる。

$$\begin{aligned} \text{KL}(p \| q) &= \int p(x, y) \log \frac{q(y | x)p(x)}{p(y | x)p(x)} dx dy \\ &\geq \log \left(\int p(x, y) \frac{q(y | x)p(x)}{p(y | x)p(x)} dx dy \right) \\ &= 0 \end{aligned}$$

- 等号成立は $q(y | x) = p(y | x)$ のとき、またそのときのみ。

【注意】 上記は証明のあらすじ。正確には結論は $q(y | x) = p(y | x)$ ($p(x, y)$ -a.s.) になる。

近似ターゲット > 分位点回帰 > 証明

ピンボール損失でのリスクは，条件付き分位点関数によって最小化される

■ 定義：

- 損失関数は $\ell_\alpha(y, y') := (1 - \alpha)|y - y'| \mathbf{1}\{y - y' < 0\} + \alpha|y - y'| \mathbf{1}\{y - y' \geq 0\}$
- また， $F(y|x) := \mathbb{P}(Y \leq y|x)$ ， $F^\leftarrow(\alpha|x) := \inf\{y \in \mathbb{R} : F(y|x) \geq \alpha\}$ と定義.

■ 仮定： $\forall x$ で $F(\cdot|x)$ は狭義単調増加かつ連続と仮定し，その場合でのみ示す.

■ 条件付きリスク $R(b|x) := \mathbb{E}[\ell_\alpha(Y, b)|x]$ に着目する.

■ まず，定義から $R(b|x) = \int_{-\infty}^b (\alpha - 1)(y - b)p(y|x)dy + \int_b^{\infty} \alpha(y - b)p(y|x)dy$ であり，

右辺を b で愚直に微分して整理すると ① $\frac{\partial}{\partial b} R(b|x) = F(b|x) - \alpha$ を得る.

【補足】 $\ell_\alpha(y, y')$ は $y' = y$ において微分不能だが，それを積分した $\mathbb{E}[\ell_\alpha(Y, b)|x]$ であれば微分可能ということ．また，条件付き密度 $p(y|x)$ の存在なども仮定している．

近似ターゲット > 分位点回帰 > 証明

ピンボール損失でのリスクは，条件付き分位点関数によって最小化される

■ 単調性の仮定から $F(b|x) - \alpha$ は狭義単調増加なので，①より $R(b|x)$ は狭義凸。

■ ①と単調性の仮定から， $\frac{\partial}{\partial b} R(b|x) = 0 \iff F(b|x) = \alpha \iff b = F^{\leftarrow}(\alpha|x)$ 。

■ よって $R(b|x)$ は可微分な狭義凸関数で，(微分) = 0 は $b = F^{\leftarrow}(\alpha|x)$ のとき。

よって $\arg \min_{b \in \mathbb{R}} R(b|x) = F^{\leftarrow}(\alpha|x)$ である。特に，狭義凸より最小化元は1点のみであり，任意の $b \neq F^{\leftarrow}(\alpha|x)$ に対して， $R(b|x) > R(F^{\leftarrow}(\alpha|x)|x)$ となる。

■ よって， $R(f) = \mathbb{E}_X [R(f(X)|X)]$ の最小化元は， $f^* = F^{\leftarrow}(\alpha|\cdot)$ に限られる。

【注意】 上記は証明のあらすじ。条件付き密度の存在を仮定したので，上で仮定を追加するまでもなく $F(\cdot|x)$ は可微分，特に連続である。

【補足】 結論部は $f^*(\cdot) = F^{\leftarrow}(\alpha|\cdot)$ (a.s.- X) . $\mathbb{E}_X [\mathbb{E}[\ell_\alpha(Y, f(X))|X]] = \mathbb{E}_X [\mathbb{E}[\ell_\alpha(Y, f^*(X))|X]]$ ならば $\mathbb{E}[\ell_\alpha(Y, f(x))|x] - \mathbb{E}[\ell_\alpha(Y, f^*(x))|x]$ が非負可測関数であることと，非負可測関数 f について， $\mathbb{E}[f(X)] = 0 \iff f(x) = 0$ (a.s.- x) (Çınlar, 2011, Proposition 4.13など)であることから結論が従う。