

分類タスクへの確率論的アプローチ

確率論的分類アプローチ



ここから「確率的分類アプローチ」を説明

- ここで出てくる重要な考え方：条件付き確率の推定

確率論的分類

誤分類率リスクが小さい分類器を作りたい

- どうやって誤分類率リスクが小さいモデルを作るか？

$$R(f) = \mathbb{E} [\ell_{0/1}(Y, f(X))] = \mathbb{P}(Y \neq f(X))$$

- 0/1損失が入っている最適化は微分が役に立たないので難しい
- ヒント：最適な分類器（近似ターゲット）の形は分かっていた

$$f^*(\mathbf{x}) = \arg \max_{1 \leq k \leq K} p(y = k | \mathbf{x})$$

ここに着目する



確率論的分類

最適な分類器 $f^*(\mathbf{x})$ が、クラス事後確率 $p(y|\mathbf{x})$ を使って表せることに着目

- 最適な分類器は次の形なので、

$$f^*(\mathbf{x}) = \arg \max_{1 \leq k \leq K} p(y = k | \mathbf{x})$$

- モデル $p_\theta(y|\mathbf{x})$ を学習し、決定規則 $\tau(\mathbf{p}) = \arg \max_{1 \leq k \leq K} p_k$ で予測する方針をとる

$$f_\theta(\mathbf{x}) = \arg \max_{1 \leq k \leq K} p_\theta(y = k | \mathbf{x})$$

- どうやって条件付き分布のモデル $p_\theta(y|\mathbf{x})$ を作り、 $p(y|\mathbf{x})$ を近似させるか？

確率論的分類＞識別的アプローチ

条件付き分布のモデル $p_{\theta}(y|\mathbf{x})$ を作り, $p_{\theta}(y|\mathbf{x}) \simeq p(y|\mathbf{x})$ となるように学習する

- クラス事後確率 $p(y|\mathbf{x})$ を近似するための方針

1. 条件付き確率の**モデル** $p_{\theta}(y|\mathbf{x})$ を用意
2. **近似ターゲットが $p(y|\mathbf{x})$ になるリスク関数**を選定
3. そのリスクの最小化を目指すための目的関数を設計して, 学習を実行


- これは特に, 識別的モデル (discriminative model) アプローチという

- 本節の最後に説明するが, これと対をなす「生成的モデルアプローチ」もある

確率論的分類 > モデル > 要件

確率論的分類には、確率としての要件を満たす値を出力するモデルが必要

- モデルは、 x を受け取って、 $1 \sim K$ の各クラスの確率を出力



- 出力値の要件：**確率値ベクトル (probability/stochastic vector)** であること
 - 各成分は0以上 ($p_k \geq 0$) かつ総和が1である ($\sum_k p_k = 1$) ベクトル p

$$p = \begin{bmatrix} 0 \\ 0.2 \\ 0.7 \\ 0.1 \end{bmatrix}$$

0以上, かつ, 足して1


【用語】「確率ベクトル」は確率変数ベクトルを指す用語として使われる場合があるため、この講義では確率値ベクトルと呼び分けることにする。

【用語】 K 個の成分からなる確率値ベクトルを、 K クラスの確率値ベクトル、あるいは K 次元の確率値ベクトルと呼ぶことにする。ただし、これは数学的には $K-1$ 次元の確率単体の元である。

確率論的分類 > モデル > 要件

確率論的分類には、確率としての要件を満たす値を出力するモデルが必要

- 2クラスの場合、モデルは1つの確率値を出力するだけで十分



- 出力値の要件：確率値 (probability) であること
 - 0以上1以下の実数 p

$$p = 0.8$$

もう一方のクラスは0.2となる

【補足】 2次元の確率値ベクトルを出力させてもよいのだが、単に1つの確率値を出力するだけでも事足りるため、2クラスの確率論的分類では、通常は、ラベルは $\{0, 1\}$ で扱う。クラス0の事後確率を近似させることにしてもよいが、特に言及がなければ、慣習的にクラス1の事後確率の近似を前提することが多い。

確率論的分類＞モデル＞要件



実際にこれらを満たせるモデルの作り方と最適化の方法は次回以降に解説

- 今回のモデルの説明は、どんなモデルが必要か、という要件の話まで

$$g_{\theta}(x) = 0.125$$

$$g_{\theta}(x) = \begin{bmatrix} 0.3 \\ 0.1 \\ 0.6 \\ 0 \end{bmatrix}$$

確率論的分類＞確率値を近似するための学習方法



確率値を出すモデルは作れたとして、どうやって $p_{\theta}(y|x)$ を学習させるのか？

- リスク関数と近似ターゲットの考え方を活用する！
- リスク関数をうまく選ぶと、その近似ターゲットがクラス事後確率になる
 - そのリスク関数の最小化を目指して学習すれば、結果としてモデルはクラス事後確率の近似を目指していることになる

近似ターゲット > 交差エントロピーの場合

リスクが交差エントロピーのとき、**近似ターゲットはクラス事後確率**


■ 交差エントロピー (cross entropy)

$$R(q) := \mathbb{E}_p[-\log q(Y|X)]$$

- $\ell((x, y), q) = -\log q(y|x)$ は、**交差エントロピー損失 (cross-entropy loss)**

■ この場合の近似ターゲットは、**クラス事後確率 (class-posterior)** になる

$$q^*(y|x) = p(y|x)$$



【注意】ここでの近似ターゲットは、あらゆる関数全体で考えているのではなく、「あらゆる条件付き確率 $q(y|x)$ の全体」の中で考えていることに注意。

【補足】ここで、損失関数は「 $f(x)$ と y の誤差を測る関数」から一般化して、データ点 (x, y) と関数 q に対して値を返す関数 $\ell((x, y), q)$ であればよいものとした。

【補足】近似ターゲットが条件付き確率になるようなリスクは他にもある。【用語】交差エントロピー損失は、対数損失 (log loss) と呼ぶこともある。

【用語】一部では、交差エントロピー損失という名前で、後述のロジスティック関数やソフトマックス関数を合成した負の対数尤度を指す場合がある。

交差エントロピー＞用語

交差エントロピーの経験リスク最小化は、最尤法と呼ばれる

■ 交差エントロピーの経験リスク

$$\frac{1}{n} \sum_{i=1}^n (-\log p_{\theta}(y_i | x_i))$$

- $-\log p_{\theta}(y | x)$ を、データ (x, y) の **負の対数尤度** (negative log likelihood) という
- この場合の経験リスク最小化は **最尤法** (maximum likelihood) という

■ この負の対数尤度をもとにして、学習の目的関数を作る (最尤法ベースの学習)

交差エントロピー > 性質

交差エントロピーは、KLダイバージェンスという量に関係

■ KLダイバージェンス (Kullback-Leibler divergence)

$$\text{KL}(p\|q) := \int p(x, y) \log \left(\frac{p(x, y)}{q(x, y)} \right) dx dy$$

■ KLダイバージェンスの最小化は交差エントロピーの最小化と等価

$$\text{KL}(p\|q) = \underbrace{\mathbb{E}_p[-\log q(Y|X)]}_{\text{cross-entropy}} + \underbrace{\mathbb{E}_p[\log p(Y|X)]}_{\text{constant}}$$

定数なので最適化では無関係

【補足】 条件付き確率 $p(y|x)$ のみをモデル化している場合、特に断らない限り、同時密度のモデルとしては真の入力分布 $p(x)$ と組み合わせた $q(x, y) = q(y|x)p(x)$ を用いることにする。 【用語】 日本語では「カルバック・ライブラー・ダイバージェンス」と表記することが多い。また、幅広い分野で使われる量のため、相対エントロピー (relative entropy)、KL情報量などの別名も多い。

KLダイバージェンス

確率分布間の差異を計るための定量的な尺度として多用される

■ p から q へのKLダイバージェンス


$$\text{KL}(p\|q) := \int p(x, y) \log \left(\frac{p(x, y)}{q(x, y)} \right) dx dy$$

- 性質① 向きがある量 (p から見て q がどれだけ離れているかを表す)

$$\text{KL}(p\|q) \neq \text{KL}(q\|p)$$

- 性質② 値は0以上で、かつ、値が0になるのは $p = q$ のときに限る

$$\text{KL}(p\|q) \geq 0 \quad \text{かつ} \quad \text{KL}(p\|q) = 0 \Leftrightarrow p = q$$




【注意】 上の性質からわかるように、これは数学的には距離の公理を満たさない。 【補足】 上記の等号成立条件は、正確には p -a.s. での成立。

KLダイバージェンス以外の選択肢



なぜKLダイバージェンス（から派生した交差エントロピー）で学習するのか？

- KLダイバージェンスの他にも分布間の相違度指標は色々ある.
 - 逆KLダイバージェンス（reverse KL divergence） $KL(p||q) \leftrightarrow KL(q||p)$
 - α -ダイバージェンス， β -ダイバージェンス， γ -ダイバージェンス
 - ヘリンジャー距離（Hellinger distance）
 - ワッシャースタイン距離（Wasserstein distance） ， ……
- どれを使うのが良いか？結局はケースバイケース.



【補足】 KLダイバージェンスは情報理論など至るところに現れる「由緒正しい」分布間相違度なので好まれて使われるが、相違度指標には一つ一つ特性があり、当然ながら、KLダイバージェンスにもそれなりの「クセ」がある。

確率論的分類アプローチ > まとめ



分類タスクへの確率論的なモデルによるアプローチを解説

■ 「確率的分類アプローチ」を説明

- 誤分類率を最小にする分類器は、クラス事後確率 $p(y|\mathbf{x})$ を使って表される
- そこで、手持ちのデータからクラス事後確率 $p(y|\mathbf{x})$ を推定することにした
- クラス事後確率の推定は、交差エントロピーをリスクとする学習で行う
 - ▶ これは、最尤法ベースの学習という
 - ▶ 最尤法ベースの学習で $p(y|\mathbf{x})$ を近似できるのは、KLダイバージェンス由来

確率論的分類＞補足



$p(y|x)$ の推定をする確率論的分類において、大きく2種類のアプローチがある

	モデリングの対象	考え方の違い
識別的モデルアプローチ	条件付き分布 $p_{\theta}(y x)$	直接的に分類に使う部分だけを学習する
生成的モデルアプローチ	同時分布 $p_{\theta}(x, y)$	データの生成規則の全体を学習する

■ どちらが良いかはケースバイケース

- 現在はまず識別的アプローチを考えることが多いと思われる
- そのため、この講義では分類タスクへの生成的モデルアプローチは割愛

【注意】 生成的モデルといっても、生成タスクのために使えるとは限らない。「生成タスクのための」生成モデルとは関連はあれど異なるものと考えたほうがよい。

確率論的分類＞補足＞生成的モデリング

この講義では説明しないが、次のような方針で $p_{\theta}(y|\mathbf{x})$ を学習する方法もある

■ 生成的モデル (generative model) アプローチ

1. まず、同時確率のモデル $p_{\theta}(\mathbf{x}, y)$ を準備する
 - ▶ $(p_{\theta}(\mathbf{x}, y) = p_{\theta}(\mathbf{x}|y) \cdot p_{\theta}(y))$ のように分けてモデル化することも多い)
2. これを、何らかの方法で $p_{\theta}(\mathbf{x}, y) \simeq p(\mathbf{x}, y)$ となるように学習する
 - ▶ $(p_{\theta}(\mathbf{x}|y) \simeq p(\mathbf{x}|y) \text{ と } p_{\theta}(y) \simeq p(y))$ のように分けて学習することも多い)
3. クラス事後確率は、 $p_{\theta}(\mathbf{x}, y)$ から、
$$p_{\theta}(y|\mathbf{x}) = \frac{p_{\theta}(\mathbf{x}, y)}{\int p_{\theta}(\mathbf{x}, y) dy}$$
 として計算

【用語】 生成的という修辭の由来はおおよそ次のとおり。 $p(\mathbf{x}|y)$ はクラスごとの特徴量の生成分布であり、例えば「3という数字に対する手書き文字の画像が従う生成分布」などが相当する。これをモデル化して推定することは、分類という目的のために、一旦「データの生成規則を丸ごと学習する」ようなものである。