

2クラスの確率論的分類

2クラスの確率論的分類（確率論的二値分類）



確率論的分類を，まず2クラス分類の場合から説明

- 誤分類率 $R(f) = \mathbb{E} [\ell_{0/1}(Y, f(X))] = \mathbb{P}(Y \neq f(X))$ に対して最適な予測器の形は，

$$f^*(\mathbf{x}) = \arg \max_{1 \leq k \leq K} p(y = k | \mathbf{x})$$

- そこで，モデルで $p(y | \mathbf{x})$ を近似するよう学習し，その値が最大なクラスを出力


$$f_{\theta}(\mathbf{x}) = \arg \max_{1 \leq k \leq K} p_{\theta}(y = k | \mathbf{x})$$

- 2クラスの場合は，もう少し単純になる

確率論的二値分類 > モデル

確率論的二値分類では、モデルがいくらか単純になる

- 前提として通常、確率論的二値分類では、ラベルは $\{0, 1\}$ とする.
- モデルは単純になる： $p(y = 1 | \mathbf{x})$ だけ近似すればよい



$$\begin{bmatrix} p(y = 1 | \mathbf{x}) \\ p(y = 0 | \mathbf{x}) \end{bmatrix} \rightarrow p(y = 1 | \mathbf{x})$$

- 決定規則も単純になる：最大事後確率則は、0.5での閾値処理で表せる

$$\tau(\mathbf{p}) = \arg \max_{1 \leq k \leq K} p_k \rightarrow \tau(p) = \begin{cases} 1 & (p \geq 0.5) \\ 0 & (p < 0.5) \end{cases}$$

確率論的二値分類 > 分布近似のためのリスク関数

確率論的二値分類では、交差エントロピー損失も、特有の表式がある

- ラベルが $\{0,1\}$ で、モデルが $g(x) := q(y = 1 | x)$ なら、交差エントロピー損失は、

$$\ell((x, y), g) = -\log q(y | x) = -y \cdot \log g(x) - (1 - y) \cdot \log(1 - g(x))$$

となり、リスク関数は二値交差エントロピー（binary cross entropy）となる。

$$R(g) := \mathbb{E}[-Y \log g(X) - (1 - Y) \log(1 - g(X))]$$


- 単に、交差エントロピーを、2クラスの場合の記号のもとで表しただけのこと
 - このリスク関数での近似ターゲットは、もちろん $g^*(x) = p(y = 1 | x)$ である

【注意】ここでの近似ターゲットは、あらゆる関数ではなく、「出力が確率値であるような、あらゆる関数」の中での最小化元である。

確率論的二値分類＞確率値を出力するモデルの作り方

出力が確率値になるモデル $g_{\theta}(x)$ を用意する必要がある

- 線型モデルなどは、 $[0,1]$ の範囲外の実数も出力してしまう
 - そのままでは確率のモデルとして不適格
- 対策：出力が $[0,1]$ の範囲に収まるように、出力値の変換を行う関数を合成




確率論的二値分類＞確率値を出力するモデルの作り方

出力値を[0,1]の範囲に収めたい場合，次のような変換を用いる

ロジスティック関数（シグモイド関数）


$$\sigma(z) = \frac{1}{1 + e^{-z}}$$



- 非常によく使われる

標準正規分布の累積分布関数

$$\Phi(z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^z e^{-\frac{t^2}{2}} dt$$



- 機械学習では頻繁には使われない


【用語】一般化線型モデルなどの文脈では，これらの関数は逆リンク関数（inverse link function）や平均関数（mean function）と呼ばれることがある．機械学習でシグモイド関数といえば，通常は左の（標準）ロジスティック関数を指す．広義にはシグモイドはS字カーブの形状（ギリシャ文字シグマの語末形ςの形状）を持つ関数全般を指す（右の累積分布関数も含む）．

確率論的二値分類＞モデル＞ロジスティック関数

モデルの中間的な出力に，ロジスティック関数を合成して確率値のモデル化

- 確率値を出力するモデル

$$g_{\theta}(x) = \sigma(s_{\theta}(x)) = \frac{1}{1 + e^{-s_{\theta}(x)}}$$




確率論的二値分類>モデル>例


0から1までの出力に収めながらも自由なモデルを作ることが可能

■ ロジスティック関数による確率モデルの例


$$g(\mathbf{x}) = \sigma(1 + x_1 + x_2)$$



$$g(\mathbf{x}) = \sigma(1 + 0.1x_1^2 + 0.1x_2^2)$$



$$g(\mathbf{x}) = \sigma(1 + x_1^3 + 0.5x_2^3 + 0.2x_1x_2)$$



確率論的二値分類 > 学習法 > 正則化付き最尤法

例えばロジスティック関数によるモデルを，L2正則化付きの最尤法で学習

- ロジスティック関数による確率モデル

$$g_{\theta}(x) = \sigma(s_{\theta}(x))$$

- リスク関数として，二値交差エントロピーが小さいモデルを目指す

$$R(g_{\theta}) := \mathbb{E}[-Y \log g_{\theta}(X) - (1 - Y) \log(1 - g_{\theta}(X))]$$

- そのために，目的関数を経験リスク + L2正則化項で定義し，これを最小化

$$L(\theta) := \frac{1}{n} \sum_{i=1}^n [-y_i \cdot \log g_{\theta}(x_i) - (1 - y_i) \cdot \log(1 - g_{\theta}(x_i))] + \lambda \|\theta\|^2$$

- L2正則化付き最尤法 (L2-regularized maximum likelihood estimation)

確率論的二値分類 > 最適化 > 微分



「微分して0とおく」方法を試すために勾配を計算する

- 線型モデルの最小二乗回帰では、一階の条件から一意な最適解を見つけられた。
- 今の場合で同じことができるか、試してみよう。
 - 損失関数は次式だった

$$\ell((\mathbf{x}, y), g_{\theta}) := -y \log g_{\theta}(\mathbf{x}) - (1 - y) \log(1 - g_{\theta}(\mathbf{x}))$$

- 目的関数は次式だった

$$L(\boldsymbol{\theta}) := \frac{1}{n} \sum_{i=1}^n \ell((\mathbf{x}_i, y_i), g_{\theta}) + \lambda \|\boldsymbol{\theta}\|^2$$

確率論的二値分類 > 最適化 > 微分

ロジスティック関数による確率モデルでの、交差エントロピー損失の微分

■ 状況設定

- モデル $g_{\theta}(\mathbf{x}) = \sigma(s_{\theta}(\mathbf{x}))$
- 損失関数 $\ell((\mathbf{x}, y), g_{\theta}) := -y \log g_{\theta}(\mathbf{x}) - (1 - y) \log(1 - g_{\theta}(\mathbf{x}))$

■ このとき、勾配は次式のようになる

$$\nabla \ell((\mathbf{x}, y), g_{\theta}) = (g_{\theta}(\mathbf{x}) - y) \nabla s_{\theta}(\mathbf{x})$$

モデルの出力値

中間出力値の勾配

確率論的二値分類 > 最適化 > 微分

勾配は次式のようになる

- 勾配は次式のようになる

$$\nabla \ell((\mathbf{x}, y), g_{\boldsymbol{\theta}}) = (g_{\boldsymbol{\theta}}(\mathbf{x}) - y) \nabla s_{\boldsymbol{\theta}}(\mathbf{x})$$

- よって、L2正則化付き最尤法では、

$$\nabla L(\boldsymbol{\theta}) = \frac{1}{n} \sum_{i=1}^n (g_{\boldsymbol{\theta}}(\mathbf{x}_i) - y_i) \nabla s_{\boldsymbol{\theta}}(\mathbf{x}_i) + 2\lambda \boldsymbol{\theta}$$

- 例えば、 $s_{\boldsymbol{\theta}}(\mathbf{x})$ が線型モデルなら、一階の条件から最適解を見つけられそうか？

確率論的二値分類＞用語＞ロジスティック回帰

線型モデル＋ロジスティック関数の，最尤法ベースの学習

■ ロジスティックモデル (logistic model)

- 線型モデル＋ロジスティック関数というモデルのこと

$$g_{\theta}(x) = \sigma(\theta^{\top} \phi(x)) = \frac{1}{1 + e^{-\theta^{\top} \phi(x)}}$$

■ ロジスティック回帰 (logistic regression)

- ロジスティックモデルの最尤推定のこと（正則化が付くこともある）

$$L(\theta) := \frac{1}{n} \sum_{i=1}^n \left[-y_i \cdot \log g_{\theta}(x_i) - (1 - y_i) \cdot \log(1 - g_{\theta}(x_i)) \right] + \lambda \|\theta\|^2$$

- 注意：ロジスティック回帰は，名前に反して分類の手法

確率論的二値分類 > ロジスティックモデル > 勾配

残念ながら、 $\nabla L(\boldsymbol{\theta}) = 0$ の解の公式はない

- ロジスティックモデルの場合、 $g_{\boldsymbol{\theta}}(\mathbf{x}) = \sigma(\boldsymbol{\theta}^\top \boldsymbol{\phi}(\mathbf{x}))$ なので、

$$\nabla L(\boldsymbol{\theta}) = \frac{1}{n} \sum_{i=1}^n (\sigma(\boldsymbol{\theta}^\top \boldsymbol{\phi}(\mathbf{x}_i)) - y_i) \boldsymbol{\phi}(\mathbf{x}_i) + 2\lambda \boldsymbol{\theta}$$

- よって $\nabla L(\boldsymbol{\theta}) = \mathbf{0}$ は、次と等価.

$$\frac{1}{n} \sum_{i=1}^n (\sigma(\boldsymbol{\theta}^\top \boldsymbol{\phi}(\mathbf{x}_i)) - y_i) \boldsymbol{\phi}(\mathbf{x}_i) + 2\lambda \boldsymbol{\theta} = \mathbf{0}$$

- 残念ながら、この方程式の解の公式は知られていない

確率論的二値分類 > ロジスティックモデル > 最適化の困難





「微分して0とおく」で一意的な最適解を得るという手が使えない

- それでも、勾配を活用して最適化をする方法がある
- 勾配法 (gradient-based methods)
 - 勾配情報をもとにパラメーターを繰り返し更新するタイプの最適化手法の総称

基本知識の確認＞勾配のもつ意味

勾配は、最も上昇する方向（steepest ascent direction）を表す

- 1次元の場合、微小距離だけ θ を移動させるとき、
 - θ を $\nabla L(\theta)$ の方向に移動すれば、 L は最も増加する
 - θ を $-\nabla L(\theta)$ の方向に移動すれば、 L は最も減少する




【補足】1次元の場合、勾配は単なる1変数の微分に他ならない： $\nabla L(\theta) = \frac{d}{d\theta} L(\theta)$.

基本知識の確認＞勾配のもつ意味

勾配は、最も上昇する方向（steepest ascent direction）を表す

- 多次元の場合も同じ。微小距離だけ θ を移動させるとき、
 - θ を $\nabla L(\theta)$ の方向に移動すれば、 L は最も増加する
 - θ を $-\nabla L(\theta)$ の方向に移動すれば、 L は最も減少する



勾配降下法による最適化＞アルゴリズム

勾配降下法（gradient descent）により目的関数の最小化を目指す

- パラメーター θ を適当に初期化 ($\hat{\theta} \leftarrow \theta$)
- 以下を必要なだけ繰り返す
 - 目的関数 L の現在のパラメーター $\hat{\theta}$ における勾配 $\nabla L(\hat{\theta})$ を計算
 - 勾配の反対方向にパラメーターを少し更新（学習率 $\eta > 0$ ）

$$\hat{\theta} \leftarrow \hat{\theta} - \eta \nabla L(\hat{\theta})$$

- 早期停止条件を満たしていたら中断
- 最終的な $\hat{\theta}$ を使用する

勾配降下法による最適化＞詳細

基本はシンプルだが、細かく見ていくと色々な項目を決める必要がある

- パラメーター θ を適当に初期化 ($\hat{\theta} \leftarrow \theta$)
 - ← 初期化の方法は色々ある
(ハイパーパラメーター)
- 以下を必要なだけ繰り返す
 - ← 繰り返しの最大回数 T は決め打ち
(ハイパーパラメーター)
 - 目的関数 L の現在のパラメーター $\hat{\theta}$ における勾配 $\nabla L(\hat{\theta})$ を計算
 - **勾配の反対方向** にパラメーターを少し更新 (学習率 $\eta > 0$)
 - ← 繰り返しの t 回目には $\eta = \eta_t$ など
徐々に小さくすることもある
(ハイパーパラメーター)
 - 早期停止条件を満たしていたら中断
 - ← 例えば検証損失の改善幅が
 S 回にわたって ϵ に満たなかったら
早期停止 (ハイパーパラメーター)
- 最終的な $\hat{\theta}$ を使用する

$$\hat{\theta} \leftarrow \hat{\theta} - \eta \nabla L(\hat{\theta})$$


勾配降下法による最適化 > 詳細 > 重み減衰

勾配法で最適化する場合のL2正則化は，重み減衰とも呼ばれる

■ 重み減衰 (weight decay)

- 勾配法で最適化をする場合の，L2正則化の呼称
- L2正則化項があると，勾配法の更新方向は $-\nabla L(\hat{\theta}) = -\nabla \hat{R}(g_{\hat{\theta}}) - 2\lambda\hat{\theta}$
- 単に $R(g_{\theta})$ を小さくするだけの方向と比べて， $-2\lambda\hat{\theta}$ だけズレる

■ これは，更新の度に少しずつパラメーターを原点に向けて縮小すると解釈できる




【用語】ここでの「重み」は「パラメーター」と同義（重み付き和の係数に由来する用語）。ただし，「重み」といったとき，定数項に対応するパラメーターは含まないこともある。後者の場合，定数項に対応するパラメーターはバイアスと呼ばれ，バイアスを除くパラメーターにだけ重み減衰が適用される。

勾配降下法による最適化 > 詳細 > 早期停止

何らかの指標に基づいて、早期停止（early stopping）をすることが多い

- 例）検証データ上で直近 S 回にわたって ε 以上の改善がみられなかったら終了



検証損失値

- 「更新回数」（iteration）というハイパーパラメーターの選択にほかならない


確率論的二値分類 > 実験 > 設定

ロジスティックモデルをL2正則化付き最尤法で学習（勾配降下法で最適化）

タスク・学習戦略

分類タスク・教師付き学習

特徴量	ラベル
x_1	y_1
x_2	y_2
$\vdots$	$\vdots$
$\{(X_i, Y_i)\}_{i=1}^n \stackrel{\text{i.i.d.}}{\sim} p$	



訓練データ

モデル

ロジスティックモデル

$$g_{\theta}(x) = \sigma(\theta^{\top} \phi(x))$$

- 中身は30次の多項式

目的関数

負の対数尤度+正則化

$$L(\theta) := \frac{1}{n} \sum_{i=1}^n \ell((x_i, y_i), g_{\theta}) + \lambda \|\theta\|^2$$

- ハイパーパラメーター選択
- モデル選択指標は、早期停止時点の検証損失値
- 正則化係数 λ は $\{10^{-3}, 10^{-2}, 10^{-1}, 10^0\}$ から選択

最適化手法

勾配降下法


$$\hat{\theta} \leftarrow \hat{\theta} - \eta \nabla L(\hat{\theta})$$

- 学習率 η は 0.5
- 更新回数上限10000回
- 早期停止あり（直近5更新の改善幅が 10^{-3} 未満で停止）


確率論的二値分類＞実験＞結果（学習過程）

更新の繰り返しにより，徐々に目的関数値が小さいパラメーターを探索

縦軸：目的関数値




横軸：更新回数




確率論的二値分類 > 実験 > 学習結果

妥当そうなスコアリングモデルが学習できている

- 正例のあたりでは 1 に近く，負例のあたりでは 0 に近いスコア
 - その境目付近ではグラデーションがついている



訓練データ




学習済みモデル $g_{\hat{\theta}}$ が出力した確率値スコア


確率論的二値分類 > 実験 > 学習結果

予測器としても良さそうなものになっている

- 学習後のモデルに決定規則を合成した予測器 $f_{\hat{\theta}}(\mathbf{x}) := \tau(g_{\hat{\theta}}(\mathbf{x}))$ の様子




分類器としての出力
(スコアを0.5で閾値処理した結果)




評価用データでの予測と正解ラベル

確率論的二値分類 > 実験 > 学習結果（参考）


訓練前の初期化した時点での予測器と，訓練後の予測器



訓練前



目的関数値



訓練後

確率論的二値分類 > まとめ



確率論的二値分類の標準的な枠組みを説明した

■ 確率論的二値分類

- ロジスティック関数を組み込むことでモデル $g_{\theta}(\mathbf{x})$ の出力値が確率値になるようにする
- 交差エントロピーをリスクとして学習することで $g_{\theta}(\mathbf{x}) \simeq p(y = 1 | \mathbf{x})$ となるようにする
- 最適化は勾配法ベースで行う

■ 注意

- 確率値を出力できるなら、ロジスティック関数でなくてもよい
- 確率値の近似をさせられるなら、交差エントロピーの最小化でなくてもよい
- 上手く最適化できるなら、勾配法でなくてもよい
- ただし、現在はこの組み合わせが標準的（特に工夫しない場合に使われる）

確率論的二値分類 > 補足 > 勾配の導出

勾配の式 $\nabla \ell((\mathbf{x}, y), g_\theta) = (g_\theta(\mathbf{x}) - y) \nabla s_\theta(\mathbf{x})$ の導出

■ $\frac{d}{dz}\sigma(z) = \sigma(z)^2 \cdot e^{-z}$ と $\sigma(z)e^{-z} = 1 - \sigma(z)$ より, ① $\frac{d}{dz} \log \sigma(z) = 1 - \sigma(z)$ を示せる.

● [証明] $\frac{d}{dz} \log \sigma(z) = (\sigma(z))^{-1} \cdot \left(\frac{d}{dz} \sigma(z) \right) = \sigma(z) \cdot e^{-z} = 1 - \sigma(z).$

■ $\tilde{y} := 2y - 1$ と定めると, ② $\ell((\mathbf{x}, y), g_\theta) = (-\log \sigma(s_\theta(\mathbf{x})\tilde{y}))$ を示せる.

● [証明] $1 - \sigma(z) = 1 - (1 + e^{-z})^{-1} = (1 + e^{-z} - 1)(1 + e^{-z})^{-1} = (1 + e^z) = \sigma(-z).$

■ ①と②から, $\nabla \ell((\mathbf{x}, y), g_\theta) = (g_\theta(\mathbf{x}) - y) \nabla s_\theta(\mathbf{x})$ を得る.

$$\nabla \ell((\mathbf{x}, y), g_\theta) = - (1 - \sigma(s_\theta(\mathbf{x})\tilde{y})) \cdot (\nabla s_\theta(\mathbf{x})\tilde{y})$$

● [証明]
$$= \begin{cases} (\sigma(s_\theta(\mathbf{x})) - 1) \nabla s_\theta(\mathbf{x}) & (y = 1) \\ (1 - \sigma(-s_\theta(\mathbf{x}))) \nabla s_\theta(\mathbf{x}) & (y = 0) \end{cases} = \begin{cases} (\sigma(s_\theta(\mathbf{x})) - 1) \nabla s_\theta(\mathbf{x}) & (y = 1) \\ (\sigma(s_\theta(\mathbf{x}))) \nabla s_\theta(\mathbf{x}) & (y = 0) \end{cases}$$

【補足】最後の式変形は, $y = 0, 1$ をそれぞれ代入すると確認できる.

ロードマップ

