

多クラスの確率論的分類

講義の前提知識＞ノテーションの注意

この講義では、ベクトルの成分を表すために次の記号を使う

- 多次元の出力をするモデルを扱うにつれて、特定の成分を表す機会が増える
 - そこで、次の便利な記号を用意しておく
- （次元を問わず）ベクトル a に対して、その第 k 成分を $a[k]$ と表す.

$$a = \begin{pmatrix} 1 \\ 10 \\ 100 \\ 1000 \end{pmatrix} \text{ とするとき, } a[3] = 100$$

多クラスの確率論的分類（確率論的多値分類）



多クラス分類の場合の確率論的分類を説明

- 誤分類率 $R(f) = \mathbb{E} [\ell_{0/1}(Y, f(X))] = \mathbb{P}(Y \neq f(X))$ に対して最適な予測器の形は,

$$f^*(\mathbf{x}) = \arg \max_{1 \leq k \leq K} p(y = k | \mathbf{x})$$

- そこで, モデルで $p(y | \mathbf{x})$ を近似するよう学習し, その値が最大なクラスを出力

$$f_{\theta}(\mathbf{x}) = \arg \max_{1 \leq k \leq K} p_{\theta}(y = k | \mathbf{x})$$

確率論的多値分類＞確率値ベクトルを出力するモデル


出力が確率値ベクトルになるモデル $g_{\theta}(x)$ を用意する必要がある

- モデルで近似したいのは、全クラスの事後確率を並べた確率値ベクトル関数

$$x \mapsto \begin{pmatrix} p(y = 1 | x) \\ \vdots \\ p(y = K | x) \end{pmatrix}$$

成分が非負で、総和が1になる

- 対策：出力が確率値ベクトルの要件を満たすように、出力値の変換を合成




確率論的多値分類＞確率値ベクトルを出力するモデル

出力が確率値ベクトルとなるようにしたい場合、次のような変換を用いる

■ ソフトマックス関数 (softmax)

$$\text{Softmax}(z_1, \dots, z_K) = \frac{1}{\sum_{k=1}^K e^{z_k}} \begin{pmatrix} e^{z_1} \\ \vdots \\ e^{z_K} \end{pmatrix}$$

- まず $z_k \mapsto e^{z_k} \geq 0$ としておいて、総和で割るので、これは確率値ベクトルになる



4次元の実ベクトルを、4次元の
確率値ベクトルに変換

$$(Z = \exp(z_1) + \dots + \exp(z_4))$$

確率論的多値分類＞ソフトマックス関数＞補足

ソフトマックス関数は、ロジスティック関数の多クラス化とみなせる

- 2クラスの場合、ソフトマックス関数への入力も出力も2次元で、

$$\text{Softmax}(z_1, z_2) = \begin{pmatrix} \frac{e^{z_1}}{\sum_{i=1}^2 e^{z_i}} \\ \frac{e^{z_2}}{\sum_{i=1}^2 e^{z_i}} \end{pmatrix}$$

- いま、 $w = z_1 - z_2$ とおき、ロジスティック関数 $\sigma(t) = \frac{1}{1 + e^{-t}}$ を使って表すと、

$$\text{Softmax}(z_1, z_2) = \begin{pmatrix} \frac{e^{z_1}}{\sum_{i=1}^2 e^{z_i}} \\ \frac{e^{z_2}}{\sum_{i=1}^2 e^{z_i}} \end{pmatrix} = \begin{pmatrix} \frac{e^{z_1 - z_2}}{e^{z_1 - z_2} + e^{z_2 - z_2}} \\ \frac{e^{z_2 - z_2}}{e^{z_1 - z_2} + e^{z_2 - z_2}} \end{pmatrix} = \begin{pmatrix} \frac{1}{1 + e^{-w}} \\ \frac{1}{1 + e^w} \end{pmatrix} = \begin{pmatrix} \sigma(w) \\ 1 - \sigma(w) \end{pmatrix}$$

確率論的多値分類 > モデル > 予測器

ソフトマックスと最大事後確率則でモデルを作ることができる

- スコアリングモデル $s_{\theta}(x)$ を，確率値ベクトルのモデル $g_{\theta}(x)$ に変換する

$$g_{\theta}(x) = \text{Softmax}(s_{\theta}(x))$$

- $g_{\theta}(x)$ の学習は後述

- スコアリングを予測ラベルにするための決定規則には最大事後確率則を使う

$$\tau(p) = \arg \max_{1 \leq k \leq K} p_k$$

- 結局のところ，予測器は，次のようになる．

$$f_{\theta}(x) = \tau(g_{\theta}(x))$$

$\text{Softmax}(s_{\theta}(x))$



確率論的多値分類＞ベクトルを出力するモデル

モデル $s_{\theta}(x)$ としてクラス数ぶんのパラメーター線型モデルを用意

- クラスごとに線型関数 $\theta_k^{\top} \phi(x)$ を用意（特徴量変換 ϕ は共通）
- 出力値を並べれば， K 次元のベクトルを出力する関数になる

$$\begin{array}{c} \boldsymbol{x} \mapsto \begin{bmatrix} \theta_1^{\top} \phi(x) \\ \theta_2^{\top} \phi(x) \\ \vdots \\ \theta_K^{\top} \phi(x) \end{bmatrix} \\ s_{\theta}(x) \end{array}$$

確率論的多値分類＞学習方法

近似ターゲットが $p(y|\mathbf{x})$ になるように交差エントロピーをリスクとして学習

- $g_{\boldsymbol{\theta}}(\mathbf{x}) \simeq p(y|\mathbf{x})$ となるように学習したいので、最尤法ベースの学習をすればよい

$$\hat{R}(g_{\boldsymbol{\theta}}) = -\frac{1}{n} \sum_{i=1}^n \log g_{\boldsymbol{\theta}}(\mathbf{x}_i)[y_i]$$


- 例) L2正則化付き最尤法

$$L(\boldsymbol{\theta}) = \hat{R}(g_{\boldsymbol{\theta}}) + \lambda \|\boldsymbol{\theta}\|^2$$

確率論的多値分類 > 多クラスロジスティック回帰

線型モデル + ソフトマックス関数 + 最尤法ベースの学習

- 多クラスロジスティックモデル (multi-class logistic model)
 - クラス毎に別々の線型モデルを用意し，出力はまとめてSoftmaxで変換



- 多クラスロジスティック回帰 (multi-class logistic regression)
 - 多クラスロジスティックモデルを最尤法ベースで学習させて， $p(y|x)$ を近似

$$R(g_\theta) = \mathbb{E} [-\log g_\theta(X)[Y]]$$

確率論的多値分類＞ソフトマックスと最尤法＞勾配

ソフトマックスと負の対数尤度を使うときの、勾配を導出する

- K 次元出力のスコアリング関数 $s_{\theta}(\mathbf{x})$ を用いて、モデル $g_{\theta}(\mathbf{x}) = \text{Softmax}(s_{\theta}(\mathbf{x}))$
- データが $(\mathbf{x}, y)$ のときの損失関数（負の対数尤度） $\ell((\mathbf{x}, y), g_{\theta}) = -\log g_{\theta}(\mathbf{x})[y]$
- θ に関する勾配 $\nabla \ell((\mathbf{x}, y), g_{\theta})$ は、 $\log$ によって Softmax の分子分母を分解すれば、

$$\nabla \ell((\mathbf{x}, y), g_{\theta}) = -\nabla s_{\theta}(\mathbf{x})[y] + \nabla \log \left(\sum_k \exp(s_{\theta}(\mathbf{x})[k]) \right)$$

$$\nabla \log \left(\sum_k \exp(s_{\theta}(\mathbf{x})[k]) \right) = \frac{\sum_k \exp(s_{\theta}(\mathbf{x})[k]) \cdot \nabla s_{\theta}(\mathbf{x})[k]}{\sum_j \exp(s_{\theta}(\mathbf{x})[j])} = \sum_k g_{\theta}(\mathbf{x})[k] \cdot \nabla s_{\theta}(\mathbf{x})[k]$$

確率論的多値分類＞ソフトマックスと最尤法＞勾配

ロジスティックモデルの負の対数尤度の勾配は，次のように書ける

■ 勾配は

$$\nabla \ell((\mathbf{x}, y), g_{\theta}) = -\nabla s_{\theta}(\mathbf{x})[y] + \sum_k g_{\theta}(\mathbf{x})[k] \cdot \nabla s_{\theta}(\mathbf{x})[k]$$

■ 特に，多クラスロジスティック回帰なら， $s_{\theta}(\mathbf{x})[k] = \boldsymbol{\theta}_k^{\top} \boldsymbol{\phi}(\mathbf{x})$ なので，

$$\nabla_{\boldsymbol{\theta}_k} \ell((\mathbf{x}, y), g_{\theta}) = (g_{\theta}(\mathbf{x})[k] - \mathbf{1}\{k = y\}) \boldsymbol{\phi}(\mathbf{x})$$

確率論的多値分類＞ソフトマックスと最尤法＞最適化

この場合も解の公式は得られないので、勾配法による最適化を行う

- 多クラスロジスティック回帰なら、 $L(\boldsymbol{\theta}) = \frac{1}{n} \sum_{i=1}^n (-\log g_{\boldsymbol{\theta}}(\mathbf{x}_i)[y_i])$ に対して、

$$\nabla_{\boldsymbol{\theta}_k} L(\boldsymbol{\theta}) = \frac{1}{n} \sum_{i=1}^n (g_{\boldsymbol{\theta}}(\mathbf{x}_i)[k] - \mathbf{1}\{k = y_i\}) \boldsymbol{\phi}(\mathbf{x}_i)$$

- 勾配法では、 $-\nabla L(\boldsymbol{\theta})$ 方向に更新する。L2正則化付きなら、重み減衰も加えて、

$$-\nabla_{\boldsymbol{\theta}_k} L(\boldsymbol{\theta}) = \frac{1}{n} \sum_{i=1}^n (\mathbf{1}\{k = y_i\} - g_{\boldsymbol{\theta}}(\mathbf{x}_i)[k]) \boldsymbol{\phi}(\mathbf{x}_i) - 2\lambda \boldsymbol{\theta}_k$$

【補足】 ここで、 $\nabla L(\boldsymbol{\theta}) = (\nabla_{\boldsymbol{\theta}_1} L(\boldsymbol{\theta}), \dots, \nabla_{\boldsymbol{\theta}_K} L(\boldsymbol{\theta}))^\top$.


確率論的多値分類 > 実験 > 設定

L2正則化付き多クラスロジスティック回帰（勾配降下法で最適化）

タスク・学習戦略

分類タスク・教師付き学習

特徴量	ラベル
x_1	y_1
x_2	y_2
$\vdots$	$\vdots$
$\{(X_i, Y_i)\}_{i=1}^n \stackrel{\text{i.i.d.}}{\sim} p$	



訓練データ

モデル

多クラス
ロジスティックモデル

$$g_{\theta}(x) = \text{Softmax}(s_{\theta}(x))$$

$$s_{\theta}(x)[k] = \theta_k^{\top} \phi(x)$$

- 各々の中身は30次の多項式

目的関数

負の対数尤度+正則化

$$L(\theta) := \frac{1}{n} \sum_{i=1}^n \ell((x_i, y_i), g_{\theta}) + \lambda \|\theta\|^2$$

- 正則化係数 λ は $\{10^{-5}, \dots, 10^0\}$ から選択
- ハイパーパラメータ選択は早期停止時点の検証損失値を使用

最適化手法

勾配降下法

$$\hat{\theta} \leftarrow \hat{\theta} - \eta \nabla L(\hat{\theta})$$


- 学習率 η は 0.1
- 更新回数上限10000回
- 早期停止あり（直近10回の改善幅が 10^{-3} 未満で停止）

【補足】 学習の安定化のために、 ϕ の高次の項は、各項の次数 r に応じて、それぞれ予め 10^{-r} 倍したものとした（多項式モデルとしての表現力には影響なし）。


【実験ソースコード】 [番号]_multiclass_classification.ipynb

確率論的多値分類＞実験＞結果


訓練前の初期化した時点での予測器と，訓練後の予測器



訓練前のモデルと訓練標本



訓練誤差





訓練後のモデルと訓練標本


確率論的多値分類＞実験＞結果

妥当そうなスコアリングモデルが学習できている


- 各クラスの主要な集団のあたりでは1に近く、他のクラスの領域では0に近くなる
 - その境目付近ではグラデーションがついている



クラス1



クラス2




クラス3

学習済みモデル $g_{\hat{\theta}}$ が出力した確率値スコア


確率論的多値分類 > 実験 > 結果

予測器としても良さそうなものになっている

- 学習後のモデルに決定規則を合成した予測器 $f_{\hat{\theta}}(\mathbf{x}) := \tau(g_{\hat{\theta}}(\mathbf{x}))$ の様子



分類器としての出力
(スコア最大値を与えるラベルを予測)



評価用データでの予測と正解ラベル

確率論的多値分類 > まとめ



確率論的多値分類の標準的な枠組みを説明した

■ 確率論的多値分類

- ソフトマックスを使うことでモデルの出力値が確率値になるようにする
- 交差エントロピーをリスクとすることで、モデルに $p(y|\mathbf{x})$ を近似させる
(最尤法ベースの学習)
- 予測ラベルの選択をする決定規則としては、最大事後確率則を使う
- 最適化は勾配法ベースで行う

■ もちろん、この組み合わせでなくとも良いという注意は二値分類のときと同じ

確率論的多値分類＞ソフトマックス関数＞補足



ソフトマックスという名前は, $\arg \max$ に似ていることからきている

- LogSumExpという関数とSoftmaxの関係を使って説明する

確率論的多値分類 > ソフトマックス関数 > LogSumExp

LogSumExp関数というものを考える

- 「対数・総和・指数」という関数 (log-sum-exponential)

$$\text{LogSumExp}(z_1, \dots, z_K) = \log \left(\sum_{k=1}^K \exp(z_k) \right)$$

- これは max に似ている
 - 例) $\text{LogSumExp}(2, 5, 8, 0) \simeq 8.0513$ となり, おおよそ最大値 8 に一致

演習課題



実際，次が成立する

- 次を示せ.

$$\max\{z_1, \dots, z_K\} \leq \text{LogSumExp}(z_1, \dots, z_K) \leq \max\{z_1, \dots, z_K\} + \log(K)$$

確率論的多値分類 > ソフトマックス関数 > LogSumExp

SoftmaxとLogSumExpの関係

- SoftmaxはLogSumExpの勾配になっている

$$\frac{\partial}{\partial z_k} \text{LogSumExp}(z_1, \dots, z_K) = \text{Softmax}(z_1, \dots, z_K)[k]$$

- 理由：

- Softmaxの定義から, $\text{Softmax}(\mathbf{z})[k] = \exp(z_k - \text{LogSumExp}(\mathbf{z}))$
- 裏を返せば, $\text{LogSumExp}(\mathbf{z}) = z_k - \log \text{Softmax}(\mathbf{z})[k]$.
- これと, $\frac{\partial}{\partial z_k} \text{Softmax}(\mathbf{z})[k] = \text{Softmax}(\mathbf{z})[k] \cdot (1 - \text{Softmax}(\mathbf{z})[k])$ から上記が従う.

確率論的多値分類＞ソフトマックス関数＞性質

LogSumExpはmaxに似ており，その勾配であるSoftmaxはargmaxに似ている

- max を最も上昇させる入力の微小変化は，最大値の変数の方向
 - 例) $\max(2, 5, 8, 0) = 8$ であり，第3成分を増加させなければ上昇しない
- LogSumExp (maxに似ている) の，勾配であるSoftmaxは，arg max に似ている
 - 例) $\text{Softmax}(2, 5, 8, 0) \approx [0.002, 0.047, 0.950, 0.000]$ となり，最大値の第3成分がほぼ1，それ以外がほぼ0となっている → 最大値成分を指し示すベクトル