

ニューラルネットワーク

ニューラルネットワーク



次は，ニューラルネットワークとよばれる柔軟なモデルを解説します

- ニューラルネットワークというモデルは，非線形モデルの主要なものの一つであり，実用的にも広く使われている。
- どういう学習の仕組みになっているかを理解しておくと，ここまでの内容と，近年のニューラルネットワークを用いた高度な機械学習モデルに関する話がつながって，裏の仕組みがイメージしやすくなる

講義の前提知識＞ノテーションの注意

この講義では、1変数関数は断りなく多次元のベクトルに適用できるとする


- 多次元の出力をするモデルを扱う上で、便利な記号を用意しておく.
- ベクトル $\boldsymbol{a}$ に対して、1変数関数 ψ を成分ごとに適用したものを $\psi(\boldsymbol{a})$ で表す.

$$\psi(\boldsymbol{a}) := \begin{bmatrix} \psi(a_1) \\ \psi(a_2) \\ \vdots \\ \psi(a_d) \end{bmatrix}$$

ニューラルネット > 複雑なモデルと特徴量

ニューラルネットのポイントは、変換の階層性

- 線型モデルでは、出力値へのパラメーターの関与は、出力直前の一箇所だけ




- ニューラルネットワーク (neural network, NN) では……



ニューラルネット > 基本の構成要素 > 順伝播型NN

ニューラルネットワークの中でも、最もプレーンなものから説明

- 順伝播型ニューラルネットワーク (Feed-forward neural network, FNN)
 - レイヤー (layer, 層) とよばれる部品を直列に繋げて複雑な関数を作る




【用語】 特別な味付けがないという比喻で、「バニラ」ニューラルネットワーク (vanilla neural network) とも呼ばれる。多層パーセプトロン (Multi-layer Perceptron, MLP) とも呼ばれる。伝播は、伝搬 (でんぱん) ではなく伝播 (でんぱ) であることに注意。

ニューラルネット > 基本の構成要素 > レイヤー

各レイヤーの中身は、「線型変換を施してから活性化関数」でできている

■ 各レイヤー内の計算は $x \mapsto \psi(Wx + b)$ (W, b はパラメーター, ψ は固定)

- 線型変換 $x \mapsto Wx + b$ の後, 共通の ψ を成分毎に適用 $\psi(u) = [\psi(u_1), \dots, \psi(u_r)]^\top$
- W は重み, b はバイアス, ψ は活性化関数 (activation function) という




ニューラルネット > 基本の構成要素 > 活性化関数

よく使われる活性化関数（他にも多数提案されている）

Sigmoid

（標準ロジスティック関数）

$$\psi(u) = 1/(1 + \exp(-u))$$





ReLU

$$\psi(u) = \max\{0, u\}$$


Leaky ReLU

$$\psi(u) = \max\{\alpha u, u\} \quad (0 \leq \alpha < 1)$$



Swish


$$\psi(u) = u/(1 + \exp(-\beta u))$$



Linear activation

$$\psi(u) = u$$

（恒等写像）




ニューラルネット > 基本の構成要素 > 順伝播型NN

このモデルは階層性がポイント

- 一つ一つのレイヤーは、さほど複雑な処理は行わない
 - 線型変換 + 成分ごとの活性化関数
 - しかし、それを多数重ねることで、全体としては複雑な関数を表現
- 各レイヤー内の処理には調整可能なパラメーター (W, b) が付いている




$$x \mapsto \psi_1(W_1(x) + b_1) \mapsto \psi_2(W_2(\psi_1(W_1(x) + b_1) + b_2) \mapsto \psi_3(W_3(\dots$$



ニューラルネット＞基本の構成要素

隠れ層を増やしていくと，関数として複雑化していく

- 既存の層は変えずに，ランダム初期化した層を順次追加していった場合




レイヤーの数

ニューラルネット > 基本の構成要素 > 順伝播型NN

パラメーターの形状：前の層の出力を受け取れて、次の層に渡せる必要がある

- 入力層・出力層のパラメーターは、モデルとしての入出力次元に合わせる
- 中間層の出力の次元数は任意に選択可能（ハイパーパラメーター）
 - 例）3次元入力→**16次元**→**8次元**→2次元出力
 - 隣り合うレイヤー間では、出力を受け渡せる必要がある



【注意】 入力層・出力層の次元数は、受け付ける入力次元数・欲しい出力次元数に合わせる必要がある。


ニューラルネットワーク > 基本の構成要素 > 出力層

出力層の活性化関数は、確率値にしたいか否かなどで決まる

■ 出力層の活性化関数では、通常は以下が用いられる


- 回帰 → 実数出力にしたいので恒等活性化関数

$$\psi(u) = u$$



- 2クラス確率論的分類 → シグモイド関数（ロジスティック関数）

$$\psi(u) = \text{Sigmoid}(u)$$



- 多クラス確率論的分類 → ソフトマックス関数

$$\psi(u) = \text{Softmax}(u)$$

ニューラルネット > 基本の構成要素 > 活性化関数の役割



活性化関数は省いてはいけない？

- 活性化関数がないければ、いくつ層を重ねても、結局1つの層に縮約できてしまう


$$W_2(W_1x + b_1) + b_2 = (W_2W_1)x + (W_2b_1 + b_2)$$

- つまり、活性化関数が無ければ、1層分の複雑さの関数しか表すことができない
- 線型（+ 定数）よりも複雑な関数を表せるようにするのが活性化関数の役割
 - ゆえに、活性化関数のことを「非線型性」（nonlinearity）と呼ぶこともある


ニューラルネット＞基本の構成要素＞ユニット

レイヤーを細かく見ると，ユニットを多数繋げたものという見方もできる

- 順伝播型NNは，ベクトルを変換するレイヤーを積み重ねたモデル



- レイヤーは，複数の**ユニット (unit, 素子)** からなる



ニューラルネット > 基本の構成要素 > ユニット

ユニットは、レイヤーをさらに詳しく見たもの

- 重み行列 W , バイアス b , 活性化関数 ψ からなるレイヤーは,

$$W = \begin{bmatrix} \mathbf{w}_1^\top \\ \vdots \\ \mathbf{w}_r^\top \end{bmatrix}, \quad b = \begin{bmatrix} b_1 \\ \vdots \\ b_r \end{bmatrix} \quad \text{とすると,} \quad \psi(W\mathbf{x} + b) = \begin{bmatrix} \psi(\mathbf{w}_1^\top \mathbf{x} + b_1) \\ \vdots \\ \psi(\mathbf{w}_r^\top \mathbf{x} + b_r) \end{bmatrix}$$

- これは、次の形の**ユニット (unit, 素子)** を r 個並べたものともみなせる
 - w を**重み(weight)**, b を**バイアス(bias)**, $\psi: \mathbb{R} \rightarrow \mathbb{R}$ を**活性化関数**として

$$\mathbf{x} \mapsto \psi(\mathbf{w}^\top \mathbf{x} + b)$$


【用語】 「重み」は $\mathbf{w}^\top \mathbf{x} = w_1 x_1 + \dots + w_p x_p$ という重み付き和の重みであることから。「バイアス (偏り)」は、出力の値を $+b$ だけ「ずらす」ことから。

ニューラルネット > 表現図式と用語 > ユニット


ユニットを表す図式

- ユニット $x \mapsto \psi(\mathbf{w}^\top \mathbf{x} + b)$ の図 (重み $\mathbf{w}$, バイアス b , 活性化関数 ψ)

- 入力を受け取るとユニットの「現在の値」 = **活性値 (activation)** が決まる



- ユニットの活性値は, 次のユニットたちに渡される (重み付き和で)




$$\begin{bmatrix} h_1 \\ h_2 \end{bmatrix} = \begin{bmatrix} \psi(\mathbf{w}_1^\top \mathbf{u} + b_1) \\ \psi(\mathbf{w}_2^\top \mathbf{u} + b_2) \end{bmatrix}$$

ニューラルネット＞表現図式と用語＞用語


ユニットを複数並べたものがレイヤーとなる

- 並べた個数はレイヤーの幅 (width) という



ニューラルネット＞表現図式と用語＞全体

よく使われる図式



隠れ層が2層ある → 隠れ2層のFNN
(two-hidden-layer FNN) という


入力層を除いて3層ある → 3層FNN
(three-layer FNN) ともいう

ニューラルネット > アーキテクチャ




ユニット単位で見れば，結合の仕方はもっと自由に設計してもよい

- 今回扱ったレイヤーは，前の層の**全ての**ユニットから，今の層の**全ての**ユニットに線が繋がっているので，**全結合層（fully-connected layer）**と呼ばれる



全結合

- 例えば，次のようなネットワークを考えてもよい



あえて一部だけ結合

- ネットワークの設計のパターンは**アーキテクチャ（architecture）**と呼ばれる

ニューラルネット＞モデルの構造



ニューラルネットワークの人気の理由の一つは、その柔軟さにある

- 応用分野ごとに、問題に合った形のモデルを生み出すことができる
 - 画像に適した構造，テキストに適した構造，……が研究・開発されている
- 応用分野ごとの適したアーキテクチャ選定は，学習における事前知識の典型例