

学習の障壁① 非構造化データ

データの種類

データには、大きく分けて2種類ある

ID	降水量	祝日	売上
0001	22	0	120万
0002	0	1	240万
0003	21	0	105万
0004	...	...	...
0005	...	...	...

構造化データ

例) 表形式データ



1. 栄養バランスの取れた食事をとること。特に、多量の果物と野菜を含めること。
より身体を活動
り、規則正しい
ること。


非構造化データ

例) 画像やテキストなどのデータ

データの種類＞表形式データ

データベースに入っているような，行と列があるデータを表形式データという

- 表形式データ（tabular data）や，テーブルデータという



ID	降水量	祝日	売上	...
0001	22	0	120万	...
0002	0	1	240万	...
0003	21	0	105万	...
0004	...	...	...	...

- カラムには普通，それぞれ名前（フィールド名）が付いている

データの種類＞表形式データ

表形式データのことを，構造化データともいう

■ 構造化データ（structured data）

- テーブルデータとほぼ同義
- あらかじめ決められた，明確な構造を持った形で整理されたデータという意味

■ どこに何の情報が書いてあるかが明確


ID	降水量	祝日	売上	...
0001	22	0	120万	...
0002	0	1	240万	...
0003	21	0	105万	...
0004	...	...	...	...

売上を知りたいければ
ここを見ればよい

データの種類＞画像データ

画像データは、コンピュータの中でどうやって扱われているのか？

- 画像を拡大すると、画素（pixel, ピクセル）という小さな四角が並んでいる




- それぞれの画素は数値を保持していて、それによって色や明るさを表している

【補足】 正確には、これはラスター画像（raster image）やビットマップ画像（bitmap image）と呼ばれる種類の画像。ほかにベクター画像（vector image）と呼ばれる種類の画像データもある。この講義では、特に断りなく画像といえばラスター画像を指す。


データの種類＞画像データ

画像データは数値を四角形に並べたもの


- RGBカラー画像：各画素は3つの数値（光の三原色を混ぜ合わせる量を指定）



(Red, Green, Blue)
= (122, 133, 82)



- グレースケール画像：各画素は1つの数値（明度を指定）



Lightness = 0.53

データの種類＞無加工の特徴量

つまり、我々にはこう見える情報は……



データの種類＞無加工の特徴量

コンピューターにはこう見えている

	0.12	0.13	0.18	...
0.12	0.12	0.13	0.18	...
0.14	0.14	0.53	0.54	...
0.15	0.15	0.49	0.62	...
0.14	0.14	...	...	...

データの種類＞テキストデータ

テキストデータは、コンピューターの中でどうやって扱われているのか？

- コンピューターの中では、1つ1つの文字に番号が振られている
 - その対応表や個々の番号を文字コード（character code）という

@	A	B	C	...
40	41	42	43	...

- ちなみに、日本語の文字はもっと後ろの番号（よく使う文字は桁が少ない傾向）

い い 天 気
[‘227129132’, ‘227129132’, ‘229164169’, ‘230176151’]

【補足】 文字コードには沢山の種類がある。多言語対応のUnicodeという国際標準があり、その中でも、現在は UTF-8 という文字コードが事実上の標準である。

データの種類＞テキストデータ

コンピューターにとって言語は、文字コードの羅列

- シェイクスピアの芸術も、「文字コード」を並べた文字列（string）に見える

```
['84', '111', '32', '98', '101', '44', '32', '111', '114', '32', '110', '111', '116', '32', '116',  
'111', '32', '98', '101', '44', '32', '116', '104', '97', '116', '32', '105', '115', '32', '116',  
'104', '101', '32', '113', '117', '101', '115', '116', '105', '111', '110', '46']
```


データの種類＞無加工の特徴量

つまり、我々にはこう見える情報は……

”To be, or not to be,
that is the question.”


データの種類＞無加工の特徴量

コンピューターにはこう見えている

```
['84', '111', '32', '98', '101', '44', '32',  
'111', '114', '32', '110', '111', '116', '32',  
'116', '111', '32', '98', '101', '44', '32',  
'116', '104', '97', '116', '32', '105', '115',  
'32', '116', '104', '101', '32', '113', '117',  
'101', '115', '116', '105', '111', '110', '46']
```

データの種類＞無加工の特徴量

この数値の羅列から、意味論的な情報を見出す必要がある




- 意味論的な情報が重要そうなタスクなら、「意味のある情報」を抽出できなければ、おそらく精度良くは解けないだろう

データの種類＞非構造化データ

画像データやテキストデータは、非構造化データと総称される

- **非構造化データ（unstructured data）**：構造化データではないデータのこと




- 構造化データとの違い

- 構造化データでは、決まった位置に決まった意味の情報が書かれていた
- 非構造化データでは、どの位置に何の情報があるか決まっていない

データの種類＞非構造化データ＞高次の情報

高次の情報は、多くの有用なタスクにおいて最重要になると思われる

- 非構造化データを見て「犬……寝ている……毛布がある……」といった高次の情報を捻り出さないと解けなそうなタスクは多い



ラベル
生物の種類

ラベル
物体の個数

ラベル
シーン説明文

- 実用的なタスクでは、このような高次の情報抽出が鍵に！

データの種類＞非構造化データ＞高次の情報



非構造化データから，高次の情報を見出すには？

- 非構造化データの特性の一つは，概念の階層性
- 階層的な情報処理をすることにより，高次情報を扱えるかもしれない

データの種類＞非構造化データ＞階層性

非構造化データの特性は、概念の階層性にある


- 加工前の特徴量は、微細で断片的な情報だけを持つ
- それらが統合されて、上位の概念ができている



データの種類＞非構造化データ＞階層性

非構造化データの特性は、概念の階層性にある

- 加工前の特徴量は、微細で断片的な情報だけを持つ
- それらが統合されて、上位の概念ができている



データの種類 > 非構造化データ > 階層性



非構造化データを扱うタスクでは，この階層性のうまい活用が鍵になる

- このような階層的な特徴抽出のプロセスを，明示的な設計なしに一気通貫で学習するモデルがニューラルネット



ロードマップ

