

深層モデルと表現学習

深層モデルと表現学習



ニューラルネットのようなモデルは階層性により特徴を抽出


- 深層学習（deep learning）という考え方を解説
 - 層を多く重ねた「深い」ニューラルネットワークをモデルとして使う手法
- 画像やテキストのような「非構造化データ」を扱う上で、階層性が有用になる
 - 高次の情報の抽出方法を、一気通貫で学習
- 一方で、深層モデルの最適化は特有の難しさがある
 - 困難ではありながら、様々な工夫により乗り越えられつつある

深層モデル

層を多数重ねたニューラルネットワークモデルのことを深層NNという

■ 深層ニューラルネットワーク (deep neural networks, DNNs)

- 入力の特徴量に何層もの変換を施す




- 入力側を「浅い層」 (shallow layers) , 出力側を「深い層」 (deep layers) という

【補足】ここでのレイヤーは、全結合層に限らない。画像なら画像、テキストならテキストに適したレイヤーを想定してほしい。

深層モデル＞層の役割

途中の特徴量は徐々に高次の情報を持つように

- 画像やテキストなどの非構造化データでは、階層性がタスクを解く鍵になる




- DNNで学習がうまくいくと、（不思議なことに）徐々に高次の情報が抽出されるようなモデルになることが知られている
- どういう意味か？


深層モデル＞層の役割

途中の層の出力を調べよう（中間出力）

- 学習済みモデルに画像を入力して，中間層の出力ベクトルを詳しく見る







- それぞれの中間層のユニットの値を最大化するように入力画像を調整してみる



深層モデル＞層の役割

浅い層（入力側に近い層）



- 浅い層でのユニットの出力値が最大化されるような入力画像（ユニットごと）
 - かなり局所的な構造に反応するユニットが学習されている
 - ちょっとした模様や、一定の方向を持ったエッジなどに反応



深層モデル＞層の役割

中間あたりの深さの層（真ん中あたり）

- 少し深い層のユニットの出力値が最大化されるような入力画像（ユニットごと）
 - もう少し大きな構造に反応するユニットが学習されている
 - パターンや大きめの図形に反応



深層モデル＞層の役割

深い層（出力側に近い層）


- ストロベリーに対応する出力層ユニットの出力値を最大化するような入力画像
 - 画像分類のために学習されたモデルなので、そういうユニットがある
 - 1個のイチゴの形状ではない．イチゴの画像らしさが学習されている気がする



深層モデル＞層の役割

まとめると……加工前の特徴量から情報が段階的に抽出・統合されていく

- 浅い層：線や点に反応して値が大きくなる（活性化する）ユニットが学習
- 少し深い層：図形やパターンに反応して値が大きくなるユニットが学習
- 深い層：より統合的な情報に反応して値が大きくなるユニットが学習




深層モデル＞層の役割＞補足

ユニットの活性化値最大化の方法

- 次式の最適化はどうやって実行しているのか？

$$\text{Max}_x u_1$$

- データ変数も計算グラフの一部
 - パラメーターによる勾配を計算できるのと同様に, $\nabla_x u_1$ を導出可能



【補足】 このように, ユニットやレイヤーの出力値を最大化するような入力を求める手法は, 活性化値最大化 (activation maximization) と呼ばれる.

深層モデル＞層の役割




階層的な情報処理を学習できる（可能性がある）ことが深層モデルの本領

- 深層モデルは、その階層性により、非構造化データから高次の情報を段階的に抽出できる可能性がある
- 実際に、上手くいけば階層的な特徴抽出器が学習されることがある
 - 例えば、画像の分類タスクの予測器として深層モデルを学習しているだけだが、自然と階層的な情報処理になることがある

深層モデル＞層の役割

こうして見ると，学習済みモデルを「使いまわせる部分がある」気がしてくる

- 特に，うまく学習できていれば，浅い層については使い回せそうに見える
 - 浅い層……画像処理に共通する処理（例：境界線や図形パターンの検出など）
 - 深い層……そのときのタスクに特化した情報抽出（例：イチゴのスコアなど）




- ここから，新しい学習戦略「事前学習と精密調整」の発想が生まれる

深層モデル＞学習戦略＞事前学習と精密調整

精密調整：別のタスクで学習済みのモデルを，目的タスクのデータで再訓練

■ 精密調整，ファインチューニング（fine-tuning）

- 別タスクの学習済みモデルから，目的とするタスクのために追加学習すること




【補足】 この学習戦略との対比として，事前学習済みモデルから始めずにゼロから学習することは，フルスクラッチでの学習（full-scratch training）という。


深層モデル＞学習戦略＞事前学習と精密調整＞方法

精密調整では，学習済みモデルを初期値として勾配法でパラメーターを更新

- ニューラルネットなら，**学習済みモデル**を初期値として**勾配法で学習**すればよい




- 一部のパラメーターはあえて更新しない（freezeする＝固定する）こともある



深層モデル＞学習戦略＞事前学習と精密調整

精密調整にも，細かいやり方はいくつかの流儀がある

- 主流な方法：最終層周辺だけは新規の層で置き換えて，全体を勾配法で再学習



- 他の流儀もある


- 単純に，学習済みモデルを初期値として，勾配法で追加学習
- 最終層周辺だけは新規の層で置き換えて，その新規の層だけ勾配法で再学習

【補足】 さらに細かく見ると，学習済みパラメータを再利用した部分に対しては学習率を小さめにしたりする工夫も行われる。

深層モデル＞学習戦略＞事前学習と精密調整

事前学習：あとから精密調整する想定で、学習済みモデルを作っておく段階

- **事前学習（pre-training）**：事前に学習済みモデルを作る段階のこと



- 事前学習に使うタスクは、最終的な目的のタスクと同じとは限らない
 - むしろ「大量にデータが得られるような事前学習用タスク」の力を借りられることがポイント

深層モデル＞学習戦略＞事前学習と精密調整


事前学習としてどのようなタスクが適しているかは、探究の余地のある課題

- **事前学習タスク（pre-training task）**：事前学習のためのタスクのこと
 - このタスクを解くことで、精密調整後に様々なタスクの良いモデルが得られるような、普遍的に有用なパラメーターを獲得することを期待
 - 分野ごとに定番があったり、より良い方法が模索されていたりする
- 例）画像を扱うモデルの事前学習
 - 「ImageNet」データの1000クラス画像分類タスクが、事前学習タスクの定番

深層モデル＞学習戦略＞事前学習と精密調整＞利点

大規模な学習を繰り返すことなく，タスクに合った高性能モデルを得られる

通常の学習




タスクごとに
大量のデータと
大量の計算資源で学習

事前学習＋精密調整

事前学習

精密調整



事前学習は
大変だが

タスクごとの
教師データは
小さめで済む

深層モデル＞学習戦略＞事前学習と精密調整

どこで事前学習済みモデルを手に入れるか？


- 近年では、研究者や企業が学習済みモデルを公開することが多い
 - 例えば先ほどまでの実験は、InceptionというGoogle発の学習済みモデル
- 学習済みモデルが公開されているサイトなどもある
 - Hugging Face (<https://huggingface.co/>) などが主要なもの
 - ▶ 画像系：画像分類、物体検出、画像生成、深度推定、……など
 - ▶ テキスト系：文書分類、翻訳、要約、テキスト生成、文類似度、……など
 - ▶ 音声系：音声認識、音声合成、話者認識、音声区間検出、……など

深層モデル＞表現学習



ここで、なぜ使いまわせるような気がしたか？を考えてみよう


- 先ほどの場合に使い回しができる気がしたのは、これが入力データの意味論的な情報をうまく捉えた「中間的な特徴表現」を獲得できているように見えるため



深層モデル＞表現学習

深層モデルの学習に対する一つの見方

- 見方によっては、深層モデルは特徴写像も一気通貫で学習するモデルといえる




- この特徴写像は、モデル内での中間表現となるベクトルを出力する
- このようにモデルの内部で使われる中間表現を、データの**ベクトル表現 (vector representation)** という

深層モデル > 表現学習

深層モデルは、入力のベクトル表現を（タスクの学習と同時に）学習している

■ 表現学習（representation learning）、特徴学習（feature learning）

- タスクに有用な中間表現（ベクトル表現）をデータから自動的に学習すること
- ベクトル表現を学習する = 入力をベクトルに変換する関数を学習する



【補足】「表現学習」や「特徴学習」は、旧来の人手による特徴エンジニアリングに依存する特徴設計の仕方とは対照的である。

【注意】ベクトルの特定の成分が、特定の情報を持っている、というわけではない（例：第1成分が線の有無を見ているなどの簡単な解釈ができるとは限らない）。

深層モデル＞表現学習

細かい注釈 2 つ

- ①どの層まで汎用性があり，どこからがタスク特化，という線引きはない
 - ただし，少なくとも最終層はタスクに特化しがちだと考えられている
 - 精密調整で最終層は新品に置き換えることが多いのはこれが理由
- ②学習済みモデルだからといって良いベクトル表現を学習しているとは限らない
 - 先の画像分類モデルの例では？
 - ▶ 入力を階層的に処理して抽象を取り出す特徴抽出器になっている様子が見られたからこそ，汎用的なベクトル表現を学習できていることが期待できた
 - ▶ 画像に特化したレイヤーが使われていることも，有用な特徴抽出に寄与

【補足】最終層は，そもそもタスクによって欲しい出力の形状（次元数など）が異なることもよくあるので，アーキテクチャのレベルでタスク特化なこともある。

深層モデル＞表現学習＞方法

うまく表現学習をするには？


- 狙って試みることもあれば、学習の副産物として表現学習ができることもある
 - 先ほどの例では、教師付き学習（画像分類）の副産物として表現学習が達成（階層的モデルが獲得した中間表現はデータの本質を捉えていることがある）
 - 積極的に表現学習を目的とした事前学習が行われることもある
- 表現学習のための事前学習
 - 教師付きで行う手法も、教師なしで行う手法も探求されている

深層モデル＞表現学習＞オートエンコーダー

教師なし学習による表現学習の方法のアイデアの一つ

■ 次の2つを用意する

- エンコーダー（符号化器）：入力をベクトル表現に変換するモデル
- デコーダー（復号化器）：ベクトル表現からデータを再現しようとするモデル



■ 入力と同じものを出力させるのでオートエンコーダー（自己符号化器）という

【補足】学習された潜在空間の構造や、潜在ベクトルの値を解釈することは難しく、それ自体が研究の対象となっている。また、画像を出力するモデルとはどのようなものか疑問かもしれないが、上手く工夫されたアーキテクチャーのニューラルネットワークでそのようなものがある。

深層モデル＞表現学習＞オートエンコーダー

オートエンコーダーの学習方法の概要は次のとおり

- 再構成誤差（reconstruction error）を損失関数として学習することが多い

$$L(\theta) := \frac{1}{n} \sum_{i=1}^n \|x_i - D_{\theta}(E_{\theta}(x_i))\|^2$$

- 入力を（比較的低次元な）ベクトルに変換 → その値から元の入力を概ね再現できるなら、「意味を濃縮した」ベクトル表現の学習になってくれるはず
- 実際には、入力にランダムなノイズ ϵ を加えて、 $x_i + \epsilon$ から x_i を再現できるように学習させるなど、様々な派生手法がある（上記は一例にすぎない）

- これはラベルなしで実行可能なので、教師なしの表現学習の方法になっている

【用語】再構成誤差という用語は必ずしも二乗誤差に限らず用いられる一般的なものだが、二乗誤差が最も標準的である。

【補足】ノイズを加えた入力から元の綺麗なデータを復元させる学習法や、それで学習したモデルのことを、デノイジング・オートエンコーダーと呼ぶ。

深層モデルと表現学習 > まとめ



うまく表現学習をできる（場合がある）ことに深層学習の大きな利点がある


- モデルが階層的な情報処理を学習できるので、階層性に関わる**非構造化データ**を扱うための**表現学習**に適性がある
- 学習済みモデルは再利用できる場合がある
 - 特に、良い**ベクトル表現**の学習に成功しているモデルを、特徴抽出器として再利用する使い方が多い
- 再利用する際には、目的とするタスクのデータで**精密調整**することが多い
 - そうする想定で、共通性をうまく捉えたモデルをあらかじめ学習しておく**事前学習**が一般的になっている

深層モデルと表現学習 > まとめ



これほど効果的なら、なぜこれまで実現されなかったのか？

- 層を深くすることには恩恵があるが、最適化の難易度は上がる



- 過去には、データ量も少なかった（パラメーターが多いぶんデータ量も必要）
- 画像などドメイン毎の適したアーキテクチャの探究も不可欠かつ時間を要した

もっと学ぶための資料案内



良い教科書が多数出版されている

■ Ian Goodfellowらの教科書

- <https://www.deeplearningbook.org/> で著者らによって無料公開されている
- 基礎の部分は変わっていないので、基本的な部分の説明や、深層ニューラルネットに関して皆が共有している思想的な背景などを知るのには良い教科書
- 最適化手法やアーキテクチャの発展は、（当時でも既に進んでいるように思われたが）当時から数段は進歩しているのもう古い