

類似度と予測

類似度と予測




今回はk-最近傍法，通称k-NNの話をしていきます

- これまでは，損失の期待値が小さい予測器，つまり入力特徴量から予測ラベルを出す関数を作る，という考え方を説明してきた
- もう一つの考え方は「過去の似ているデータ」を参照すること
- k-NNという「事例ベースの」予測器
 - これまでに出てきたモデルとは異なり，パラメーターを持たない



類似度と予測

予測で最も参考になるものは入力点の近くのデータ，ということはよくある

- 統計的学習：データから規則性を見出して，未知のデータで予測を行う



- そのための最有力な手がかりは「近くのデータ」ということがよくある



【注意】 もちろん，近くのデータがいつでも最有力な手がかりとは限らない。「近くのデータが重要」という信念も帰納バイアスあるいは事前知識である。

類似度と予測 > k-最近傍法 (k-NN)

距離に基づいて、近くの訓練データのラベルから予測

■ k-最近傍法 (k-nearest neighbors, k-NN)

- 未知の点を、最も近い k 個の点 (k -最近傍) の多数決で分類
- 近くの点のことを、近傍という



類似度と予測 > k-最近傍法 > 回帰

回帰の場合，訓練データのラベルの平均などを使う

■ k-最近傍回帰 (k-nearest neighbor regression)




- 距離に応じた重み付き平均をする場合もある

類似度と予測 > k-最近傍法 > ボロノイ図

分類器はどのようなものになるか？（1-NNの場合の分類器を図示）

- ボロノイ図（Voronoi diagram）：最近傍の点に応じて空間を分割した図




訓練データの中で
その点が最近傍になる
領域を区分で示した図

分類器についての考え方

分類器を作る = 決定領域を決める

- **分類器 (classifier)** : 特徴量 x を受け取って、予測ラベル y を出す関数
- **決定領域 (decision region)** : 予測ラベルが k となる特徴量 x の集合 D_k
 - 決定領域の間の境界は**決定境界 (decision boundary)** という



類似度と予測 > k-最近傍法 > 特徴

k-NNは、パラメーターを持たないことが特徴的



- k を決めたら、あとは近傍の訓練データからラベルを読み取るだけ
 - 学習したパラメーターではなく、訓練データを覚えておいて予測に使うモデル
 - **事例ベースモデル (exemplar-based model)** という
 - **記憶ベースモデル (memory-based model)** ということもある
- パラメーターの存在によってモデルの自由度が制限されることがない
 - **ノンパラメトリックモデル (nonparametric model)** という
 - 対して、これまでに扱ったようなモデルはパラメトリックモデルという

【用語】 何をもってノンパラメトリックモデルと呼ぶかは単純ではない。パラメーターを持たないモデルとも、無限次元の自由度を持つモデルともいう。また、未知データで予測をするまで学習らしいことをしないので、遅延学習 (lazy learning) 型の手法であるともいう。遅延学習は怠惰学習と和訳されることもある。


類似度と予測 > k-最近傍法 > ハイパーパラメーター

k-NNは、次の2つのハイパーパラメーターを持つ

- 近い順に何番目の点まで参照するか $k \geq 1$




- 近さを定量的に定義する距離関数 $\text{dist}(x, x')$



- どちらも、例えば検証データ上での誤分類率などで選べばよい


類似度と予測 > k-最近傍法 > kの選択の影響

小さいk：柔軟😊 過適合がち😓 ↔ 大きいk：平滑😊 過少適合がち😓



小さいk

よりデータに忠実な決定境界
右上に混入した負例も決定領域を発生



大きいk

より単純な決定境界
右上に混入した負例は無視されている

基本知識の確認＞距離

2点の遠さは距離関数で測る


■ 距離 (distance) $\text{dist}(\mathbf{x}, \mathbf{x}')$

- 性質： $\text{dist}(\mathbf{x}, \mathbf{x}') \geq 0$, かつ, $\text{dist}(\mathbf{x}, \mathbf{x}') = 0 \Leftrightarrow \mathbf{x} = \mathbf{x}'$
- 性質： $\text{dist}(\mathbf{x}, \mathbf{x}') = \text{dist}(\mathbf{x}', \mathbf{x})$ (対称性)
- 性質： $\text{dist}(\mathbf{a}, \mathbf{c}) \leq \text{dist}(\mathbf{a}, \mathbf{b}) + \text{dist}(\mathbf{b}, \mathbf{c})$ (三角不等式)

■ ユークリッド距離 (Euclidean distance)

$$\text{dist}_{\text{Euclid}}(\mathbf{x}, \mathbf{x}') = \|\mathbf{x} - \mathbf{x}'\| = \sqrt{(x_1 - x'_1)^2 + \dots + (x_d - x'_d)^2}$$

- 最も有名な距離 (断りがなければこれ)




【補足】 つまり、ユークリッド距離は、2-ノルムから誘導される距離ともいえる。

類似度と予測 > k-最近傍法 > 距離関数の選択肢

距離は1種類ではないので、何をもって距離とするかは選択肢がある

■ マンハッタン距離 (Manhattan distance)

$$\text{dist}_1(\mathbf{x}, \mathbf{x}') = |x_1 - x'_1| + \cdots + |x_d - x'_d|$$



■ マハラノビス距離 (Mahalanobis distance)

$$\text{dist}_M(\mathbf{x}, \mathbf{x}') = \sqrt{(\mathbf{x} - \mathbf{x}')^\top M (\mathbf{x} - \mathbf{x}')}$$

$$\mathbf{a}^\top M \mathbf{a} = \sum_{i,j} a_i M_{ij} a_j$$

- これはユークリッド距離の一般化 (単位行列 $M = I$ の場合に相当)

【用語】 マンハッタンとはニューヨークの中心街のこと。2地点間を直線で移動できず、区画に沿って移動せざるを得ない様子になぞらえた名称。

【補足】 マハラノビス距離が実際に距離となる (距離の公理を満たす) には、重み行列が正定値対称 (positive definite) であることが必要十分である。半正定値 (positive semi-definite) であれば擬距離となり、実用上は擬距離となることを許すことが多い。


類似度と予測 > k-最近傍法 > 類似度関数

必ずしも数学的な距離関数でなければならないわけでもない

- k-最近傍法は「似ているデータ」の記録を取得して予測するという原理
 - 距離関数は、類似度 (similarity) を定量化するという気持ちで使われている
 - 距離の公理を完全には満たさずとも、類似度を表す関数ならば候補になる
- ベクトルの内積や、**コサイン類似度 (cosine similarity)** もよく用いられる

$$\langle a, b \rangle = a^\top b$$

$$\cos(a, b) = \frac{a^\top b}{\|a\| \cdot \|b\|}$$



類似度と予測 > k-最近傍法 > 実験 > 設定

2クラス分類をk-最近傍法で実行

タスク・学習戦略

2クラス分類・教師付き学習

特徴量	ラベル
x_1	y_1
x_2	y_2
$\vdots$	$\vdots$
$\{(X_i, Y_i)\}_{i=1}^n \stackrel{\text{i.i.d.}}{\sim} p$	

モデル


k-最近傍法

目的関数

なし

最適化手法

なし




訓練データ

- ハイパーパラメーターは以下
 - ▶ $k \in \{1, \dots, 10\}$ から選択
 - ▶ 距離関数は $\text{dist}_{\text{Euclid}}$
- モデル選択規準は、置き置き法による検証誤分類率を使用

類似度と予測 > k-最近傍法 > 実験 > 学習過程


検証誤分類率をモデル選択規準として、ハイパーパラメーター k を選択




$k = 6$ が選択

類似度と予測 > k-最近傍法 > 実験 > 結果

学習後のモデルの様子（評価データでの誤分類率は4%）



訓練データとk-NNの決定領域



評価用データでの予測と正解ラベル

類似度と予測 > まとめ



今回は「似ているデータ」を参照する事例ベースモデルの話をしました

- 予測における最有力な手がかりの一つは「近くのデータ」
 - 近くのデータは最も参考になる
 - もちろんこれに限るわけではない
- この考えを素直に用いるのがk-最近傍法
 - 入力 x と最も類似している k 個の訓練標本を見て、そのラベルの集計で予測
 - 極限にシンプルな手法：kを決めて、距離を決めたら、あとはやることがない

類似度と予測 > k-最近傍法 > 誤分類率リスクとの関係

一見してk-NNは、誤分類率 R が小さい予測器を目指して設計されていない

■ しかし、誤分類率リスクと1-NNは、次のように関連する (K クラス分類)

- 仮定) 特徴量空間と特徴量分布が比較的緩い条件を満たす
- このとき、訓練標本の大きさを n として、1-NNの予測器を $\hat{f}_n(\mathbf{x})$ と表し、ベイズ予測器を $f^*(\mathbf{x}) = \arg \max_k p(y = k | \mathbf{x})$ とすると、

$$\underbrace{R(f^*) \leq \lim_{n \rightarrow \infty} R(\hat{f}_n)}_{1\text{-NN}} \leq R(f^*) \cdot \left(2 - \frac{K}{K-1} R(f^*) \right) \leq 2R(f^*)$$


■ つまり、1-NN分類器の誤分類率は、データが増えていくと、 $2R(f^*)$ 以内に収まる

【参考】 Cover, T., & Hart, P. (1967). Nearest neighbor pattern classification. IEEE Transactions on Information Theory, 13(1), 21–27. IEEE Transactions on Information Theory. 【補足】 記号の上では明示的には書いていないが、 $\hat{f}_n$ は訓練標本から決まるので、それ自体が確率変数である。

類似度と予測 > k-最近傍法 > 計算コスト

近似最近傍探索 (approximate nearest neighbor search) も実用上は重要

- k-NNでは、 x が入力される毎に、最も近い訓練データを k 個見つける必要がある
 - 最悪の場合の推論コストは $\mathcal{O}(n \cdot d)$ となって、 n や d が大きいと非常に遅い
 - n の増加によって推論時間が直線的に増える



- 近似最近傍探索 (approximate nearest neighbor search)
 - 本当の k-最近傍点ではないかもしれないが、高速に取得できる近似的手法
 - 様々な手法がある (まずデータの大きな集団単位で粗く探索するなど)