

カーネル法

カーネル法



事例ベースでもありパラメーターも持っている，カーネル法を解説

- 事例ベースでもあり，パラメーター線型モデルでもあり，両方の特性を併せ持つ
 - パラメーターを持つ事例ベースモデルともいえる
- 類似度関数を使うが，訓練データに1つずつ可変なパラメーターを持たせる

カーネル法 > カーネル線型モデル

特徴量変換 ϕ の設計に訓練入力標本 $\{\mathbf{x}_i\}_{i=1}^n$ を用いる特殊な線型モデル

- 訓練入力標本 $\{\mathbf{x}_i\}_{i=1}^n$ が与えられたとき、特徴量変換を次のように定義する

$$\phi(\cdot) := \begin{bmatrix} K(\cdot, \mathbf{x}_1) \\ K(\cdot, \mathbf{x}_2) \\ \vdots \\ K(\cdot, \mathbf{x}_n) \end{bmatrix}$$


- この特徴量変換を用いて構成する線型モデルを、**カーネル線型モデル**という

$$f_{\theta}(\mathbf{x}) = \sum_{j=1}^n \theta_j K(\mathbf{x}, \mathbf{x}_j)$$

カーネル法 > カーネル線型モデル

モデルの構造

- カーネル関数 $K(x, x')$ は, x と x' の類似度を測る関数
 - データ点ごとに置いたパラメーターの値を, 類似度で重み付けて足す




$$\begin{array}{c} K(x, x_1) \cdot \theta_1 \\ K(x, x_2) \cdot \theta_2 \\ \vdots \\ K(x, x_n) \cdot \theta_n \end{array} \rightarrow f_{\theta}(x) = \sum_{j=1}^n \theta_j K(x, x_j)$$

カーネル法＞カーネル関数＞ガウスカーネル

ガウス関数を各訓練入力標本の場所に配置し，重み付き和で関数を表現

$$f_{\theta}(x) = \sum_{j=1}^n \theta_j \exp \left(-\frac{\|x - x_j\|^2}{2h^2} \right)$$



【実験ソースコード】[番号]_gaussian_kernel.ipynb 【補足】 $h > 0$ はバンド幅（bandwidth）とよばれるハイパーパラメーター。モデル選択規準で選ぶこともあるが，median heuristic や Silverman rule といった rule-of-thumb（親指ルール，ざっくりした指針のこと）が知られており，これらで選ぶこともある。


カーネル法＞性質

事例ベースモデルと、パラメーター線型モデルの、両方の性質を持つ

- 訓練標本を覚えておいて、入力 x との類似度を計算するために使う
 - データ自体に語らせるという点で、事例ベースモデルの性質を受け継いでいる

$$\left[K(\cdot, x_1), K(\cdot, x_2), \dots \right]$$

- パラメーターについては線型
 - 最適化などは、線型モデルの性質を受け継いでいる（解の公式や凸性など）



【補足】パラメーター数が訓練標本数に合わせて増えていくため、通常の線型モデルとは理論的な性質が異なり、ノンパラメトリックモデルの一種とみなされる。カーネル法の理論的背景として、再生核ヒルベルト空間（Reproducing kernel Hilbert space, RKHS）の完成度の高い数学的理論がある。

カーネル法＞表現定理



もう一段深い内容がある

- 実はこれまでの線型モデルも、学習結果の関数を適当なカーネルを用いて表せる
 - 線型モデルの場合、学習済みモデルは、密かに類似度ベースにもなっている

カーネル法＞表現定理

表現定理 (representer theorem) という定理がある

- 次の形の線型モデルを考える (ψ は r 次元の特徴抽出器とする)

$$f_{\boldsymbol{\eta}}(\cdot) = \langle \boldsymbol{\eta}, \psi(\cdot) \rangle$$

- 学習に使う目的関数は次の形で、最小化の解は $\hat{\boldsymbol{\eta}}$ であるとする

$$L(\boldsymbol{\eta}) = \sum_{i=1}^n \ell(y_i, f_{\boldsymbol{\eta}}(\mathbf{x}_i)) + \Omega(\|\boldsymbol{\eta}\|_2)$$

- 但し, Ω は狭義単調増加とする. つまり, 正則化項無しの場合は考えない.

カーネル法＞表現定理

表現定理（representer theorem）という定理から，次のことがいえる

■ 表現定理（representer theorem）の系

- 訓練済みモデル $f_{\hat{\eta}}(\cdot) = \langle \hat{\eta}, \psi(\cdot) \rangle$ は，何らかの $\{\hat{\theta}_i\}_{i=1}^n$ を用いて，次で表せる

$$f_{\hat{\eta}}(\cdot) = \sum_{i=1}^n \hat{\theta}_i \langle \psi(\cdot), \psi(\mathbf{x}_i) \rangle$$

- これは， $K(\mathbf{x}, \mathbf{x}') := \langle \psi(\mathbf{x}), \psi(\mathbf{x}') \rangle$ とおけば，カーネル線型モデルの形！

- つまり特徴量 $\psi(\mathbf{x})$ の代わりに，特徴量 $\phi(\mathbf{x}) = \begin{bmatrix} K(\mathbf{x}, \mathbf{x}_1) \\ \vdots \\ K(\mathbf{x}, \mathbf{x}_n) \end{bmatrix}$ をいつ使っても問題ない

【補足】 $\{\psi(\mathbf{x}_j)\}_{j=1}^r$ を $\mathbb{R}^r$ の基底となるようにとることができるという仮定を前提している。概要は以上の通りだが，内容を正確に述べるには関数解析という数学の分野の基本的な理解が必要になる。 【参考】 定理3.1. 福水健次. (2010). カーネル法入門—正定値カーネルによるデータ解析. 朝倉書店.

カーネル法 > 表現定理 > 意味

前ページの内容は何を言っているか？

- 訓練済みの線型モデルのパラメーターには，訓練標本の情報が含まれている

$$\hat{\eta} \quad \{(\mathbf{x}_i, y_i)\}_{i=1}^n$$

- 表現定理から，これについて少し詳しく分かる
 - $\hat{\eta}$ は，訓練事例ごとに1つずつパラメーターがあったかのように解釈できる
- 逆に，最初から訓練事例ごとにパラメーターを与えても差し支えないといえる

$$f_{\hat{\eta}}(\mathbf{x}) = \langle \hat{\eta}, \psi(\mathbf{x}) \rangle \quad \longleftrightarrow \quad f_{\hat{\theta}}(\mathbf{x}) = \sum_{j=1}^n \hat{\theta}_j K(\mathbf{x}, \mathbf{x}_j) \quad (K(\mathbf{x}, \mathbf{x}') := \langle \psi(\mathbf{x}), \psi(\mathbf{x}') \rangle)$$

カーネル法＞表現定理＞カーネルトリック

超高次元の特徴量の代わりに，対応する K でカーネル法を使うことができる

- 特徴量の次元が高いとき，超高次元のパラメーターを学習で決める代わりに，訓練データを覚えておいて，カーネル線型モデルのパラメーターを学習しても良い

- 高次元特徴量の例

- x が d 次元， $\psi(x)$ が s 次多項式特徴量のとき， $\psi(x)$ は $_{d+s}C_s$ 次元になる

- なぜ嬉しいのか？

- $\psi(x)$ は超高次元でも， $K(x, x') := \langle \psi(x), \psi(x') \rangle$ は容易に計算できる例がある

【補足】 多項式特徴量が $_{d+s}C_s$ 次元になるのは， s 個の「○」の並びに d 本の仕切り「|」を入れる（それにより $d+1$ 個に区切る）方法の数と同じため。

カーネル法＞表現定理＞利用

$\psi(x)$ は超高次元でも、 $K(x, x') := \langle \psi(x), \psi(x') \rangle$ は容易に計算できる例

■ x は d 次元、 $\psi(x)$ が s 次多項式特徴量

- 例えば、 $d = 2$, $s = 3$ なら、 $\psi(x) = (1, x_1, x_2, x_1^2, \sqrt{2}x_1x_2, x_2^2)$ は6次元の特徴量
- 対応するカーネルは $K(x, x') := \langle \psi(x), \psi(x') \rangle = 1 + \langle x, x' \rangle + \langle x, x' \rangle^2$ で、2次元の内積により計算可能

■ 比較

- モデル $f_\eta(x) = \eta^\top \psi(x)$ では、6次元ベクトルの内積計算になる
- モデル $f_\theta(x) = \theta^\top \phi(x) = \sum_{i=1}^n \theta_i K(x, x_i)$ では、2次元ベクトルの内積計算で済む

カーネル法＞カーネル化

線型モデルを使う手法の多くでは、カーネル法を「上乗せ」できる

- 訓練事例との類似度を特徴量化して、線型モデルとして使えばよいだけ
 - 「カーネルロジスティック回帰」などのように、「カーネル版」が多く存在
- $\psi(x)$ を考えずに、はじめから $K(x, x')$ を定義しても問題ない
 - 巧みな特徴量を考えるのは難しくても「類似度」の定義なら容易な場合がある

【補足】正式にカーネル関数として使える K には条件がある。正定値カーネル (positive definite kernel) とは、任意の $\{x_i\}_{i=1}^n$ と $\{\alpha_i\}_{i=1}^n$ に対して、 $\sum_i \sum_j \alpha_i K(x_i, x_j) \alpha_j \geq 0$ となること。これは、等号が含まれているので数学的には半正定値性と呼ばれる性質だが、そこを気にせず正定値カーネルと呼ぶことが多い。

【用語】線型モデルに基づく手法の、カーネル法によるバージョンを考えることを、カーネル化する (kernelize) ということがある。

カーネル法＞まとめ



今回は、事例との類似度ベース、かつパラメーターの学習を伴うモデルを解説

- カーネル関数という類似度関数を定義すれば使える
- 1990年代から盛んに研究され、現在も使われる
 - 線型モデルなので、これまでと同様、解を求めやすい（学習させやすい）
 - しかし訓練データが増えると表現力が上がっていく
- 機械学習の随所で、取り回しやすい道具として使われている

ロードマップ

