

大規模モデルと記憶と予測

大規模モデルと記憶と予測



予測の手掛かりとなる近さや類似度の概念を説明した

- その中で，次のようなキーワードが出てきた

距離 類似度

事例ベースモデル k-最近傍法 カーネル法

- これは，近年の超大規模パラメーターのモデルと関連がある

これまでのあらすじ

- 最初は、統計的な考え方に基づく予測タスクのための学習を説明してきた
 - モデルはブラックボックスとして扱った（モデルの仕組みは問わない）
 - モデルは関数近似器でもある
- 次に、予測の手掛かりとして有力なものの一つである近さの概念を説明した
 - 予測時にデータが入力されたとき、最も参考になるのは、近い訓練データの事例だろうという信念（事前知識）

記憶と予測

次の2つの側面の、両極端のモデルを見てきた

- 全体に共通する法則性・規則性を見出して使う
 - 低次多項式などのモデルでは、訓練事例を記憶できるほどの複雑さがない
 - 代わりに、綺麗な規則性があれば、事例の無いゾーンでも汎化しやすい
- あからさまに事例を覚えておいて類似性を使う
 - k-NNやカーネル法などのモデルは、法則ではなくデータに委ねている
 - つまり、ほぼ丸暗記（カーネル法は、ある意味で両方のいいところり）


記憶と予測

次の2つの側面の、両極端のモデルを見てきた

全体に共通する法則性・規則性

単純な法則があれば汎化しやすい


例) 低次多項式など



事例を暗記し、類似事例の情報を引き出す

近い事例があれば汎化しやすい



例) K-NNやカーネル法など



記憶と予測＞大規模モデル

近年の画像やテキストを扱うタスクのモデルは大規模化が進んでいる


- 近年の高性能とされるモデルは、パラメーター数がかなり多い
 - なんなら、データの個数よりもパラメーターが遥かに多いこともある



記憶と予測＞大規模モデル＞過適合の謎

旧来の理解からすると、パラメーターが多すぎると過適合しやすいはず

- 多項式モデルのイメージで言えば、過適合しそうに思える
 - 自由度が高いと訓練データ上だけで適合しても辻褄を合わせられてしまう




- 過剰パラメーター化 (overparametrization)
 - モデルのパラメータ数が訓練サンプル数を**大幅に**上回っている状態のこと
 - 近年のニューラルネットはこうなっている。なぜ上手くいく場合があるのか？

記憶と予測＞大規模モデル＞過適合の謎

では、なぜ近年の大規模モデルは汎化し得るのか？

- データを暗記できるからといって、必ず過適合するわけではない
 - 事例ベースモデルがあることから明らか



- 古典的な知恵は、「データを暗記できない程度の自由度しか持たないモデルは、過適合し得ない」というだけのこと
 - 大自由度だが汎化する手法が存在することは十分にあり得る

記憶と予測 > 大規模モデル

パラメーターが極端に多いモデルでは、2つの側面が共存していると思われる

小さいモデル

記憶できる容量はない
法則が頼り

例) 低次多項式モデル

巨大なモデル


法則も記憶も共存？

例) 大規模なニューラルネット

事例ベースモデル

全体的な法則は見ない
訓練データが頼り

例) k-NN



【補足】 ここでいうモデルの大きさは、パラメーターの個数のこと。なお、なぜ汎化するのかを余すことなく説明する理論はまだ確立されていない。

記憶と予測＞大規模モデル




大規模ニューラルネットがなぜ汎化するのか，決定版の理論はまだない

- なぜ汎化するのかを余すことなく説明する理論はまだ確立されていない
 - そもそもアーキテクチャーが強力な事前知識だが，それを考慮しても汎化できすぎている（と思われる）
- ニューラルネットの損失地形が関係しているという説もある
 - 過剰パラメーター化されていると，損失地形に「広い盆地」が発生
 - 盆地はパラメーターが多少変化しても損失の変化が小さいような場所
 - 多少変わっても大勢に影響がないということは，パラメーターが含む情報量が少なめであり，タスクにとって本質的な法則を捉えている可能性がある


記憶と予測＞大規模モデル＞最適化の謎

旧来の理解からすると，階層的なモデルの最適化は難しいはず

- 勾配法での最適化は，局所解に陥る場合がある
 - 特に，より低い位置に行くために，一旦昇らなくてはならない形状のとき




- 勾配法は現在地の局所的な情報で移動するので，遠くの情報は見えていない



記憶と予測＞大規模モデル＞最適化の謎

旧来の理解からすると，階層的なモデルの最適化は難しいはず

- 階層的なモデルでは局所解が多くなりやすと考えられてきた




記憶と予測＞大規模モデル＞最適化への恩恵

過剰パラメーター化は，最適化において有利になる面があると考えられている

- パラメーターが少なめな階層モデルでは，確かに障壁だらけな構造かもしれない




- 超高次元では逆に，移動可能な方向が多くなり，障壁を回り道しやすくなる




記憶と予測 > 大規模モデル > 最適化への恩恵

超高次元では、勾配法が局所解に捕まるというイメージを超えた動きをする

- 損失曲面を転がり落ちていくかと思いきや……



- 実際は、超高次元なので、真下にめり込んでいくような動きをする



【参考】 Li et al. (2018). Visualizing the loss landscape of neural nets. Advances in Neural Information Processing Systems, 31.

【補足】 実験ソースコードを開くと動画で見ることができる。 【実験ソースコード】 [番号]_loss_landscape.ipynb

大規模モデルと記憶と予測＞まとめ



近年，大規模なモデルが高性能を発揮するという知見が蓄積されて急速に発展

- 汎化の理論は未完成
 - 事例の暗記もできるが，過適合するとは限らない（cf. 事例ベースモデル）
 - 明確な記憶にも，厳密な法則にも依らず，両者が曖昧に融合した仕組みか？
- 最適化の描像も解明が進められている
 - 高次元なので直観がアテにならない
 - どうやら良い解に辿り着きやすい構造があるらしいと考えられている（良解の占有体積が大きい，回り道で必ず良解に行ける，など）
- なぜ上手くいくのか，完全な全体像は解明されていない