



学習の障壁② 次元の呪い

次元の呪い



データの次元が高いほど，学習は難しくなる



- 一般に，高次元のデータ処理では，様々な形で支障が出てくることが知られる
 - この現象は次元の呪いと呼ばれる
- 特に学習においては，類似度や距離があてにならなくなっていく
 - 今回は，距離に関連した高次元現象を説明

次元の呪い



高次元データでは、普通の直観から外れた現象が色々と起き始める

- 高次元は基本的にスカスカ




- だがそれだけでなく、我々が持っている幾何学的な直観から外れた現象が起きる

基本知識の確認＞球と球面


d 次元空間における球と球面

- 球 (ball) とは, 長さが半径 r 以内の点の集合



- 球の体積は, d から決まる係数 a_d を用いて $V(r) = a_d \cdot r^d$

- 球面 (sphere) とは, 球の表面であり, 長さが半径 r ちょうどの点の集合




【用語】高次元 ($d \geq 4$) の場合は, それぞれ超球 (hyperball) や超球面 (hypersphere) ともいう. 2次元の場合は, それぞれ円板 (disc) や円周 (circle) という. 【補足】例えば, 2次元の場合, 円の面積は πr^2 .

次元の呪い > 高次元で起きる現象 > 球面集中現象

高次元の球は、体積のほとんどが、表面の薄い殻の部分にある

■ 高次元球の体積

- 高次元の球は、体積のほとんどが、表面の薄い殻の部分にある
- $\therefore$) 半径 r の d 次元球の体積は $V(r) = a_d r^d$ なので、厚さ s の外殻の体積は、


$$\text{Shell} = \text{Sphere}(r) - \text{Sphere}(r-s) = a_d \cdot r^d \cdot \left(1 - \left(1 - \frac{s}{r}\right)^d\right) \simeq a_d \cdot r^d = V(r)$$

【参考】 Hall, P., Marron, J. S., & Neeman, A. (2005). Geometric representation of high dimension, low sample size data. *Journal of the Royal Statistical Society Series B: Statistical Methodology*, 67(3), 427–444.

【参考】 3.3.3項 of Vershynin, R. (2018). *High-Dimensional Probability: An Introduction with Applications in Data Science*. Cambridge University Press.

次元の呪い > 高次元で起きる現象 > 球面集中現象



結果として、適当に点をばら撒くと、ほとんどが球面近くに集中する

■ 球面集中現象 (concentration on the sphere)

- 例えば d 次元の正規分布 $\mathcal{N}(0, I_d)$ は、 d 次元球の表面の一様分布に酷似

$$\|X\|_2 \sim \sqrt{d}$$

体積はほとんど
表面部分にあるので
分布も表面に集中



こうして内部に
分布する訳ではない

【参考】 Lemma 3.2.4 of Vershynin, R. (2018). High-Dimensional Probability: An Introduction with Applications in Data Science. Cambridge University Press.


【補足】 正確には例えば、 X が d 次元の等方的分布のとき、 $\mathbb{E}\|X\|_2^2 = d$ が成立。

【参考】 3.3.3項 of Vershynin, R. (2018). High-Dimensional Probability: An Introduction with Applications in Data Science. Cambridge University Press.


次元の呪い > 高次元で起きる現象 > 球面集中現象

結果として、適当に点をばら撒くと、ほとんどが球面近くに集中する

- 低次元では中心の近くに分布，高次元では中心の近くにはほとんど分布しない



中心



中心

次元の呪い > 高次元で起きる現象 > 距離の均質化

高次元空間では、適当に点をばら撒くと、「2点間の距離」は一様に遠い

- 高次元空間では、どの点も遠くに見える（近い点というものがなくなる）

$$\|X - Y\|_2 \sim \sqrt{2d}$$



- 空間が有り余っているため

【参考】 Exercise 3.2.6 of Vershynin, R. (2018). High-Dimensional Probability: An Introduction with Applications in Data Science. Cambridge University Press.


【補足】 正確には例えば、 X と Y が独立な期待値 0 の d 次元の等方的分布のとき、 $\mathbb{E}\|X - Y\|_2^2 = 2d$. 【参考】 Hall, P., Marron, J. S., & Neeman, A. (2005). Geometric representation of high dimension, low sample size data. Journal of the Royal Statistical Society Series B: Statistical Methodology, 67(3), 427–444.

次元の呪い > 高次元で起きる現象 > 直交

高次元空間では、適当に点をばら撒くと「2点のなす角」は、ほとんど直角


- 位置ベクトルのなす角

$$\cos(x, y) = \frac{\langle x, y \rangle}{\|x\| \cdot \|y\|}$$



- 高次元空間では、ランダムに2つのベクトルを配置すると、ほぼ直交する

$$\cos(X, Y) \sim \frac{1}{\sqrt{d}}$$







- 空間が有り余っているため

【参考】 Hall, P., Marron, J. S., & Neeman, A. (2005). Geometric representation of high dimension, low sample size data. *Journal of the Royal Statistical Society Series B: Statistical Methodology*, 67(3), 427–444. 【補足】 正確には例えば、 X と Y が独立な d 次元の等方的分布のとき、 $\mathbb{E}\langle X, Y \rangle^2 = d$ が成立。 【参考】 Remark 3.2.5 of Vershynin, R. (2018). *High-Dimensional Probability: An Introduction with Applications in Data Science*. Cambridge University Press.

次元の呪い (Curse of Dimensionality)

高次元データでの学習は難しい


- 次元の呪い (the curse of dimensionality)
 - 高次元性に由来する (不思議な) 現象により, 学習に困難をきたすこと
 - 学習に限らず, 最適化や数値計算においても, 色々な形で「呪い」が現れる



次元の呪い > 距離・類似度ベースの学習への影響

「距離」が頼りな学習手法の基本性能は、高次元ほど低下する

- 膨大なデータがあれば、高次元空間も埋まってゆくので、この限りではない
 - しかし、高性能に到達するのに必要なサンプル数は次元に対して急増



- 例) 任意の学習アルゴリズムに対し、あるデータ分布が存在して、データが $n < 2^d$ ならば誤分類率が $1/4$ 以上、という悲観的な定理などがある


【補足】 正確には、特徴量空間を $[0,1]^d$ とする2クラス分類で、任意の $c > 1$ と任意の学習アルゴリズムに対し、 c -Lipschitzな $p(y = 1 | \mathbf{x})$ を持つ分布 p が存在して、ベイズ分類器の誤分類率は0でありながら、 $n < (c + 1)^d / 2$ の任意のサンプルサイズでは誤分類率が $1/4$ 以上となる。という主張などが示される。 c -Lipschitzというのは、近さが役に立ちやすい分布というものの定式化の一つだが、そういった条件のもとでも都合の悪い分布が存在するということがポイント。

【参考】 Theorem 19.4 of Shalev-Shwartz, S., & Ben-David, S. (2014). Understanding Machine Learning: From Theory to Algorithms. Cambridge University Press.

次元の呪い > 対策

考えられる対策の方向性は「意味のある低次元構造」を探して利用すること

- 見かけ上は高次元でも、本質的には低次元のなら希望はある
 - 例) 上手くすれば低次元表現が可能な場合



← 3次元空間に埋め込まれた2次元空間
曲面上の位置は2次元情報で指定できる



- 極端な話, 例えば (x, y, z) というデータでも, $(x, y, z, 0, 0, \dots, 0)$ と無駄に埋めれば, 見かけ上は何次元にもなる

【実験ソースコード】 [番号]_curse_of_dimensionality.ipynb

【補足】 隠れた低次元的構造だけが唯一の希望ではない. 何があれば次元の呪いから抜け出せるのかは探究の余地がある.

次元の呪い > 対策 > イメージ

とある100次元のデータでk-最近傍分類を行った結果




$$\mathbf{x} = (x_1, x_2, \dots, x_{100})$$

k-最近傍分類の結果（誤分類率）


次元の呪い > 対策 > イメージ

特徴量の最初の2次元だけで距離を測ってk-最近傍分類を行った結果



$$\mathbf{x} = (x_1, x_2, \dots, x_{100})$$

そのままのデータで
k-最近傍分類を行った結果



$$\mathbf{x} = (x_1, x_2)$$

特徴量の100次元のうち
最初の2次元だけを使った場合

次元の呪い > 対策 > イメージ > 種明かし

実は、本来は2次元の特徴量に、自分で作った98個のノイズを付けていた

- 本来2次元のデータの後ろに、98次元の正規分布に従うノイズを付けて、見かけ上だけ100次元になるようにしたものだった
 - そのため、データを2次元に減らしても全く問題なかった

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_{100} \end{pmatrix} \left. \vphantom{\begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_{100} \end{pmatrix}} \right\} \text{noise} \quad \rightarrow \quad \mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$$

- 本来、最初の2次元だけ見て類似度を測るのが正解なデータだったということ
 - ポイント：データの見かけの次元が高次元で全然性能が出なくても、本質的情報だけ使えば、うまくいくかもしれない

次元の呪い > まとめ



高次元空間ならではの直観に反する現象と，高次元での学習の困難を説明した

■ 高次元現象

- 高次元球の体積は，外殻の近くがほとんどを占める
- 適当にばら撒いた点では，距離は一様に遠く，なす角は直角に近くなる

■ 次元の呪い

- 高次元では距離が形骸化しがち
- 高次元は困難だが，低次元構造に希望がある