


類似度と表現学習（学習戦略②）

類似度と表現 > 表現学習 > 学習戦略



どのように類似度計算のためのベクトル表現を学習するか

- 基本の考え方：似たものは近く，異なるものは遠くなるように表現を学習




- 学習戦略（どのようなデータから学習するか）はいくつか選択肢がある
 - 分類ラベルからの教師付き学習
 - 類似性・非類似性ラベルからの教師付き学習
 - ラベル無しデータからの教師無し学習・自己教師付き学習


類似度と表現 > 表現学習 > 学習戦略②



「類似性・非類似性」を表すラベルを収集して教師付き学習

■ 類似性・非類似性ラベル $s \in \{0,1\}$ からの教師付き学習

- (x, x') という異なる入力組と、ラベル s (類似なら 1, 非類似なら 0) を収集

(, , 0)

(, , 1)

(, , 1)

(x, x', s)

【補足】類似性は「 x と x' が同じクラスに属する」として分類ラベルから定める場合もあるが、もっと一般に「意味的に近いかな否か」で考えることもある。もちろんそれでは曖昧すぎるように思える場合もあるが、データの生成分布 $p(x, x', s)$ を考えてしまえば何であれ差し支えないことがわかる。

類似度と表現 > 表現学習 > 学習戦略②

類似性・非類似性のラベルは収集が容易で、データ量を増やしやすい

- 「同じクラスか否か」という2値でのラベル付けは、クラスラベル収集と比べて比較的少ない労力で可能なことがある



- さらに、**自己教師付き学習 (self-supervised learning)** という学習戦略も可能
 - 類似性・非類似性ラベルに相当するものを、データ自身から「作成」する（擬似ラベル, pseudo label という）

【用語】 自己教師付き学習は、ラベルなしデータから学習する戦略なので教師なし学習の一種にほかならないが、入力データからラベル相当の情報を作成するという特色あるアプローチを指してこのように呼ばれている。

類似度と表現 > 表現学習 > 学習戦略②


自己教師付き学習の具体的な方法

■ 対照学習 (contrastive learning) : 同一データ内と他データとの対比から学習

- 同じ1つの x_i から, 複数のデータを作製し, これを正例 (類似ペア) と定める



- 負例は, ミニバッチ内の他のデータとの全てのペアを考えて負例とみなす




【補足】 実は類似したデータが同じミニバッチに入っている可能性も当然あり, それは負例ということにして学習されてしまうが, バッチサイズがそれなりに大きめであれば大抵問題ないだろうという考えで許容することが多い.

類似度と表現 > 表現学習 > 学習戦略②

cos類似度を並べて，正例ペア vs. 多数の負例ペア の多クラス分類で学習


- 作製されたデータ同士でコサイン類似度を計算



- これを，まず作製されたデータの全通りについて計算する

類似度と表現 > 表現学習 > 学習戦略②

続いて、多クラスの確率論的分類かのごとく、ソフトマックスに代入



【補足】 多クラス分類と同じ学習法だが、クラス数が必ずしも一定ではなく、ミニバッチ内の他サンプルとの対比での学習となっている。


類似度と表現 > 表現学習 > 学習戦略②

その負の対数尤度を損失として，多クラス確率論的分類かのごとく学習

- 正例ペアの作製データ1つあたりの損失値 ($\mathbf{x}_i^{(2)}$ を中心にした $L_i^{(2)}$ も同様)

$$L_i^{(1)} = -\log \frac{\exp[\text{sim}_\eta(\mathbf{x}_i^{(1)}, \mathbf{x}_i^{(2)})]}{\exp[\text{sim}_\eta(\mathbf{x}_i^{(1)}, \mathbf{x}_i^{(2)})] + \sum_{j \in B \setminus \{i\}} \sum_{v=1,2} \exp[\text{sim}_\eta(\mathbf{x}_i^{(1)}, \mathbf{x}_j^{(v)})]}$$

- 実際はこれをミニバッチの各データについて計算し，和をとる



類似度と表現 > 表現学習 > 学習戦略②

さらに実際は、ソフトマックスに温度パラメーターを付けたものが使われる

■ Cos類似度は値の範囲が $[-1,1]$ に限られている

- それゆえ、正例に対応する値を相対的に大きくしたくても限界がある

$$\text{Softmax}(\underbrace{1, -1, \dots, -1}_K)[1] = \frac{e}{e + Ke^{-1}}$$

→ $K = 10$ 程度でも、 $\text{Softmax}(\underbrace{1, -1, \dots, -1}_{10}) = (0.42, 0.058, \dots, 0.058)^\top$ となる.


■ そこで、ソフトマックスに温度 (temperature) パラメーターというものを導入

温度パラメーター付きソフトマックス関数

ソフトマックスに**温度パラメーター (temperature)** を導入する場合がある

$$\text{Softmax}_T(\mathbf{z}) = \left(\frac{\exp\left(\frac{z_j}{T}\right)}{\sum_{k=1}^C \exp\left(\frac{z_k}{T}\right)} \right)_{j=1,\dots,C}$$

- $T (> 0)$ を変えると、出力される確率値ベクトルの「鋭さ」を調整できる



類似度と表現 > まとめ




類似度関数を学習する手法を解説しました

- 「顔認証」や「類似商品検索」を，通常のカテゴリタスクの枠組みで解こうとすると未知クラスの取り扱い，動的なクラス追加という複雑さに直面
- いずれも，類似度学習が真価を発揮するタスク
- 類似度学習には色々な方法が提案されているが，基本は次の形で表現学習

$$\text{sim} \left(\phi_{\eta}(x), \phi_{\eta}(x') \right)$$


- 教師付きでの学習法もあれば，（対照学習など）教師なしの学習法もある

ロードマップ




講義全体の構成

第Ⅰ部



機械学習の仕組み

第Ⅱ部



応用領域の案内

第Ⅲ部



発展編