


自然言語処理 (Natural Language Processing)


自然言語処理 (Natural Language Processing)

機械に「人間の言語を使う」能力を獲得させる

- 人間の言語を自動処理したり，生成したりする



自然言語理解




自然言語生成

- 人間の言語系が実行できるタスクを自動化し，さらには人間とのインターフェース基盤とすることが目標

自然言語処理＞データの取得方法

テキスト情報は、キーボード等を使って入力することでデータにできる

- キーボードは多くのコンピューターに標準搭載
 - 他にも、タッチパネル上のソフトウェアキーボードや、音声入力などが発達



自然言語処理 > テキストデータ

テキストデータは文字番号の羅列

- コンピューターの中では、1つ1つの文字に番号が振られている
 - その対応表や個々の番号を文字コード（character code）という

@	A	B	C	...
40	41	42	43	...

- コンピューターの中では、テキストは文字コードの列

"To be, or not to be,
that is the question."

→
['84', '111', '32', '98', '101', '44', '32', '111', '114', '32', '110',
'111', '116', '32', '116', '111', '32', '98', '101', '44', '32', '116',
'104', '97', '116', '32', '105', '115', '32', '116', '104', '101',
'32', '113', '117', '101', '115', '116', '105', '111', '110', '46']

自然言語処理＞テキストデータ



テキストデータ処理は，この文字コードを使って計算するのか？


- いや，そういうわけではない
- 文字化けが起きる仕組みなどの理解のために知っておいたほうが良いが，実際に処理をする中で，文字コードを使って計算を行う場面はまずない
- 実際には，文字単位で処理するのは稀で，単語など大きな単位で扱う

自然言語処理＞テキストデータ



テキストデータには階層性がある

- 言語における意味の基本単位は「語」 (word)
 - 語を並べた文 (sentence) によって, 「何がどうした」という情報が表現
 - ▶ 更に, 文を複数使って作られた文章によって, 意見や情報がやり取りされる



自然言語処理＞基本タスク

言語における意味の基本単位は語（word）

- 文字列を単語に分割するタスクを**単語分割（word segmentation）**という

“To be or not to be, ……” → [“To”, “be”, “or”, “not”, “to”, “be”, ……]

「吾輩は猫である。……」 → [“吾輩”, “は”, “猫”, “で”, “ある”, “。”, ……]

- まずは、テキストがどのような語で構成されているかを明らかにすることから
 - 日本語や中国語などでは、語の区切りを見つけることが必要
 - 英語などでは、空白文字で区切られたものを語であると考えればよい

【用語】 また、単語間に空白を入れて区切ることを「分かち書き」という。分かち書きは、単語分割の類義語として用いられることもある。

【補足】 日本語をはじめ、単語分割そのものは難しいタスクだが、現在は既に十分に解決されたタスクと言ってよいだろう。優れたツールがある。


自然言語処理＞基本タスク＞トークン化

現在は「トークン」というものが基本単位として扱われることも多い

- 一般には、辞書に載っているような「単語」だけでなく、記号など特殊な文字の並びも「単語」のように役割・意味を持つ
- そこで、「単語」ではなく「トークン」という単位が使われる
- 文字列をトークン列に分割・変換する処理を**トークン化 (tokenization)** という
 - 単語より細かい単位（サブワード）が出てくることもある

自然言語処理 > 基本タスク > 概観

自然言語処理において、機械学習は「応用への別ルート」になっている



【補足】ここに挙げたタスクは全てを網羅してはいない。

自然言語処理＞応用タスク




この講義では、応用タスクと、機械学習系のアプローチを重点的に解説

- 基本タスクも使いながら、これらの応用的なタスクが実用化されている
 - 文書分類
 - トピック分析
 - 情報抽出
 - 情報検索
 - 翻訳
 - 要約
 - 対話

自然言語処理＞応用タスク＞自然言語理解

文書分類タスク (document classification)

- テキスト1つを一つのクラスに分類



- 代表例となるタスク


- 感情分析, 迷惑メールフィルタ, ニュース分類など



自然言語処理＞応用タスク＞自然言語理解

系列ラベリングタスク (sequence labeling task)

- 入力の単語列に対して、それぞれにラベルを予測



- 代表例となるタスク
 - 品詞タグ付け (part-of-speech tagging, POS tagging)
 - 固有表現認識 (named entity recognition, NER)

【用語】 予測されるラベルが一定の構造を持っているともみなせるので、構造化予測 (structured prediction) の一種でもある。

【補足】 品詞タグ付けは、辞書的な単語分割から大きく異なるトークン化を行った場合は、タスクとしては考えづらくなる。

自然言語処理＞応用タスク＞自然言語理解

品詞タグ付け（part-of-speech tagging, POS tagging）

- 文を単語の系列としたうえで、その一単語ずつに品詞を求めるタスク
- 例)

6／月／27／日／、／ハル／は／国立／科学／
博物／館／の／展示／を／訪れ／た／。

6	月	27	日	、	ハル	は				
NUM	NOUN	NUM	NOUN	PUNCT	PROPN	ADP				
数詞	名詞	数詞	名詞	約物	固有名詞	助詞				
国立	科学	博物	館	の	展示	を	訪れ	た	。	
NOUN	NOUN	NOUN	NOUN	ADP	NOUN	ADP	VERB	AUX	PUNCT	
名詞	名詞	名詞	名詞	助詞	名詞	助詞	動詞	助動詞	約物	

【補足】 約物とは句読点や括弧，疑問符・感嘆符などの記号のこと。ADPここでは助詞としたが，一般には前置詞と後置詞を合わせた接置詞を指す。

自然言語処理＞応用タスク＞自然言語理解

固有表現認識 (named entity recognition, NER)

- 人名, 地名, 組織名, 日付などの「固有名詞・固有表現」を抽出するタスク
- 例)

6 / 月 / 27 / 日 / 、 / ハル / は / 国立 / 科学 / 博物 / 館 / の / 展示 / を / 訪れ / た / 。


6	月	27	日	、	ハル	は				
B-DATE	I-DATE	I-DATE	I-DATE	O	B-PERSON	O				
日付(始)	日付(続)	日付(続)	日付(続)		人名(始)					
国立	科学	博物	館	の	展示	を	訪れ	た	。	
B-FAC	I-FAC	I-FAC	I-FAC	O	O	O	O	O	O	
施設(始)	施設(中)	施設(中)	施設(中)							

【補足】 上記の形式はBIOフォーマットといい, B=Beginning, I=Inside, O=Outside を表す。

自然言語処理＞応用タスク

テキストの意味的類似度計算 (semantic textual similarity, STS)

- 二つのテキストの意味の類似度を予測するタスク



- 応用例

- 情報検索 (information retrieval)
- 質問応答 (question answering)

自然言語処理＞応用タスク

トピック分析 (topic analysis) , **トピックモデリング (topic modeling)**

- 文書集合から、単語等を手掛かりにしてトピックを定義して割り当てるタスク


文書集合

このレストランのパスタは美味しい。

新鮮な魚を使った寿司は最高だ。

昨日のサッカーの試合は盛り上がった。

彼は野球チームの熱心なファンだ。



トピックA

レストラン
パスタ
美味しい
⋮

トピックB

サッカー
試合
ファン
⋮

このレストラン…… トピックA

新鮮な魚を使っ…… トピックA


昨日のサッカー…… トピックB

彼は野球チーム…… トピックB

自然言語処理 > 応用タスク > 自然言語生成

続いて自然言語生成（natural language generation）タスク

- 無条件（unconditional）生成：特に条件なく「ありそうな文章」を生成する
- 条件付き生成（conditional）生成：何らかの他の情報を条件づけて生成する




【補足】 現在では、基本的に全てが条件付き生成である。無条件生成も、特殊なトークン <BOS> (beginning of sequence) を条件付けた生成で実現できる。

自然言語処理＞応用タスク

系列変換タスク (sequence-to-sequence, seq2seq)

- 条件付き生成の中でも、テキストを条件付けてテキスト生成するタスク



- 様々なタスクが、この種類のタスクとみなせる
 - 翻訳 (translation)
 - 対話 (dialogue)
 - 質問応答 (question answering)
 - 文書要約 (document summarization)

自然言語処理＞応用場面




こういったタスクは、様々な応用をもつ

- 自然言語理解
- 自然言語生成
- これらの基礎技術が、使い方によって幅広い応用につながっている

自然言語処理＞応用場面

機械翻訳 (machine translation)

- 情報へのアクセスが可能になったり，コミュニケーションが円滑になったり
 - 条件付き生成など



自然言語処理＞応用場面

テキストコンテンツのモデレーション（監視や削除）

- スпамメールの除去や、動画投稿サイトのコメント欄の荒らし防止など
 - テキスト分類（スパム分類）



自然言語処理＞応用場面

ソーシャルメディア分析


- 口コミの分析や、SNSの話題抽出などによって、マーケティングの成果を計測
 - テキスト分類（感情分析）、トピック分析、要約生成



自然言語処理＞応用場面

セマンティック検索 (semantic search)


- 意味的に近いキーワードでも文書の検索ができるようになって便利
 - 類似度学習に基づく情報検索



自然言語処理＞応用場面

テキストチャット・インターフェイス

- AIと「自然に会話する」形式で、情報や指示をやりとりできる
 - 条件付きテキスト生成（テキストを条件付けた生成）



自然言語処理＞応用場面

視覚障がいのある人の補助ツール

- スマホカメラで撮影をすると言語で解説
 - 条件付き生成（画像や動画を条件付けた生成）＋音声合成



自然言語処理＞応用場面

自律的なエージェント

- 超高品質なテキスト生成により，「計画を立てて行動を選択する自律的な存在」すなわち「エージェント」として振る舞わせることができる．また，行動の選択肢や使用方法もテキストで与えることにより，柔軟に拡張可能．
 - 条件付き生成（そこまでの生成テキストを条件付けた生成）



自然言語処理＞モデル



自然言語処理の学習では，テキストを入出力できるモデルが必要になる

- テキストデータを処理する上で，次の3つの考慮事項を順に解説していく
 - 1. どうやって単語（トークン）の区切りを決めるか／見つけるか？
 - 2. どうやって離散的なトークン（トークン番号）をモデルで扱うか？
 - 3. どうやってトークンの並びの系列をモデルで扱うか？