

トークン化

トークン化



現在は「単語」を単位として分割するとは限らない

- どうやって単語（トークン）の区切りを決めるか／見つけるか？

トークン化

テキストをトークン列に分解することをトークン化という

- トークン (token)

- 系列データの最小単位として使うものをトークンという
- 単語や、句読点、「's」のような文字列、ひいては絵文字やその他何でも

- トークン化 (tokenization)

- テキストを、適切に区切るなどして、トークンIDの系列に変換すること
- つまりトークン版の”単語分割”

トークン化＞トークナイザー

トークン化を実行するツールは、トークナイザーという

- テキストを受け取ると、トークンに分割し、そのIDの列を出力

「私はAIでデータを処理した。」

↓ 分割 ↓

「私は／AI／で／デ／ータ／を／処／理／した／。」

↓ Token IDに変換 ↓

158341／17527／4344／20951／124101／7277／158556／5584／23085／788

- トークナイザーは、ルールベースの場合も、学習される場合もある

トークン化>サブワード

上手くトークンを決定してトークン化できれば、レアな単語への対処にもなる

- 辞書にある単語の中でも、そのパーツが意味を持っている場合がある
 - 「言語」「言葉」「発言」「言論」は別々の単語だが、「言」が共通
 - 「extraordinary」=「extra」+「ordinary」（凡庸の向こう側＝非凡な）
- この構造を使わないのは勿体無い！
 - あらゆる単語について、その単語を含むデータを集めるのは大変
 - しかし「extraordinary」という単語の出現頻度が高くななくても、extra-をもつ単語とordinaryという単語がある文書からも学習が進むようになる

トークン化＞トークナイザー＞種類

実用的なトークナイザーは主に2種類に大別できる

- 形態素解析器（辞書的な単語を中心とするトークナイザー）
 - 形態素は意味を持つ最小単位の表現要素で，形態素解析は基本タスクの1つ
 - タスクはトークン化にとどまらないが，トークナイザーの役割も果たす
 - 日本語ではMeCab, Juman++, Kuromojiなどのライブラリがある
- サブワードトークナイザー（データから学習されるトークナイザー）
 - 大規模言語モデルなどでは，こちらが標準的になっている
 - BPE, WordPiece, Unigramなどのアルゴリズムがあり，Hugging Face TokenizersやSentencePieceといったライブラリで利用できる

【補足】以前のモデルでは形態素解析が主流だったが，近年のモデルでは，未知語に強く言語非依存なサブワードトークナイザーが標準的になっている。

トークン化＞トークナイザー

サブワードに基づくトークナイザーでは、未知語が発生しない


- 語彙（ボキャブラリー, vocabulary）
 - トークナイザーが出力しうる全てのトークンの集合のこと
- 辞書に基づくトークナイザーでは、語彙にない部分文字列などは未知語・未知トークン（unknown word/token）という扱いになる
 - 辞書作りが鍵になるが、辞書作りも大変
- 一方、サブワードトークナイザーでは、仕組み上、通常は未知語が発生しない
 - 最終的には1文字単位でもトークン化するため
 - 未知の文字などが出現した場合には発生する

トークン化＞トークナイザー



トークナイザーの内部の仕組みはこの講義では省略

- トークナイザーは，テキストを受け取ると，それをトークン列に変換するもの



- トークンとは単語のようなものだが，より柔軟で細かいサブワードも含まれる
- 目的によって，形態素解析器がトークナイザーとして使われたり，サブワードトークナイザーがデータから作られたりする