


生成タスクへの潜在変数型アプローチ

生成タスク > 潜在変数型の生成



潜在変数からの変数変換によるデータ生成

- 学習済みの生成器は、次のように「潜在変数」を入力すると画像を出力




- このような生成器を、どうやって作ればよいか？

生成タスク > アプローチ

アプローチ①：潜在変数からの変数変換によるデータ生成



- モデルによって変数変換 = 生成器 (generator) を学習するという方針



- 潜在変数の分布 $p(z)$ は既知のものを使い，簡単にサンプルもできる分布とする


- しかし，こういった目的関数で生成器を学習すればよいか？

【補足】 潜在変数の分布としては，例えば標準正規分布や，一様分布などが用いられる．潜在変数は単純な分布でも，複雑な生成器を学習すれば，複雑なデータ分布に対応できるわけである．

生成タスク > 潜在変数型の生成 > VAEs


潜在変数からの変数変換による生成モデル①

■ 変分オートエンコーダー (variational auto encoders, VAEs)




■ 生成器（この場合は復号化器と呼ばれる）に，2つのものを新設

- 左側のパート（エンコーダーという）




- 生成器の出力側に，正規分布を付け加えた




生成タスク > 潜在変数型の生成 > VAEs

変分オートエンコーダーの構造と学習方法

- エンコーダー（符号化器, **encoder**）は, x を受け取って, z の分布を出力




- 分布を出力とは例えば, モデルから多次元正規分布の平均と分散を出力するなど



生成タスク > 潜在変数型の生成 > VAEs

変分オートエンコーダーの構造と学習方法

- 生成器 g_θ の出力側に、正規分布を付け加える



$$p_\theta(\mathbf{x} \mid \mathbf{z}) := \mathcal{N}(g_\theta(\mathbf{z}), I)(\mathbf{x}) \propto e^{-\frac{1}{2}\|\mathbf{x} - g_\theta(\mathbf{z})\|^2}$$

- 学習は、ある特殊な損失関数を用いて行えばよい

$$\ell(\theta, \phi, \mathbf{x}) := -\text{ELBO}(g_\theta, \text{Enc}_\psi, \mathbf{x}) := \underbrace{\mathbb{E}_{\mathbf{z} \sim \text{Enc}_\psi(\mathbf{x})}[-\log p_\theta(\mathbf{x} \mid \mathbf{z})]}_{\text{Reconstruction error}} + \underbrace{\text{KL}(\text{Enc}_\psi(\mathbf{x}) \parallel p(\mathbf{z}))}_{\text{Regularization}}$$


- 上記で正規分布を付加したことにより、 $-\log p_\theta(\mathbf{x} \mid \mathbf{z}) = \frac{1}{2}\|\mathbf{x} - g_\theta(\mathbf{z})\|^2 + (\text{const.})$

- この損失関数は一体何なのか？それは別のセクションで解説

生成タスク > 潜在変数型の生成 > GANs

潜在変数からの変数変換による生成モデル②

■ 敵対的生成ネットワーク (generative adversarial networks, GANs)



- 生成器に加えて，識別器というものを用意する

生成タスク > 潜在変数型の生成 > GANs

GANsの学習のアルゴリズムは次のようになる

- 生成器と識別器が、競合する目標でそれぞれ学習
 - 生成器は、識別器に「フェイク」判定されないようにする
 - 識別器は、生成器が出したサンプルを見破り、実データと正しく2値分類する

$$\min_{\theta} \max_{\psi} \mathbb{E}_{x \sim \mathcal{D}} [\log \text{Dis}_{\psi}(x)] + \mathbb{E}_{z \sim p_z} [\log(1 - \text{Dis}_{\psi}(g_{\theta}(z)))]$$

- ▶ Dis_{ψ} については最尤法ベースの学習になっている
- ▶ g_{θ} については Dis_{ψ} の対数尤度を減らすという学習になっている


生成タスク > 潜在変数型の生成 > GANs

敵対的生成ネットワークの着想

- 今の状況は訓練データがラベル無しなので教師なし学習だが、教師なしは難しい

$$\mathcal{D} := \left\{ \begin{array}{c} \text{鳥} \\ \text{犬} \\ \text{猫} \\ \text{鳥} \end{array} \right\} \stackrel{\text{i.i.d.}}{\sim} p(\mathbf{x})$$

- 教師付き学習のような方法で生成器を学習できないだろうか？


「 $\in \mathcal{D}$ という事実」から、教師付き風に学習できないか？

- $p(\mathbf{x})$ のサンプルか否かの分類器を学習すれば、この情報を学習に使える！
 - しかし、 $p(\mathbf{x})$ のサンプル「ではない」ほうのデータはどう用意するか？
 - →今まさに学習しようとしている生成器に生成させればいい！

生成タスク > 潜在変数型の生成 > 拡散モデル

潜在変数からの変数変換による生成モデル③

■ 拡散モデル (diffusion models, DMs)




- 生成器として、逆拡散過程と呼ばれる特殊なものを用意する
- この形式の生成器は、スコアマッチングと呼ばれる学習法で学習できる

生成タスク > 潜在変数型の生成 > 可逆モデル

潜在変数からの変数変換による生成モデル④

■ 正規化流 (normalizing flows, NFs)



- 生成器を, **可逆ニューラルネット (invertible neural networks, INNs)** という特殊なもので用意する
- この場合, 変数変換の公式で生成器から直接的に尤度を計算できて, 学習可能


$$p_\theta(\mathbf{x}) = p_z(g_\theta^{-1}(\mathbf{x})) \cdot \left| \det \frac{\partial g_\theta^{-1}(\mathbf{x})}{\partial \mathbf{x}} \right|$$

生成タスク＞潜在変数型の生成＞条件付き生成



条件付き生成をするときは、潜在変数が条件付きになるようにする方法がある

- 条件変数を受け取るエンコーダーを作る（条件に合った潜在変数を出力させる）



- テキストで条件付ける画像生成で有名なStableDiffusionなどはこの方式
 - VAEをあらかじめ学習しておき、その後、エンコーダーを条件変数を受け取るものにすげ替えて、拡散過程で学習

【補足】 StableDiffusionの場合、VAEによるデコーダー部分の学習方法は、このセクションで説明したVAEの基本的な学習法から比べると、様々な工夫が凝らされたものになっていることに注意。VAEの目的関数の正則化を弱めて、GANの学習法を併用し、そのうえ学習済み画像分類器の内部表現の乖離度を損失に加えている。

ロードマップ

