


生成タスクへの潜在変数型アプローチ① (VAE)

生成タスク > 潜在変数型の生成 > VAEs



VAEは現在、画像生成モデルの重要な部品として使われている


- 学習済みのデコーダーは、次のように「潜在表現」を入力すると画像を出力



生成タスク > 潜在変数型の生成 > VAEs

変分オートエンコーダーの着想

- 生成器のモデルだけを見ると，次のようになっている



- このモデルから，原理的には次の式でデータの密度関数のモデルを導出できる

$$p_{\theta}(x) = \int p_{\theta}(x | z) \cdot p(z) dz$$

- ここから最尤法ベースの学習をしたいが……この積分は計算時間的に実行不能

生成タスク > 潜在変数型の生成 > VAEs > 着想

変分オートエンコーダーの着想

- ベイズの定理：周辺尤度がわかれば事後分布を計算可能

$$p(\mathbf{z} | \mathbf{x}) = \frac{p(\mathbf{x} | \mathbf{z}) p(\mathbf{z})}{p(\mathbf{x})}$$

- ということは、逆に、事後分布がわかれば周辺尤度を計算可能

$$p(\mathbf{x}) = \frac{p(\mathbf{x} | \mathbf{z}) p(\mathbf{z})}{p(\mathbf{z} | \mathbf{x})}$$

- 事後分布も分からないには変わらないが、事後分布を近似するモデルを用意することになれば、上手いトリックが使える（実はこれがエンコーダー）

生成タスク > 潜在変数型の生成 > VAEs > 着想

変分オートエンコーダーの着想

- エンコーダーには（生成器から決まる確率モデルの）事後分布の近似をさせる

$$q_{\psi}(z | x) := \text{Enc}_{\psi}(x)(z)$$

- 真の事後分布は $p_{\theta}(z | x) = \frac{p_{\theta}(x, z)}{p_{\theta}(x)}$ だが、実は次の関係を示すことができる

$$\text{KL}[q_{\psi}(z | x) \| p_{\theta}(z | x)] = \log p_{\theta}(x) - \text{ELBO}(g_{\theta}, \text{Enc}_{\psi}, x)$$

- よって $\text{Min}_{\psi} \text{KL}[q_{\psi}(z | x) \| p_{\theta}(z | x)]$ による近似をするなら、次を実行すればよい

$$\text{Min}_{\psi} \left[-\text{ELBO}(g_{\theta}, \text{Enc}_{\psi}, x) \right]$$

生成タスク > 潜在変数型の生成 > VAEs > 着想

先ほどの等式の導出は難しくない

- $\text{KL}[q_\psi(z | \mathbf{x}) \| p_\theta(z | \mathbf{x})] = \log p_\theta(\mathbf{x}) - \text{ELBO}(g_\theta, \text{Enc}_\psi, \mathbf{x})$ の導出

$$\begin{aligned}\text{KL}[q_\psi(z | \mathbf{x}) \| p_\theta(z | \mathbf{x})] &= \mathbb{E}_{z \sim \text{Enc}_\psi(\mathbf{x})} \left[\log \text{Enc}_\psi(\mathbf{x})(z) - \log p_\theta(z | \mathbf{x}) \right] \\ &= \mathbb{E}_{z \sim \text{Enc}_\psi(\mathbf{x})} \left[\log \text{Enc}_\psi(\mathbf{x})(z) - \log p_\theta(\mathbf{x}, z) + \log p_\theta(\mathbf{x}) \right] \\ &= \log p_\theta(\mathbf{x}) + \mathbb{E}_{z \sim \text{Enc}_\psi(\mathbf{x})} \left[\log \text{Enc}_\psi(\mathbf{x})(z) - \log p_\theta(\mathbf{x}, z) \right] \\ &= \log p_\theta(\mathbf{x}) - \text{ELBO}(g_\theta, \text{Enc}_\psi, \mathbf{x})\end{aligned}$$

- ここで $-\text{ELBO}(g_\theta, \text{Enc}_\psi, \mathbf{x}) := \mathbb{E}_{z \sim \text{Enc}_\psi(\mathbf{x})} \left[\log \text{Enc}_\psi(\mathbf{x})(z) - \log p_\theta(\mathbf{x}, z) \right]$ と定義した.

生成タスク > 潜在変数型の生成 > VAEs > 着想

先ほどの等式の導出は難しくない

- さらにこれを式変形すれば、次のように書き直すこともでき、先に書いた損失関数としての $-\text{ELBO}(g_\theta, \text{Enc}_\psi, \mathbf{x})$ に一致することも分かる

$$\begin{aligned} -\text{ELBO}(g_\theta, \text{Enc}_\psi, \mathbf{x}) &:= \mathbb{E}_{\mathbf{z} \sim \text{Enc}_\psi(\mathbf{x})} \left[\log \text{Enc}_\psi(\mathbf{x})(\mathbf{z}) - \log p_\theta(\mathbf{x}, \mathbf{z}) \right] \\ &= \mathbb{E}_{\mathbf{z} \sim \text{Enc}_\psi(\mathbf{x})} \left[\log \text{Enc}_\psi(\mathbf{x})(\mathbf{z}) - \log p_\theta(\mathbf{x} \mid \mathbf{z}) - \log p(\mathbf{z}) \right] \\ &= \mathbb{E}_{\mathbf{z} \sim \text{Enc}_\psi(\mathbf{x})} \left[-\log p_\theta(\mathbf{x} \mid \mathbf{z}) + \log \frac{\text{Enc}_\psi(\mathbf{x})(\mathbf{z})}{p(\mathbf{z})} \right] \\ &= \mathbb{E}_{\mathbf{z} \sim \text{Enc}_\psi(\mathbf{x})} \left[-\log p_\theta(\mathbf{x} \mid \mathbf{z}) \right] + \text{KL}(\text{Enc}_\psi(\mathbf{x}) \parallel p(\mathbf{z})) \end{aligned}$$

生成タスク > 潜在変数型の生成 > VAEs > 着想

変分オートエンコーダーの着想（生成器の学習）

- さらに、生成器（デコーダー）部分も、そのまま $-\text{ELBO}(g_{\theta}, \text{Enc}_{\psi}, \mathbf{x})$ を損失関数とする最小化で学習をすることにする

$$\text{Min}_{\theta} \left[-\text{ELBO}(g_{\theta}, \text{Enc}_{\psi}, \mathbf{x}) \right]$$

- 先ほどの関係式の通りだが、KL項の最小化は $q_{\psi}(z | \mathbf{x})$ の学習が担っていた

$$\text{KL}[q_{\psi}(z | \mathbf{x}) \| p_{\theta}(z | \mathbf{x})] = \log p_{\theta}(\mathbf{x}) - \text{ELBO}(g_{\theta}, \text{Enc}_{\psi}, \mathbf{x})$$

- もし $q_{\psi}(z | \mathbf{x})$ が良い仕事をして、実際にKL項を最小化してくれれば、生成器は $-\text{ELBO}(g_{\theta}, \text{Enc}_{\psi}, \mathbf{x})$ の最小化だけで学習すれば、 $\log p_{\theta}(\mathbf{x})$ の最大化になる

生成タスク > 潜在変数型の生成 > VAEs

変分オートエンコーダーの学習のアルゴリズムは次のようになる

- 損失関数は次の通り：訓練データ点 $\mathbf{x}_i$ ごとに次を計算

$$\ell(\boldsymbol{\theta}, \boldsymbol{\psi}, \mathbf{x}) = \underbrace{\mathbb{E}_{\mathbf{z} \sim \text{Enc}_{\boldsymbol{\psi}}(\mathbf{x})} [-\log \mathcal{N}(g_{\boldsymbol{\theta}}(\mathbf{z}), I)(\mathbf{x})]}_{\text{Reconstruction error}} + \underbrace{\text{KL}(\text{Enc}_{\boldsymbol{\psi}}(\mathbf{x}) \| p(\mathbf{z}))}_{\text{Regularization}}$$

- 正則化項は、事後分布の近似結果が事前分布 $p(\mathbf{z})$ から離れすぎないように調整
 - これは、例えば $\text{Enc}_{\boldsymbol{\psi}}(\mathbf{x}) = \mathcal{N}(m_{\boldsymbol{\psi}}(\mathbf{x}), \Sigma_{\boldsymbol{\psi}}(\mathbf{x}))$, $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, I)$ などのモデルを使っておけば、正規分布同士のKLダイバージェンスなので簡単に計算可能

$$\text{KL}(\text{Enc}_{\boldsymbol{\psi}}(\mathbf{x}) \| p(\mathbf{z})) = \frac{1}{2} \left(\text{tr}(\Sigma_{\boldsymbol{\psi}}(\mathbf{x})) + \|\mu_{\boldsymbol{\psi}}(\mathbf{x})\|^2 - h + \log \det \Sigma_2 \right)$$


生成タスク > 潜在変数型の生成 > VAEs

変分オートエンコーダーの学習のアルゴリズムは次のようになる


- 再構成誤差（reconstruction error）の計算方法

$$\mathbb{E}_{z \sim \text{Enc}_\psi(x)}[-\log \mathcal{N}(g_\theta(z), I)(x)]$$

- x をエンコーダーに入力して近似事後分布を得て，そのサンプルを多数取得



- その各サンプルを生成器に入力して $g_\theta(z)$ を得て， $-\log \mathcal{N}(g_\theta(z), I)(x)$ を計算




- この値を，取得した潜在変数サンプルの各々で計算して平均

生成タスク > 潜在変数型の生成 > VAEs

変分オートエンコーダーの学習のアルゴリズムは次のようになる

- 損失の計算は先ほどの方法でよいが、微分にはひと工夫が必要
 - 期待値部分にパラメーターが入っているため、あるいは、計算グラフの途中で潜在変数 z のサンプリングが含まれるためともいえる



生成タスク > 潜在変数型の生成 > VAEs


変分オートエンコーダーの学習のアルゴリズムは次のようになる

- 再パラメーター化トリック (reparametrization trick) が一つの方法

- 例えば、エンコーダーを $\text{Enc}_\psi(\mathbf{x}) = \mathcal{N}(m_\psi(\mathbf{x}), \text{diag}(\sigma_\psi^2(\mathbf{x})))$ という構造にしておけば、別の変数 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ をサンプリングして、次のように変換すれば、 $\mathbf{z}$ は

$$\text{Enc}_\psi(\mathbf{x}) \text{ からのサンプルになる : } \mathbf{z} := m_\psi(\mathbf{x}) + \exp\left(\frac{1}{2} \log \sigma_\psi^2(\mathbf{x})\right) \odot \boldsymbol{\epsilon}$$

- これなら計算グラフも問題なく描けて、誤差逆伝播で勾配計算が可能



生成タスク > 潜在変数型の生成 > VAEs

変分オートエンコーダーの学習のまとめ

- 次の目的関数（正則化などは加える場合もある）で学習

$$L(\theta, \psi) := \frac{1}{n} \sum_{i=1}^n \left\{ -\text{ELBO}(g_{\theta}, \text{Enc}_{\psi}, x_i) \right\}$$

- この目的関数を最小化するように、符号化器と復号化器の最適化を行う

$$\underset{\theta, \psi}{\text{Min}} L(\theta, \psi)$$

- ここで使われている損失関数は


$$-\text{ELBO}(g_{\theta}, \text{Enc}_{\psi}, x) = \underbrace{\mathbb{E}_{z \sim \text{Enc}_{\psi}(x)} [-\log \mathcal{N}(g_{\theta}(z), I)(x)]}_{\text{Reconstruction error}} + \underbrace{\text{KL}(\text{Enc}_{\psi}(x) \| p(z))}_{\text{Regularization}}$$

【補足】 この最適化を行う際、過去には θ についての最小化ステップと ψ についての最小化ステップを交互に行う場合があったが、現在は単に同時に行われる。


生成タスク > 潜在変数型の生成 > VAEs

VAEは、データの圧縮・解凍の方法を学習しているともいえる

- データ x をエンコーダーで圧縮（潜在表現の分布に変換）



- 潜在表現からデコーダーでデータを再構成




生成タスク > 潜在変数型の生成 > VAEs



VAEは現在、画像生成モデルの重要な部品として使われている

- 学習済みのデコーダーは、次のように「潜在表現」を入力すると画像を出力



- ただし、実際の学習方法は、元々のELBOを用いる方法から変化してきている
 - 後述のGANの学習法を併用したり、学習済み分類器の内部表現を損失関数に活用したり