


ロードマップ



今回は賞味期限が短い内容です




短期的に状況が変化する要素が多いので……

- ここから先の内容は，2025年初頭の内容だと思っておいってください
- 最新の潮流の話ですが，代わりに古くなるのも早いです

言語モデルの大規模化

言語モデルの大規模化


作られるモデルのパラメーター数は急激に大規模化している



- モデル名に付けられている「B」は、Billion（10億）単位のパラメーター数表示

データの大規模化

訓練に使われるデータの量も急激に大規模化している



- 1兆トークンはどれくらい？ → 約13億冊の書籍に相当

余談：人間の脳のニューロン数との比較


今のパラメーター数は，人間の脳と比べてどれぐらいなのか？

- Azevedo et al. (2009) によれば，大人の男性の脳は平均で (86.1 ± 8.1) B（861億 $\pm$ 81 億）個のニューロンを含んでいる．
- 当然，素子として機能が異なるので詳しい個数の比較をしても意味がないが，個数のオーダーはLLMは数百B，人間の脳は100B程度であり，奇しくも遠くない（何千倍も違うわけではない）



100B 前後

$\approx$



100～1000Bのオーダー

【参考】 Azevedo et al. (2009). Equal numbers of neuronal and nonneuronal cells make the human brain an isometrically scaled-up primate brain. *Journal of Comparative Neurology*, 513(5), 532–541. <https://doi.org/10.1002/cne.21974>

【補足】 燃費は明らかに人間のほうがよい。反面，LLMは人間は比にならない記憶力を持っている。

大規模化の背景

モデルの大規模化の背景には、スケーリング則（scaling laws）がある

- **モデルとデータの規模**に対して、予測可能な形でテスト損失が低下（経験則）
- 例：チンチラ・スケーリング則（Chinchilla scaling law）

$$L^*(\text{param}, \text{data}) \simeq 1.61 + \frac{406.4}{\text{param}^{0.34}} + \frac{410.7}{\text{data}^{0.28}}$$

- $L^*(\text{param}, \text{data})$ ：学習後のテスト損失値
- param：パラメーター数， data：訓練トークン数

【補足】スケーリング則は通常、事前学習（次トークン予測）におけるテスト損失の話。事前学習で性能が良いほど後続タスクでも良いという傾向はある。
なお、Chinchillaスケーリング則はテスト損失ではなく平滑化した訓練損失値から構築されている。これは、訓練用コーパスのデータ量が膨大で、実際のところ1エポック未満しか学習が行われないので、（平滑化した）訓練損失がテスト損失の推定値として機能しているため。

また、パラメーター数には、埋め込みベクトルのパラメーター数（語彙の数に比例）は含まない。

【参考】Equation (10) in Hoffmann et al. (2022). Training Compute-Optimal Large Language Models. arXiv. <http://arxiv.org/abs/2203.15556>

訓練計算量

ただパラメーターとデータを大きくすれば良いというものではない

- パラメーターとデータが増えると，訓練に必要な計算量が増える
- FLOPs (FLoating-point Operations)

浮動小数点演算の回数のこと．行列積などは浮動小数点演算なので，これを数えれば訓練に必要な計算の概算になる．

- トランスフォーマーの場合：

$$\text{FLOPs} \simeq 6 \cdot \text{param} \cdot \text{data}$$

【詳細】 paramは（トークン埋め込み以外の）パラメーター数，dataは訓練トークン数．計算量はデータ量というよりバッチサイズ×ステップサイズで決まるように思われるかもしれないが，訓練コーパスの大きさが実際に訓練に使うデータ量を凌駕しているため，1エポック未満しか訓練されておらず影響がない（“the training runs for our analysis have all been trained on less than an epoch of data” (Hoffmann et al., 2022)) ．

【参考】 Table A4 of Hoffmann et al. (2022). Training compute-optimal large language models (arXiv:2203.15556). arXiv. <http://arxiv.org/abs/2203.15556> や Kaplan et al. (2020). Scaling laws for neural language models (arXiv:2001.08361). arXiv. <https://doi.org/10.48550/arXiv.2001.08361>

スケーリング則の重要性

ただ興味深いだけではなく，LLMを作るための予算計画に使える

- 予算から，訓練に使える計算量（FLOPs）の上限が決まる
- 計算量は，パラメーター数とデータ量のとりうる組合せの制約となる

$$\text{FLOPs} = 6 \cdot \text{param} \cdot \text{data}$$

- この制約の下，最高性能を目指す（必要なパラメーター数とデータ量も分かる）

$$\arg \min_{(\text{param}, \text{data})} \quad L^*(\text{param}, \text{data}) = 1.61 + \frac{406.4}{\text{param}^{0.34}} + \frac{410.7}{\text{data}^{0.28}}$$
$$\text{FLOPs} \geq 6 \cdot \text{param} \cdot \text{data}$$

【参考】例えばGPT-3の訓練にはNVIDIA Tesla V100のクラウドインスタンスを用いて7億円ほどの予算が必要という：Li, C. (2020, June 3). OpenAI's GPT-3 language model: A technical overview. <https://lambdalabs.com/blog/demystifying-gpt-3>. 他にも，Llama3の場合は， 3.8×10^{25} FLOPsの予算だったらしい：Section 3.2 of Dubey et al. (2024). The Llama 3 herd of models (arXiv:2407.21783). arXiv. <https://doi.org/10.48550/arXiv.2407.21783>

スケーリング則の重要性


経験則の破綻が観察されるまでは、規模を大きくすれば性能が向上

- 経験則が成立しているうちは、新しい手法やモデルの開発をしなくても、大規模化さえすれば性能が上がるという予報を意味する
- 性能がまだまだ確実に上がるはずだ、といえる法則はかつてないもの
- モデル構造（トランスフォーマーを深くするか幅広にするかなど）にあまり依存せず、パラメーター数だけに依存する経験則であることもポイント。ただしトランスフォーマーに限る（他のモデルで適用できるとは限らない）。

モデルの大規模化の効果

創発的能力（emergent abilities）も確認されている

- 一定の規模（パラメーター・データともに）に達すると性能が向上し始める現象



【参考】 量的な変化により質的な変化が生まれているという点が創発的と形容されている。 Wei et al. (2022). Emergent abilities of large language models. Transactions on Machine Learning Research. 【図】 Figure 2 of Wei et al. (2022).