

# マルチモーダルモデル

# マルチモーダルモデル

---



テキスト，画像，音声，……などを統一的に扱えるモデルを解説

- マルチモーダルとは（ここでは）「多種類データの」という意味

# マルチモーダルモデル

---

データのモダリティとは，データの様式のこと

- モダリティ (modality)

- テキスト，画像，音声，動画，……



- 複数のモダリティを同時に扱うモデルを，マルチモーダルモデルという

- 逆に1種類のデータだけを扱うものはユニモーダルという



# マルチモーダルモデル＞タスク

マルチモーダルなタスクには、次のようなものがある

## ■ 画像もテキストも入力できるチャットボット

両方の情報を使って  
応答のテキストを生成



ユーザーは  
画像もテキストも  
入力


【用語】 テキスト条件付きの画像生成なども広義にはマルチモーダルといえるが、入力・出力のそれぞれが1モダリティずつなので、特にクロスモーダル（cross-modal）と呼んで区別することがある。現在はマルチモーダルというと、入出力が複数モダリティな場合を想定することが多い。 【補足】 画像はGoogleのGemini.




# マルチモーダルモデル＞アプローチ

## マルチモーダルなモデルの実現アプローチ

- マルチモーダルな特徴量の情報を使いたい




- それには、共通の埋め込みを学習することが鍵になる



# マルチモーダルモデル > CLIP

表現学習法として，CLIP（Radford et al., 2021）などの手法がある


- CLIP（Contrastive Language-Image Pretraining）
  - テキストと画像で，共通の埋め込み空間を学習



# マルチモーダルモデル > CLIP

## CLIPの学習法：自己教師付きの対照学習

- インターネット上からテキスト付きの画像を大量に収集  $\mathbf{x}_i := (\text{text}_i, \text{image}_i)$
- それぞれを埋め込み、全組合せのコサイン類似度をSoftmaxに入れて $L$ を最小化



$$\begin{aligned} L_{\text{text}} &:= \frac{1}{n} \sum_{i=1}^n \left( -\log \text{Softmax}_\tau(\{c_{ij}\}_{j=1}^n)[i] \right) \\ L_{\text{image}} &:= \frac{1}{n} \sum_{j=1}^n \left( -\log \text{Softmax}_\tau(\{c_{ij}\}_{i=1}^n)[j] \right) \end{aligned} \Rightarrow L := \frac{1}{2} (L_{\text{text}} + L_{\text{image}})$$

【参考】 Radford et al. (2021). Learning transferable visual models from natural language supervision. Proceedings of the 38th International Conference on Machine Learning, 8748–8763. 【補足】 上記で  $B := \{\mathbf{x}_i\}_{i=1}^n$  はミニバッチであり、学習はミニバッチ確率的勾配法で行われる。  $\text{Softmax}_\tau$  は温度付きソフトマックス。




# マルチモーダルモデル

大規模なマルチモーダルモデルでは、複数のモダリティを統一的に扱う

## ■ 早期融合 (early fusion)

- 画像もテキストと同様に、トランスフォーマー系モデルで統一的に扱う



- 画像は、学習済みVAEの符号化器で潜在表現に変換してから、一定サイズのパッチに切り分けて入力（出力時も潜在空間で生成して、VAEで復号化）

【参考】 Zhou et al. (2024). Transfusion: Predict the next token and diffuse images with one multi-modal model. The Thirteenth International Conference on Learning Representations. <https://openreview.net/forum?id=SI2hl0frk6> 【補足】 画像の潜在表現での生成は、トランスフォーマーを生成器として扱って拡散モデルの方法で学習される。

# マルチモーダルモデル



現在では、更に、音声や動画のデータも同様に扱えるモデルが作られている

- 大きな仕組みは「共通の表現ベクトルの空間で計算をできるようにする」
- VAEや拡散モデルによる画像生成，アテンションによる系列処理と自己回帰的なテキスト生成など，ここまでに出来た技術を総動員するかのようにして，統一的に扱えるアーキテクチャが模索されている



# ロードマップ

