


大規模言語モデルの訓練方法（概要）

大規模言語モデルの訓練方法

次の3ステップからなる学習と、次ページにある強化学習をすることが多い


1. 事前学習

- 言語モデルとしての訓練
- 大規模コーパスでトークン予測のタスクによる自己教師付き学習




2. 指示チューニング

- 言語モデルをエージェントらしく挙動させる
- 教師付きファインチューニング



3. 選好チューニング

- 人間がモデルの出力に対して付けたランキング（選好データ）を収集
- より人間が好む出力をするようにRLHFやDPO




大規模言語モデルの訓練方法

さらに望ましい特性を持たせるように強化学習をすることも多い

4. 特性促進のための強化学習

- 例えば「数学の問題を解く能力が高い」など、評価可能な特性の促進を目的として強化学習
- 実際に出力させてみて、結果を評価し、学習を進める、という処理を大規模に繰り返す





ステップ1：事前学習（Pretraining）



大量のデータから大量の計算量を使って学習



~15兆トークン
(12兆単語程度)
のテキストデータ



延べ3,084万時間の計算
(1台600万円近くする
GPUを16,000台使用)



params.zip


229GB

まるでイン
ターネットを
圧縮したよう
なもの


事前学習 > 訓練方法

次トークン予測（next-token generation）による自己教師付き学習

- 途中までの文章 [?]，次のトークンを予測させる




- 途中までの文章から [?] 次のトークンを予測させる



ステップ2：指示チューニング（Instruction tuning）

言語モデルをエージェントらしく挙動させるために教師付き追加訓練

- 指示と正解出力のペアで，教師付き精密調整（ファインチューニング）をする



- 学習方法は普通に次トークン予測

指示チューニング>データセット

指示チューニング用のデータセット例（Taori et al., 2023）

instruction string · lengths	input string · lengths	output string · lengths	text string · lengths
 9↔58 51.7%	 0↔247 98.8%	 0↔419 74.5%	 154↔589 67.2%
Give three tips for staying healthy.		1.Eat a balanced diet and make sure to include plenty of fruits and vegetables. 2. Exercise regularly to keep your body active and strong. 3. Get enough sleep and maintain a consistent sleep schedule.	Below is an instruction that describes a task. Write a response that appropriately completes the request. ### Instruction: Give three tips for staying healthy. ### Response: 1.Eat a balanced diet and make sure to include plenty of fruits and vegetables. 2. Exercise regularly to keep your body active and strong. 3. Get enough sleep and maintain a consistent sleep schedule.
What are the three primary colors?		The three primary colors are red, blue, and yellow.	Below is an instruction that describes a task. Write a...
< Previous 1 2 3 ... 521 Next >			

【参考】 Taori, R., Gulrajani, I., Zhang, T., Dubois, Y., Li, X., Guestrin, C., Liang, P., & Hashimoto, T. B. (2023). Stanford Alpaca: An Instruction-following LLaMA model [Dataset]. stanford_alpaca.

指示チューニング>限界

指示チューニングデータを大規模かつ高品質に作るのは難しい

- 既存データセットの再利用の場合，テンプレートを使うので出力の多様性が低い
- 人手での作成の場合，出力自体を人が作らなければならないので高コスト
- ただし，厳選された1,000件のデータセットによる指示チューニングで，RLHFや選好モデリングもせずに，InstructGPTに匹敵する性能を達成したという報告もある（Zhou et al., 2023）ので，そもそも指示チューニングを大規模データで行う必要がない可能性はある

ステップ3：選好チューニング

まずモデルに出力させてみて、それに対する人間の選好で学習

- さらに人に好まれる回答をするようにアシスタントとしての訓練
 - 有害な回答・バイアスなどのアラインメント的な側面もカバー
- 色々な手法が用いられる
 - 人のフィードバックからの強化学習（reinforcement learning from human feedback, RLHF）
 - RLHFから派生した直接選好最適化（direct preference optimization, DPO）

選好チューニング > RLHF

「より好まれる出力」を出すように精密調整

- 「入力 x に対し, y^- よりも y^+ の方が好まれた」というデータ (x, y^-, y^+) を収集
 - ここから「好まれる度合い」を表す報酬モデル $r(x, y)$ を学習しておく
- これを用いてLLM $\pi_\theta(y|x)$ を精密調整 (ここで $\pi_{\text{ref}}(y|x)$ は事前学習済みLLM)

$$\text{Max}_{\theta} \left\{ \underbrace{\mathbb{E}_{X \sim \mathcal{D}, Y \sim \pi_\theta(\cdot|X)}[r(X, Y)]}_{\text{期待報酬を最大化}} - \beta \cdot \underbrace{\text{KL}(\pi_\theta \| \pi_{\text{ref}})}_{\text{過度な変化を抑制}} \right\}$$

- 最適化は, 期待値記号自体にパラメーターが入っているので, ひと工夫が必要

【補足】 上記で, 正確には $\text{KL}(\pi_\theta \| \pi_{\text{ref}}) = \mathbb{E}_{X \sim \mathcal{D}}[\text{KL}(\pi_\theta(\cdot|X) \| \pi_{\text{ref}}(\cdot|X))]$ かつ, トークンレベルのKLダイバージェンス. また, 初期値は $\pi_\theta = \pi_{\text{ref}}$. 【参考】 Ouyang et al. (2022). Training language models to follow instructions with human feedback. Advances in Neural Information Processing Systems, 35, 27730–27744.

ステップ4：特性促進のための強化学習

「検証可能な報酬による強化学習」（RLVR）で、評価可能な特性を促進する

- 「 x に対する出力 y の好ましさを簡単に評価できる」課題データ (x, y) を収集
 - その「好ましさ」を表す報酬関数を $v(x, y)$ とする（検証可能な報酬と呼ぶ）
 - 例えば数学やプログラミングの課題や、思考トークンの多さなど
- これを用いてLLM $\pi_{\theta}(y|x)$ を精密調整（ここで $\pi_{\text{ref}}(y|x)$ は事前学習済みLLM）

$$\text{Max}_{\theta} \left\{ \underbrace{\mathbb{E}_{X \sim \mathcal{D}, Y \sim \pi_{\theta}(\cdot|X)}[v(X, Y)]}_{\text{期待報酬を最大化}} - \underbrace{\beta \cdot \text{KL}(\pi_{\theta} \| \pi_{\text{ref}})}_{\text{過度な変化を抑制}} \right\}$$

- 最適化は、期待値記号自体にパラメーターが入っているので、ひと工夫が必要

大規模言語モデルの訓練方法



次トークン予測による事前学習の後に、様々な方法による事後学習が行われる

- 人類による選好を反映するための「選好チューニング」 (RLHFやDPOによる)
- 推論能力を高めるための「特性促進のための強化学習」 (RLVRなどによる)
 - 同様に、熟慮によるアライメントや、出力形式が期待に合うかなど、様々な特性の促進に使われる