

クラス不均衡

Concepttest（理解を試すクイズ）



正答率が高いが望ましくないモデル

Q. 「あなたは機械学習のプロジェクトで、2値分類のモデルを学習させている。

あるときあなたは、モデルの正答率が98%を達成したという報告を受けた。

詳しく確認してみると、確かに十分なデータ量があり、
ランダムに20%を分けたテストデータで評価が行われていた。

しかし、あなたは実際の予測値を見て
このモデルではリリースできないと判断した。
何があったのだろうか。」

【質問】 モデルの解釈性が問題でしたか？ → いいえ 【質問】 モデルの出力は、0や1という分類のラベルだけで、他に変な値は混ざっていませんでしたか？ → はい

【質問】 モデルの運用コストが高いという理由ですか？ → いいえ

Concepttest（理解を試すクイズ）の答え

正解は ……




あなたが扱っている分野は、クラスの出現率の偏りが大きい分野であった。

全体の2%の確率でしか正例が生じないので、モデルは全てを負例と予測しながらも98%の精度を叩き出していたのだ。

クラス不均衡

稀な事象の検出器を学習するためには、訓練や評価のときに工夫が必要

- 2クラス分類 $\mathcal{Y} = \{0,1\}$ で、正クラス $Y = 1$ が非常に稀だとする $p(y = 1) = 0.01$ (全体の1%しか起こらない)
- 例)
 - 珍しい病気 (人口のごく僅かな割合にしか生じない)
 - 通販サイトの購買予測 (ほとんど素通りするがごく稀に購入する人がいる)




クラスの出現率の偏りが大きい分布


クラス不均衡＞不均衡下での性能指標

正答率などの指標は、見かけだけ良くなってしまうことがある


- 全体の1%しか $Y = 1$ が起きないならば、常に $Y = 0$ を予測すれば正答率99%
- しかしこれでは、本当に見つけない1%を見つけれない予測器になってしまう



評価用データ



予測器の出力




性能が不合理に
高く見えてしまう

クラス不均衡 > 不均衡下での性能指標 > 再現率

クラス1を取りこぼさずにピックアップできた度合いを評価する指標

■ **再現率 (recall)** : 「正解ラベルが1である中で正しく思い出せた割合」

$$\text{Recall} = \frac{\#\{Y_{\text{true}} = 1, Y_{\text{pred}} = 1\}}{\#\{Y_{\text{true}} = 1\}}$$



【用語】 この講義では主にリコールと呼ぶ。 【補足】 再現率は0以上1以下の値をとる。分母が0のときは定義されないが、便宜的に1と定義してもよい。

【補足】 $\#(\cdot)$ は、集合の濃度 (cardinality) といい、集合に含まれる要素の数を表す。

クラス不均衡＞不均衡下での性能指標＞再現率



再現率だけを見てもダメ

- 再現率を見ることで、重要なクラスを見落としていないか評価できる
- しかし、再現率だけを見ると、全て $y = 1$ と予測すれば100%にできる
- そこで、必要なときだけ $y = 1$ と予測するように促す指標が欲しい

クラス不均衡 > 不均衡下での性能指標 > 適合率

やみくもにクラス1と言っているだけではない度合いを評価する指標

■ **適合率 (precision)** : 「1だと予測した中で精確 (precise) だった割合」

$$\text{Precision} = \frac{\#\{Y_{\text{true}} = 1, Y_{\text{pred}} = 1\}}{\#\{Y_{\text{pred}} = 1\}}$$



クラス不均衡＞不均衡下での性能指標＞適合率と再現率



適合率と再現率を同時に使うことで、稀なクラスの予測器を適正評価できる

- 2つの指標を同時に見る
 - 再現率（recall）：クラス1を適切にピックアップできた
 - 適合率（precision）：やみくもにクラス1と言っているだけではない
- **これらが同時に高ければ**，確かに，クラス1をうまくピックアップできる
 - 見落とさずに，かつ，当てずっぽうではなくクラス1を特定している
- しかし，指標が2つに分かれていると，意思決定には使いづらい時もある
 - precisionは0.02上がるが，recallが0.03下がる場合は，モデルを変えるべき？

クラス不均衡 > 不均衡下での性能指標 > Fスコア

Precisionとrecallを1つに集計する指標として、Fスコアがある

- Fスコア (F-score, F_β スコア) ($\beta > 0$)

$$F_\beta = \frac{(\beta^2 + 1) \cdot \text{precision} \cdot \text{recall}}{\beta^2 \text{precision} + \text{recall}}$$

- よく使われる値: F_1 スコア (F_1 score)

$$F_1 = \frac{2 \cdot \text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}$$

- 他によく使われる値: F_2 はrecall重視, $F_{0.5}$ はprecision重視

【補足】 F_1 スコアは、precisionとrecallの調和平均 (harmonic mean) になっている。「重視」の意味は、 $F_\beta = (\beta^2 + 1) \cdot (\beta^2 \cdot \text{recall}^{-1} + \text{precision}^{-1})^{-1}$ と式変形するとわかる。 β が大きいほど、recallの小ささに F_β が反応して小さくなりやすくなる。【補足】 分母が0の場合は未定義になるが、この講義では便宜的に0とする。

クラス不均衡 > 不均衡下での性能指標 > Fスコア > 計算例

Fスコアの分子は掛け算なので、一方でも0に近いと値が低くなる

- Precisionとrecallのバランスが悪いときに気づける指標となっている

Precision	Recall	F_1 スコア	相加平均（参考）
1.0	0.1	$\frac{2 \cdot 1.0 \cdot 0.1}{1.0 + 0.1} \simeq 0.18$	$\frac{1.0 + 0.1}{2} = 0.55$
0.7	0.4	$\frac{2 \cdot 0.7 \cdot 0.4}{0.7 + 0.4} \simeq 0.51$	$\frac{0.7 + 0.4}{2} = 0.55$

クラス不均衡 > 不均衡下での学習



分布のクラスの不均衡は、学習にも影響する

- クラス不均衡の度合いが高い分布であることがわかっているならば、**そのことを事前知識として取り入れた**学習法を設計したほうが有利に学習できる

クラス不均衡 > 不均衡下での学習 > リスク

クラス不均衡の，学習への影響


- 通常の誤分類率リスクでは，稀なクラスでの誤分類は軽視される

$$\mathbb{P}(Y \neq f(X)) = \mathbb{P}(Y = 0) \mathbb{P}(Y \neq f(X) | Y = 0) + \mathbb{P}(Y = 1) \mathbb{P}(Y \neq f(X) | Y = 1)$$

ほぼ1

0.0001など非常に小さい

- 手持ちのデータでの経験リスクでも，稀なクラスが十分に代表されない



訓練標本



$$\frac{1}{n} \sum_{i=1}^n \ell_{0/1}(y_i, f(\mathbf{x}_i))$$

正例 ($y_i = 1$) の割合が低い

クラス不均衡 > 不均衡下での学習 > BERリスク

ここまでに出てきた意味でのリスクではないが、次のリスクを考える

- 均衡下の誤分類率（Balanced Error Rate, BER）リスク

$$R(f) := \frac{1}{2} \cdot \mathbb{P}(Y \neq f(X) | Y = 0) + \frac{1}{2} \cdot \mathbb{P}(Y \neq f(X) | Y = 1)$$

- 正例と負例の誤分類率を別々に考えてから、足して2で割ったもの

- 通常の誤分類率リスクとは、 $p(y = 0)$ や $p(y = 1)$ に相当する重みが異なる

クラス不均衡 > 不均衡下での学習 > BERリスク


BERをリスクとする学習の近似ターゲット

- 均衡下の誤分類率を特別な場合として含む, 次のリスクを考える ($\alpha \in (0,1)$)

$$R_{\alpha}(f) := (1 - \alpha) \cdot \mathbb{P}(Y \neq f(X) | Y = 0) + \alpha \cdot \mathbb{P}(Y \neq f(X) | Y = 1)$$

- この場合の近似ターゲットは, **クラス条件付き密度 (class-conditional density)** の比に基づく予測器

$$f^*(\mathbf{x}) = \mathbf{1} \left\{ \frac{p(\mathbf{x} | y = 1)}{p(\mathbf{x} | y = 0)} \geq \frac{1 - \alpha}{\alpha} \right\}$$



- つまり, $\mathbf{x}$ がクラス1から生成される確率と, クラス0から生成される確率を比較して, クラス1からの生成確率のほうが一定以上高ければ予測ラベルを1にする

クラス不均衡 > 不均衡下での学習 > BERリスク > 証明

次のように考えると容易に示せる

- 正例と負例を $\alpha : (1 - \alpha)$ で混合し直した**仮想的な分布** $p_\alpha(\mathbf{x}, y)$ を次で定義する.

$$p_\alpha(\mathbf{x}, y) := \begin{cases} p(\mathbf{x} | y = 1) \cdot \alpha & (y = 1) \\ p(\mathbf{x} | y = 0) \cdot (1 - \alpha) & (y = 0) \end{cases}$$

- $R_\alpha(f)$ は, $p_\alpha(\mathbf{x}, y)$ における誤分類率なので, 近似ターゲットは, p_α での最大事後確率則

$$f^*(\mathbf{x}) := \arg \max_{y \in \{0, 1\}} p_\alpha(y | \mathbf{x}) \quad \text{すなわち,} \quad f^*(\mathbf{x}) = \mathbf{1} \{p_\alpha(y = 1 | \mathbf{x}) \geq p_\alpha(y = 0 | \mathbf{x})\}$$

- いま, 定義から直ぐに $p_\alpha(y = 1 | \mathbf{x}) = \frac{p(\mathbf{x} | y = 1) \cdot \alpha}{p(\mathbf{x})}$ と $p_\alpha(y = 0 | \mathbf{x}) = \frac{p(\mathbf{x} | y = 0) \cdot (1 - \alpha)}{p(\mathbf{x})}$ を得て

$$f^*(\mathbf{x}) = \mathbf{1} \left\{ \frac{p(\mathbf{x} | y = 1)}{p(\mathbf{x} | y = 0)} \geq \frac{1 - \alpha}{\alpha} \right\}$$

【注意】 これは証明のあらすじ. 正確には当該リスクを最小化する予測器は上記の $f^*(\mathbf{x})$ と「ほとんどの $\mathbf{x}$ において等しい」 (a.s.- $\mathbf{x}$) という主張になる.

クラス不均衡 > 不均衡下での学習 > BERリスク > まとめ



クラス1とクラス0における誤分類率の重視比率を自分で調整する

- リスク $R_\alpha(f) := (1 - \alpha) \cdot \mathbb{P}(Y \neq f(X) | Y = 0) + \alpha \cdot \mathbb{P}(Y \neq f(X) | Y = 1)$ に対する近似

$$\text{ターゲット } f^*(\mathbf{x}) = \mathbf{1} \left\{ \frac{p(\mathbf{x} | y = 1)}{p(\mathbf{x} | y = 0)} \geq \frac{1 - \alpha}{\alpha} \right\}$$

- クラスのそもそもの出現比率（**クラス事前確率, class prior**）に関する情報は、クラス条件付き密度比の中には現れていない
- クラス事前確率の情報は、閾値のほうに入っている
- クラスの偏りに左右されにくい情報を見る予測器を作れば、最小化できるようになりリスクとなっている

クラス不均衡 > 不均衡下での学習 > アンダーバギング




実際の学習は、アンダーサンプリングとバギングの併用が効果的とされている


- リスク $R_\alpha(f) := (1 - \alpha) \cdot \mathbb{P}(Y \neq f(X) | Y = 0) + \alpha \cdot \mathbb{P}(Y \neq f(X) | Y = 1)$ を小さくしたい
- アイデア：仮想的な分布 $p_\alpha(\mathbf{x}, y)$ を、実際に作って学習に使う

$$p_\alpha(\mathbf{x}, y) := \begin{cases} p(\mathbf{x} | y = 1) \cdot \alpha & (y = 1) \\ p(\mathbf{x} | y = 0) \cdot (1 - \alpha) & (y = 0) \end{cases}$$

- どのように？ → 訓練データから、正例と負例を一定割合でリサンプリング



訓練標本




サブ標本

クラス不均衡 > 不均衡下での学習 > アンダーバギング




比率を合わせるために、負例を少なめに抽出するので、情報を捨ててしまう

- クラス不均衡の場合、多数派のクラスデータをアンダーサンプリング (undersampling)，つまり本来よりも少なく抽出することを意味する




- そこで、データ全体を有効利用できるように、何度も抽出を行う方針をとる



バギング (bagging)

バギングは訓練データからランダムな部分標本を多数作って学習する手法

- 訓練標本から再抽出をする**ブートストラップ法 (bootstrap method)** の一種
- 多数のブートストラップ標本から、個別に予測器を学習し、最後に統合する。



【用語】 ブートストラップ法で再抽出した各々のデータセットはブートストラップ標本と呼ぶ。バギングは、ブートストラップ集約 (bootstrap aggregating) の略。ブートストラップは, "pull oneself up by their bootstrap"という言い回しから、ブーツの後ろについている革紐で自身を引っ張り上げる, という自助努力の比喻。


【補足】 バギングでは通常、重複を許してサンプリングをする (復元抽出)。

バギング> アルゴリズム

一般的なバギングのアルゴリズムは次の通り

■ バギング (bagging)

- まず、以下を $b = 1, \dots, B$ について繰り返す
 - ▶ 訓練データから、一様ランダムにブートストラップ標本をサンプリング
 - ▶ ブートストラップ標本から教師付き学習を行い、予測器 f_b を作る
- 最終的な予測器 f は、構築した多数の予測器 $\{f_b\}_{b=1}^B$ を集約して作る
 - ▶ 回帰の場合、 $\{f_b(\mathbf{x})\}_{b=1}^B$ の平均を $f(\mathbf{x})$ とする
 - ▶ 分類の場合、 $\{f_b(\mathbf{x})\}_{b=1}^B$ による投票で $f(\mathbf{x})$ を決める (後述)



バギング>アルゴリズム>投票

分類タスクの場合，バギングにおける集約は投票になる．大きく2種類ある．

- ハードな投票 (hard voting) $\{f_b(\mathbf{x})\}_{b=1}^B$ を数えて，最多得票のクラスを $f(\mathbf{x})$ とする

$$\begin{bmatrix} f_1(\mathbf{x}) = 1 \\ f_2(\mathbf{x}) = 0 \\ f_3(\mathbf{x}) = 1 \end{bmatrix} \rightarrow f(\mathbf{x}) = 1$$

- ソフトな投票 (soft voting) $\{g_b(\mathbf{x})\}_{b=1}^B$ を出力し，平均をとることで $f(\mathbf{x})$ を決める
 - 前提：確率論的アプローチでクラス事後確率を $g_b(\mathbf{x})$ が近似するように学習
 - $\{g_b(\mathbf{x})\}_{b=1}^B$ の平均を $g(\mathbf{x})$ とし， $f(\mathbf{x}) = \tau(g(\mathbf{x}))$ とする (τ は最大事後確率則など)

$$\begin{bmatrix} g_1(\mathbf{x}) = 0.92 \\ g_2(\mathbf{x}) = 0.49 \\ g_3(\mathbf{x}) = 0.90 \end{bmatrix} \rightarrow g(\mathbf{x}) = \frac{g_1(\mathbf{x}) + g_2(\mathbf{x}) + g_3(\mathbf{x})}{3} = 0.77 \rightarrow f(\mathbf{x}) = 1$$

クラス不均衡 > 不均衡下での学習 > アンダーバギング > アルゴリズム


アンダーバギングは、アンダーサンプリングを組み合わせたバギング

■ アンダーバギング (under-bagging)

- まず、以下を $b = 1, \dots, B$ について繰り返す

- ▶ 訓練データから、**ランダムに一定比率で正例と負例をサンプリング**
- ▶ サンプリングしたデータから教師付き学習を行い、予測器 f_b を作る

- 最終的な予測器 f は、構築した多数の予測器 $\{f_b\}_{b=1}^B$ を集約して作る
 - ▶ 訓練済みモデルによる、ハードな／ソフトな投票



【参考】 Wallace, B. C., Small, K., Brodley, C. E., & Trikalinos, T. A. (2011). Class imbalance, redux. ICDM 2011, 754–763.

【補足】 一定比率というのは、例えば正例：負例が 1 : 1 になるようにするなど。


クラス不均衡 > 不均衡下での学習 > 実験 > 設定

不均衡データでの分類を，アンダーバギングを取り入れて学習

タスク・学習戦略

二値分類・クラス不均衡下
での教師付き学習

特徴量	ラベル
x_1	y_1
x_2	y_2
$\vdots$	$\vdots$
$\{(X_i, Y_i)\}_{i=1}^n \stackrel{\text{i.i.d.}}{\sim} p$	



訓練データ

モデル

$g_\theta(x)$ ：順伝播型NN

- リサンプリングした標本ごとに1つずつ予測器作成
- 各層のユニット数などの詳細は割愛
- 出力層の活性化関数はSigmoid

目的関数

サブ標本の負の対数尤度

$$L(\theta) := \frac{1}{|B|} \sum_B \ell((x_i, y_i), g_\theta)$$

- バギングの繰り返し数は50

最適化手法

Adam

(慣性項を用いる確率的
勾配法の一つ)

工夫

アンダーバギング

正例負例の比率は1:1で
ブートストラップ抽出

集約はソフトな投票


クラス不均衡 > 不均衡下での学習 > 実験 > 工夫なしの場合

クラス1をほとんど無視した予測器が学習されてしまう


■ 学習後のモデルに決定規則を合成した予測器 $f_{\hat{\theta}}(x) := \tau(g_{\hat{\theta}}(x))$ の様子

- precision = 0, recall = 0, $F_1 = 0$, 誤分類率=0.02 (全てクラス0の予測)

1の領域は
ほとんどない



分類器としての出力



評価用データでの予測と正解ラベル


クラス不均衡 > 不均衡下での学習 > 実験 > 工夫ありの場合

クラス不均衡に対応した学習で、少数派のクラス1を拾える予測器ができた


■ アンダーバギングで作成した予測器 $f(x)$ の様子

- precision = 0.14, recall = 1.0, $F_1 = 0.24$, 誤分類率=0.02

1の領域がある



分類器としての出力






評価用データでの予測と正解ラベル

クラス不均衡 > 不均衡下での学習 > 実験 > 学習過程

バギングで作成された個別の予測器の様子（適当に3つ）とその訓練サブ標本

- それぞれのサブ標本ではクラス1は半数 → 無視せずにうまく学習できている
- 複数のブートストラップ標本 → 負例のサンプリングにより予測器も多様
 - → 結果としてデータセット全体の情報をうまく使えている



クラス不均衡 > まとめ



クラス不均衡という現象と対策を紹介した。学習ではアンダーバギングが定番。

- クラス不均衡があると、適正な評価や学習の難易度が上がる
 - 評価は precision と recall を見るとよい（これらを統合するFスコアもある）
- **アンダーバギング**：正例と負例を再配合した、仮想的な分布 $p_{\alpha}(x, y)$ を作って学習
 - この場合は負例を大幅に減らして再抽出する = **アンダーサンプリング**する
 - データセット全体を活用するために、これを多数回実行して**バギング**する
- バギングのように、複数の予測器を学習し、それらを上手く組み合わせて予測器を作るアプローチは**アンサンブル学習 (ensemble learning)** という。

【参考】 Wallace, B. C., Small, K., Brodley, C. E., & Trikalinos, T. A. (2011). Class imbalance, redux. ICDM 2011, 754–763.

【参考】 Van Hulse, J., Khoshgoftaar, T. M., & Napolitano, A. (2007). Experimental perspectives on learning from imbalanced data. ICML'07, 935–942.

クラス不均衡 > 不均衡下での学習 > アンダーバギング > 補正

もし $p(y = 1 | \mathbf{x})$ の近似値も得たければ、学習後の補正が必要

- アンダーサンプリングで、次の $p_\alpha(\mathbf{x}, y)$ での誤分類率リスクが小さくなるよう学習

$$p_\alpha(\mathbf{x}, y) := \begin{cases} p(\mathbf{x} | y = 1) \cdot \alpha & (y = 1) \\ p(\mathbf{x} | y = 0) \cdot (1 - \alpha) & (y = 0) \end{cases}$$

- 確率論的分類アプローチでは、 $p_\alpha(y = 1 | \mathbf{x})$ が近似ターゲットということになる
- もし学習済みの g_θ から $p(y = 1 | \mathbf{x})$ の近似値も得たければ、例えば次の式で補正.

$$p(y = 1 | \mathbf{x}) \simeq \frac{1}{\frac{p(y = 0)}{p(y = 1)} \cdot \frac{\alpha}{1 - \alpha} \cdot \left(\frac{1}{g_\theta(\mathbf{x})} - 1 \right) + 1}$$

クラス不均衡 > 不均衡下での学習 > アンダーバギング > 補正の導出

$p(y = 1 | \mathbf{x})$ と $p_\alpha(y = 1 | \mathbf{x})$ の関係式は、次のように導出できる

- ① まず、 $p_\alpha(y = 1 | \mathbf{x})$ を、 p に関する量だけで表せるように式変形していく

$$p_\alpha(y = 1 | \mathbf{x}) = \frac{p_\alpha(\mathbf{x}, y = 1)}{p_\alpha(\mathbf{x})} = \frac{p(\mathbf{x} | y = 1) \cdot \alpha}{p(\mathbf{x} | y = 1) \cdot \alpha + p(\mathbf{x} | y = 0) \cdot (1 - \alpha)} = \frac{1}{1 + \frac{p(\mathbf{x} | y = 0)}{p(\mathbf{x} | y = 1)} \cdot \left(\frac{1}{\alpha} - 1\right)}$$

- ② 続いて、 $\frac{p(\mathbf{x} | y = 0)}{p(\mathbf{x} | y = 1)}$ を $p(y = 1 | \mathbf{x})$ で表すために、全く同じ式変形をしておく

$$p(y = 1 | \mathbf{x}) = \frac{p(\mathbf{x}, y = 1)}{p(\mathbf{x})} = \frac{p(\mathbf{x} | y = 1) \cdot p(y = 1)}{p(\mathbf{x} | y = 1) \cdot p(y = 1) + p(\mathbf{x} | y = 0) \cdot p(y = 0)} = \frac{1}{1 + \frac{p(\mathbf{x} | y = 0)}{p(\mathbf{x} | y = 1)} \cdot \frac{p(y = 0)}{p(y = 1)}}$$

クラス不均衡 > 不均衡下での学習 > アンダーバギング > 補正の導出

$p(y = 1 | \mathbf{x})$ と $p_\alpha(y = 1 | \mathbf{x})$ の関係式は、次のように導出できる

■ ②から次を得られる

$$\frac{p(\mathbf{x} | y = 0)}{p(\mathbf{x} | y = 1)} = \frac{p(y = 1)}{p(y = 0)} \cdot \left(\frac{1}{p(y = 1 | \mathbf{x})} - 1 \right)$$

■ これを①に代入して,

$$p_\alpha(y = 1 | \mathbf{x}) = \frac{1}{1 + \frac{p(\mathbf{x} | y = 0)}{p(\mathbf{x} | y = 1)} \cdot \left(\frac{1}{\alpha} - 1 \right)} = \frac{1}{1 + \frac{p(y = 1)}{p(y = 0)} \cdot \left(\frac{1}{p(y = 1 | \mathbf{x})} - 1 \right) \cdot \left(\frac{1}{\alpha} - 1 \right)}$$

■ モデル $g_\theta(\mathbf{x})$ は左辺を近似するものになっているので, $g_\theta(\mathbf{x}) \simeq p_\alpha(y = 1 | \mathbf{x})$ として解くと,

$$p(y = 1 | \mathbf{x}) \simeq \frac{1}{\frac{p(y = 0)}{p(y = 1)} \cdot \frac{\alpha}{1 - \alpha} \cdot \left(\frac{1}{g_\theta(\mathbf{x})} - 1 \right) + 1}$$