

分布シフト

分布シフト




分布シフトという状況について解説

- 訓練データの生成分布と，学習済みモデルを実用する場面でのデータの出方が異なる場合に，性能が思ったように出ないことが知られている
- その理由や，現象について説明（対策はこの講義では深掘りしない）

分布シフト > 統計的学習とデータの確率分布

統計的学習では、必ずしもデータ空間の全域で性能が出るように学習しない

- データの生成分布には偏りがある（出やすいデータ・出にくいデータがある）



- 訓練時の分布によって、どこを重視する予測器になるかが変わる

$$R(f) = \int \ell(y, f(x)) \cdot p(x, y) dx dy$$

- リスク関数は、データの生成分布での損失の重み付き平均

分布シフト

訓練データの分布と，評価時の分布が違ふと何が起こるか？

■ 分布シフト (distribution shift)

- 学習データの生成分布 p_{train} と，予測器の実用場面での分布 p_{test} が異なる状況

$$\{(X_i, Y_i)\}_{i=1}^n \stackrel{\text{i.i.d.}}{\sim} p_{\text{train}}(x, y) \neq p_{\text{test}}(x, y)$$

- 本来最小化したいリスクと異なるリスクの最小化になる→よい性能が出ない！

$$R_{\text{train}}(f) \neq R_{\text{test}}(f)$$

■ 例)

- クリック予測を新しい顧客層に適用，医療画像診断で疾患の発生率が地域によって異なる，商品カテゴリやトレンドの変化でモデルが古くなる

Concepttest（理解を試すクイズ）



次のうち、分布シフトが主な問題となる状況はどれか？

A	学習時と同じ環境でテストする	B	新しい顧客層に適用する
C	ランダムにサンプルされた追加データでテストする	D	モデルを改善したがデータは変わらない

【答え】 B（新しい顧客層＝分布が変わる可能性）

分布シフト > 類型

分布の異なり方に，構造を仮定することがある

- 共変量シフト (covariate shift) : 特徴量の分布だけが異なる ($p(y|x)$ は同じ)

$$p(y|x) \cdot p_{\text{train}}(x) \longleftrightarrow p(y|x) \cdot p_{\text{test}}(x)$$

- ラベルシフト (label shift) : ラベルの分布だけが異なる ($p(x|y)$ は同じ)

$$p(x|y) \cdot p_{\text{train}}(y) \longleftrightarrow p(x|y) \cdot p_{\text{test}}(y)$$

- コンセプトシフト (concept shift) : 条件付き分布だけが異なる ($p(x)$ は同じ)

$$p_{\text{train}}(y|x) \cdot p(x) \longleftrightarrow p_{\text{test}}(y|x) \cdot p(x)$$

- 一般の分布シフト : $p_{\text{train}}(x, y) \neq p_{\text{test}}(x, y)$


分布シフト > 共変量シフト

訓練時とテスト時でデータの入力分布が異なる，という分布シフト

■ 共変量シフト (covariate shift)

$$p(y|x) \cdot p_{\text{train}}(x) \quad \longleftrightarrow \quad p(y|x) \cdot p_{\text{test}}(x)$$

- 訓練時に注力した辺りと，評価時に入力されやすいデータが異なる




分布シフト > ラベルシフト

訓練時とテスト時で，ラベルの出現比率が異なる，という分布シフト


- ラベルシフト (label shift)，クラス事前分布シフト (class-prior shift)

$$p(x|y) \cdot p_{\text{train}}(y) \longleftrightarrow p(x|y) \cdot p_{\text{test}}(y)$$

- クラスごとのデータの生成分布は同じだが，その混合比率が変わる



訓練データの分布



評価データの分布


分布シフト > コンセプトシフト

訓練時とテスト時で、ラベルの条件付き分布だけが異なるという分布シフト


■ コンセプトシフト (concept shift)

$$p_{\text{train}}(y|x) \cdot p(x) \quad \longleftrightarrow \quad p_{\text{test}}(y|x) \cdot p(x)$$

- 入力の分布は同じだが、同じ特徴量 x に対するラベルの付き方が変わる



$$p_{\text{train}}(y = 1 | x)$$




$$p_{\text{test}}(y = 1 | x)$$


分布シフト > 性能の劣化

外挿的（extrapolative）な場合


$p(y|x)$ は共通



$p(x)$ が変化
(重複は少ない)



訓練時の $p_{\text{train}}(x)$ では
概ねよい予測器が学習



評価時の $p_{\text{test}}(x)$ では
当然大幅に外れる

分布シフト > まとめ



学習時と予測時の分布が異なると、思った通りの性能が出ない場合がある

- データの質が重要！と言われるゆえんの1つ
 - 実用場面でのデータ生成分布と、なるべく近い分布に従うデータを使う
- それができない場合は、分布の違いがあることを加味して学習する方法を工夫する必要がある（**転移学習, transfer learning**）
 - 本講義ではあまり大きく扱わない