

第5回

手嶋毅志 (Takeshi Teshima)

質問と回答

加算対象ではないその他の質問・コメント

期待値が集団から離れた位置になるのは初めて知って、感覚的に集団がある位置になりそうという考えがあったのでとても面白いと思った。

嬉しい感想！ありがとうございます。そうですね、例えば「所得」の統計を議論するときは、期待値ではなく中央値などのほうが、好んで使われます。超高所得者が存在するためです。

加点对象の質問

スライドでは「モデルは関数近似器である」と表現されていましたが、与えられたモデルで近似ターゲットにどれだけ近づけるかを事前に評価・予測するような理論や手法はありますか？

素晴らしい質問ですね！

完全なものとは言えませんが、理論や手法はいくつか存在します。

①リスク関数と近似度合いの関係，②モデルの表現能力解析，③スケーリング則，の3つについて説明します。

質問（続き）

① リスク関数と近似度合いの関係

まず、基本的には、リスク関数の値が減少するほど、近似ターゲットに対して近づいたということになります。

「リスク関数を最小にする予測器」が近似ターゲットですが、多くの損失関数では、リスク関数が近似ターゲットとの近さを測る指標にもなっている、ということです。

厄介な注意点：

近似ターゲットでのリスクの値は0とは限りません。

仮にそれが0だったなら、リスクの値をそのまま近似度合いとして使えますが、残念ながらそれは難しいですね。

質問（続き）

①モデルの表現能力解析

モデルがどれくらい複雑な関数を表せるのか、という理論的な研究があります。その代表例は「普遍近似定理」（universal approximation theorems）というタイプの定理です。

普遍近似定理の基本的なパターンは、

「一定の性質を満たす任意の近似対象関数 f^* と、任意の一定の条件を満たす入力範囲 K と、任意の許容誤差 $\varepsilon > 0$ に対して、今考えているモデルで表せる関数 f_{θ^*} であって K の上で測った f^* と f_{θ^*} の相違度 $\text{diff}_K(f^*, f_{\theta^*})$ が ε 以下となるものが存在する」

大雑把には「モデル $\mathcal{M}$ は、集合 $\mathcal{F}$ に属する関数なら任意精度で近似できる」です。

質問（続き）

②スケーリング則

スケーリング則は、モデルのサイズ（パラメータ数）、データセットのサイズ、学習に使われる計算量といったリソースを増やしていくと、モデルの性能（通常は損失関数の値で評価されます）が冪乗則に従って改善していくという経験則です。

この講義でも終わりがけに出てきます。経験則ですが、LLMなどの作製において活用されている、ある種の「法則」です。

モデルの表現能力に限った法則ではないですが、「モデルのサイズを増やしていくとき、近似ターゲットに対する近似限界のようなものが訪れることはなく、性能改善していく」ことも主張している（十分条件を主張）、という意味で関係します。

加対象の質問

損失関数の選択によって近似ターゲット（例：条件付き期待値・中央値・分位点）が変わるのですが、実務で損失関数を選ぶ際には、どのような基準や判断軸を設けるべきでしょうか？また、近似したい関数が明確な場合に、それに対応する損失関数をどのように設計・導出するのが一般的なのでしょうか？

いい質問ですね。①実務で損失関数を選ぶ方法，②近似したい関数が明確な場合。

①損失関数を選ぶ際の基準や判断軸

まずは標準的ないくつかの選択肢を知っておいて，その中から選ぶことが多いです。そこから先は，応用ごとの創意工夫の世界になると思います。（つづく）

質問（続き）

回帰の場合

二乗誤差が標準的ですが、絶対誤差を使うこともよくあります（外れ値に対して頑健なため）。

分類の場合

まずは0-1損失が標準的です。多クラス分類なら、費用感応的損失まで考えてもよい（＝クラスの取り違えについて重みを設ける）と思います。

もう一步丁寧に考えるなら、クラス不均衡に対策を施した損失もあります（講義でも少し触れる予定です）。

実務上は、損失関数によるリスク定義～学習という枠組みに、さらに追加する形で、いくつかの指標（他の損失や、その他の側面を評価する指標）をチェックしてから学習後のモデルを使うことが多いです。これも講義の後半に少し触れます。

質問（続き）

②近似したい関数が明確な場合に、対応する損失関数の設計・導出方法は？

残念ながら、一般的な方法はないように思います。実用上は、既によく知られた関数を近似したいことが多いので、自力で設計することは稀だと思います。
（有用な新しい近似対象と、対応する損失関数を発明したら、論文化しましょう）

なお、実は、金融工学でよく使われる「条件付きVaR（conditional value-at-risk）」と呼ばれる関数は、対応する損失関数が存在しないことが知られています。

【参考】 Gneiting, T. (2011). Making and evaluating point forecasts. Journal of the American Statistical Association, 106(494), 746–762. <https://doi.org/10.1198/jasa.2011.r10138>

【参考】 Osband, K. H. (1985). Providing Incentives for Better Cost Forecasting [PhD thesis]. University of California, Berkeley.

【参考】 Steinwart, I., Pasin, C., Williamson, R., & Zhang, S. (2014). Elicitation and identification of properties. Proceedings of The 27th Conference on Learning Theory, 482–526. <https://proceedings.mlr.press/v35/steinwart14.html>

加対象の質問

確率論的分類において、誤分類率リスクはどれくらいであれば実用するうえで低いと言えるのでしょうか。

良い質問ですね！

つまらない回答としては「ケースバイケース」ということになりますが……

重要な考え方として「ベースラインを確立する」という話を説明します。（つづく）

質問（続き）

実用の場面でどの程度の性能が出れば十分と見做されるかはケースバイケースです。

例えば、医療の診断で「70%ぐらい当たります」と言われたら、不安だ……と思ってしまいますが、不動産の購入者予測で「購入するかどうか60%ぐらいで当てられます」と言われたら、1件の購入単価が高いため、そのモデルを使って営業をかける価値はあるかもしれません。外れた場合の実害の大きさによって、許容不可能な誤分類率の水準は変わります。

また、分野ごとに「このぐらいは期待できる」という誤分類率の程度も、証拠はないですが、多少の暗黙知がある場合もあります。このぐらいのタスクなら誤分類率は1%未満までいけるはず、というような。

質問（続き）

そうは言っても「やってみるまでどれぐらいの性能が出そうか全く分からない」という場面も多いです。そこで重要になるのが「ベースラインを確立する」という考え方です。

ベースラインとは、「基準となる予測手法や、そのときの予測性能（リスク）」のこと。重要なベースラインとしては「単純集計モデル」や「人間の精度」があります。

単純集計によるモデル

特徴量をいくつかの値で区切って、その中でのラベルの分布を見ます。例えば「 x_1 の値を10ずつに区分けする。そして、その区分けでの訓練データのラベルの分布を見て、最も頻度が高かったラベルを予測ラベルとする」など。

予測器としては（おそらく最も）単純ですが、だからこそ「最低限達成できてほしい性能」を考える助けになります。

質問（続き）

人間の精度

人間の専門家の精度をベースラインとする場合もあります。例：医療での画像診断
これをベースラインとするということはつまり、人間の医師による予測の誤分類率を基準として考える、ということです。

例えば人間の医師の誤分類率が1%未満のタスクで、学習したモデルが2%の誤分類率なら、まだまだ改善の余地があることが分かりますね。

元の質問に戻ると「誤分類率リスクはどれくらいであれば実用するうえで低いと言えるのでしょうか。」でしたが、実用上は逆の考え方をして「これくらいは達成できていなければ性能が足りない」と判断できる基準を用意する（基準を確立する方法のアイデアを出す）と考えると、一步前進できることが多いように思います。

出席確認

本日の出席確認番号は……

2025

告知

- 小テストは月曜日に公開します
- シラバスを更新しました（内容を組み替えました）

ロードマップ

