

# 第6回

---

手嶋毅志 (Takeshi Teshima)

# 質問と回答

# 加算対象ではないその他の質問・コメント

---

期末テストはいつの予定ですか？またそちらは対面の予定でしょうか？

時間についてはまだ決まっていません（教務課の方々により調整）。通常は講義と同じ曜日・時間帯となるそうです。形式は**対面**で各自のデバイス使用とする予定ですが、未確定です。



# 加点对象の質問

ChatGPTのような生成AIに質問を尋ねると自身の過去の質問状況等を考慮して自身に即した回答を生成してくれるが、それも分類タスクを活用している結果なのでしょうか。

前々回、次単語予測も分類タスクの例として挙げましたが、あれはミスリードなので撤回します。ChatGPTなどを実現しているのは、生成タスクと呼ばれるタスクです。ただし、ChatGPTなどでは、生成タスクを実現する手段として、確率論的分類と同じ「条件付き確率の近似」が行われています。そのため、学習法もここで学ぶ手法と基本的に同じです（講義の終盤で具体的に話します）。（続く）



# 質問（続き）

「自身の過去の質問状況等を考慮して自身に即した回答を生成してくれる」という点については、こういった仕組みです。

ChatGPTなどでは、「テキストを入力として受け取って、その続きのテキストを生成する」というタスクが実行されています。

これを利用して、例えば次のようなテキストを入力することで、ユーザーに合わせた解答生成が実現されています（ユーザーが最後に入力した内容は太字の部分）。

入力

アシスタントとユーザーの会話：

- ・ユーザー「この前、初めてオムライス作ったんだ！」
- ・アシスタント「いいですね！うまくできましたか？」
- ・ユーザー「**見た目はイマイチ**だけど味はよかった！もっときれいに作るコツってある？」
- ・アシスタント「

# 加対象の質問

分類タスクに関して「近年はこちらが多い」とありますが、近年確率論的アプローチが主流になっている理由は何ですか？

歴史的経緯によるところが大きいと思うので、スッキリしないかもしれませんが、強いて言うなら以下の点は挙げられるかもしれません。

- ①多クラスへの拡張がより自然にできる
  - ②副産物として確率値が得られることが嬉しい場合がある
- (続く)

# 質問（続き）

## ①多クラスへの拡張がより自然にできる

決定論的な分類アプローチの手法（サポートベクトルマシンなど）では，多クラス分類への対応は2クラスの手法を複数回適用する方法で賄われることが多く，多クラス分類を自然に扱う方法はなぜかあまり発展していません．

### ■ 一対一法（One-versus-One, OvO）

「クラス  $k$  か，クラス  $l$  か」という2クラス分類器を  $K(K-1)/2$  個作成する

### ■ 一対他法（One-versus-the-Rest, OvR）

「クラス  $k$  か，クラス  $k$  以外か」という2クラス分類器を  $K$  個作成する

（ただし，決定論的な分類アプローチの主要手法の中でも，「決定木モデル」（decision trees）に基づく手法は多クラスも自然に扱うので，一概には言えません）



# 質問（続き）

②副産物として確率値が得られることが嬉しい場合がある

ラベルの予測に加えて、予測の確信度を出力したい場合

純粋な分類タスクではなく「分類タスク＋不確実性の定量化タスク」にしたい場合  
近似したクラス事後確率を「モデルの自信の度合い」だと思えることができる

例えば「不確実性の度合いが高いときはユーザーに『自信がありません』と表示する」などの使い方が考えられる

# 加点对象の質問

KLダイバージェンス以外にも分布間の距離を測る指標は色々あるとのことでしたが、分類タスクにおいて派生もとしてKLダイバージェンスを採用する長所と短所はなんですか？

最尤法は古典的な統計モデルの推定の手法としてはある種の最適性（大サンプルの極限においてサンプル効率が理論値に収束）を持っていることに由来して使われています。ただし、機械学習の文脈では、条件付き確率の近似（・推定）のための損失関数の選択はハイパーパラメーターにすぎないので、これを使うべきとする絶対的教条があるというほどではありません。



# 質問（続き）

実際のところは、各所でちゃんと長所・短所が検討された結果として使われているというよりも、実際の応用で成功例があるので、「とりあえずKLダイバージェンス」という選択が行われている、というのが実態に近いと思います。

一応

- ・ KLダイバージェンスによる分布近似は平均探索的（mean-seeking）
- ・ 逆KLダイバージェンスによる分布近似は最頻値探索的（mode-seeking）

といわれる性質はあります。また、KLダイバージェンスでモデルの出力した確率値に0があると発散してしまいますね（ $-\log q(y|x)$  がある）。そのため、0を避ける傾向があるという共通理解はあります。

# 加点对象の質問

ソフトマックス、交差エントロピー、そして決定規則としての最大事後確率則の組み合わせが、多クラス分類の場合でも唯一の方法ではないと注意がありました。多クラス分類における代替の組み合わせの例を、仮説上でも（可能であれば実世界のものでも）挙げていただけますか？そして、それは今回説明した標準的なアプローチと比較して、どのような実用的な利点や欠点があるのでしょうか？

よく言われるのは、ガンマダイバージェンスから導出される損失関数

$$\ell((\mathbf{x}, y), q) = \sum_{k=1}^K q(Y = k | \mathbf{x})^{\gamma+1} - (\gamma + 1)q(y_i | \mathbf{x}_i)^{\gamma}$$

などは（見ての通り）モデルが確率0を割り当てたクラスがあっても発散しないなど。

# 質問（続き）

---

とはいえ、実際は「まずはKLダイバージェンスから始めて、さらなる性能改善などの可能性がありそうであれば、別の損失関数／条件付き確率近似のための損失関数も検討する」という方法がよいと思います。

（研究レベルでは様々なものが探索されていて、一長一短ありますが、初手からそれらを使うことは、ほとんど無いように思います。あくまで改善の打ち手ですね）



# 加対象の質問

ロジスティック関数と標準正規分布の類型分布関数はどちらも出力の範囲が0-1で大差がないように思えるのですが、なぜ使用頻度に差があるのでしょうか。

計算の手間の違いが大きな理由だと思います。標準正規分布の累積分布関数は、
$$\Phi(z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^z e^{-\frac{t^2}{2}} dt$$
という数値積分を毎回行わないと出力が得られませんが、ロジスティック関数  $\sigma(z) = (1 + e^{-z})^{-1}$  のほうは、実用上いくらかマシですね。

# 出席確認

本日の出席確認番号は……

2025


# 告知

---

- 小テストは月曜日に公開します
- ※重要※
  - 次回, 5/30 (金) は, オンラインのみで開講します  
(Zoomの用意をしておいてください)



# ロードマップ








# 分類＞モデルの作り方

## 分類タスクのためのモデルの基本の作り方

- 離散的なラベルを出力できるモデルを作るために……




- 2つの部品を組み合わせて実現：スコアリングモデルと，決定規則





# 確率論的分類＞モデルの作り方

## 確率的分類アプローチのモデルの基本の作り方

- 確率論的分類では、スコアリングモデルの出力が確率値となるように……



- さらに  $g_\theta$  の部分を2つの部品で構成する：中間スコアと確率値への変換



$\sigma$  の例