

第8回

手嶋毅志 (Takeshi Teshima)

質問と回答

加対象の質問

講義内でデータの種類について触れていましたが、文字起こしをした際に文字化けしてしまうのは、音声データがうまく文字コードに対応していないという認識で正しいですか。

文字化けは、「文字コードX」を想定して記録されたテキストデータを、異なる「文字コードY」で表示してしまった場合に起こります。

例) いい天気だね→['227129132', …… , '227129173']→縹縹螟ㄥ琬励□縹ㄥ

一方、**文字起こし**の失敗は（通常は）文字コードとは別の理由が多いと思われます。

質問（続き）

文字起こし機能が解いているタスクは、

「特徴量は音声，ラベルはテキスト」

という予測タスクであり，「変換の失敗」は単純に「予測を外した」ということです。その主要因は，「音声が曖昧だった」「そもそもテキストに対応しない音声だった」「モデルの性能が不十分だった」など色々な場合が考えられます。

「そもそもテキストに対応しない」は，音声は波形という連続的なデータ，テキストは離散的なデータなので，一瞬それらしくも思えますが，しかし，明確な単語や，ある程度長い時間の発話であれば，明確な正解ラベルがあることが多いかと思います。

それなので，離散 vs 連続という構造的な難しさや，文字コードのようなデータ表現の問題というよりは，モデルの性能不足ということのほうが多そうです。

出席確認


本日の出席確認番号は……

2025

告知


- 小テストは月曜日に公開します

ロードマップ



これまでのあらすじ

- ニューラルネットワークという柔軟な道具を手に入れた



- 最終層の手前までを特徴写像 ϕ だと思えば、特徴量変換も含めて一気通貫で学習可能なモデルともいえる
- 対して線型モデルでは、 ϕ で特徴量に変換 $\rightarrow \theta^\top$ を掛けて出力 $\rightarrow \theta^\top \phi(x)$
- これは人類にとって重要な道具になった。一体なぜ重要になったのか？