

第9回

手嶋毅志 (Takeshi Teshima)

質問と回答

加対象の質問

事前学習タスクとして使用するデータやタスクの選び方によって、精密調整後の性能にどのような影響がありますか。

①データの選び方

同じ種類のデータでの事前学習を行うほうがよいという傾向が知られています。
例えば、自然画像の分類タスクが最終目的なら、事前学習も自然画像を使って行われているほうがよい、というのは感覚的にも納得できると思います。
(つづく)

質問（続き）

実際，例えば，約100万枚の「IMAGENET」データセット（自然画像の1000クラス分類のラベル付きデータ）での事前学習は，性能にほとんど利益をもたらさないという研究があります（Raghu et al., 2019）

自然画像分類と，医療画像系のタスクは以下のような違いがあります：

- ・多くの医療画像タスクでは，大きな画像から始め，**局所的なテクスチャの変化**を用いて病状を特定する．それに対して，自然画像分類では画像の全体的な被写体が重要
- ・標準的なIMAGENETの1000クラス分類設定よりもクラス数が大幅に少ない（糖尿病網膜症診断では5クラス、X線写真からの胸部病理診断では5～14クラス）

【参考】 Raghu, M., Zhang, C., Kleinberg, J., & Bengio, S. (2019). Transfusion: Understanding transfer learning for medical imaging. In Proceedings of the 33rd International Conference on Neural Information Processing Systems (pp. 3347–3357). Curran Associates Inc.

質問（続き）

②タスクの選び方

事前学習タスクも様々なものが提案されていて、「こちらが良い」「あちらが良い」と数多くの論文で比較されています。近年は対照学習という事前学習手法が成功していますが、今後変わる可能性もあります。
同じデータでも事前学習の方法によって、10%近く誤分類率が変わったりします。

Method	Architecture	Param (M)	Top 1
<i>Methods using ResNet-50:</i>			
Local Agg.	ResNet-50	24	60.2
MoCo	ResNet-50	24	60.6
PIRL	ResNet-50	24	63.6
CPC v2	ResNet-50	24	63.8
SimCLR (ours)	ResNet-50	24	69.3

【補足】「Top 1」とある値は正答率（=1 - 誤分類率）。【参考】Table 6 of Chen et al. (2020). A simple framework for contrastive learning of visual representations. Proceedings of the 37th International Conference on Machine Learning, 1597–1607.


加点对象の質問

カーネルトリックは超高次元パラメータを調整することで機械学習のモデルに応用可能になっていると思います。そこで疑問なのですが、パラメータを調整することで特定の訓練データに対して高い精度を発揮するよう、ある意味で「モデルにとって都合の良い」解釈を学習しているに過ぎないのではないかと思います。結果として、元の特徴量と予測結果との間の因果関係が不明瞭になり、予測根拠の直感的な解釈を本質的に困難にしているのではないかと考えております。


鋭い質問ですね。カーネルトリックは別の意味で、これはカーネル法の質問ですね。
「モデルにとって都合の良い解釈を学習」は、データごとにパラメーターを持たせるために出てくる懸念ですね。
実はここで、類似度を表す**カーネル関数の選定**が非常に重要な役割を果たします。

質問（続き）

“有効範囲が狭い”類似度関数で、かつデータの量が少ないと、確かに訓練データ点の上だけで辻褄を合わせやすくなります。



しかし、有効範囲が広い類似度関数ならば、周囲のデータへの予測も同時に上手くいくようなパラメーターであることが求められ、自由度が制限されます。




では、どのような類似度関数を使うか？ここが肝心になります。

質問（続き）

よく使われるカーネル関数には，“影響範囲”を調整するようなハイパーパラメーターがついていることが多いです。「ガウシアンカーネル」の場合は，バンド幅と呼ばれる $h > 0$ があります。

$$f_{\theta}(x) = \sum_{j=1}^n \theta_j \exp \left(-\frac{\|x - x_j\|^2}{2h^2} \right)$$



あとはモデル選択の問題に帰着されます。訓練データで辻褄を合わせている = 過適合している，ということですね。また，L2正則化も同様にズルをできないようにする効果を持ちます。

【実験ソースコード】[番号]_gaussian_kernel.ipynb 【補足】 $h > 0$ はバンド幅（bandwidth）とよばれるハイパーパラメーター。モデル選択規準で選ぶこともあるが，median heuristic や Silverman rule といった指針が知られており，これらで選ぶこともある。

質問（続き）

元の質問の後半「特徴量と予測結果との間の因果関係が不明瞭になり、予測根拠の直感的な解釈を本質的に困難にしているのではないかと考えております。」

これは、今お話ししたのとは別の良い質問・疑問点ですね。

カーネル法に限らず、データ量と同等、あるいはデータ量を超えるほどのパラメータ数を持つモデルでは、予測根拠の解釈は難しい課題です。

ただ、そもそも予測根拠の解釈は必ずしもメカニズム的な説明でなくても良いかもしれませんね。「知っている事例とこのように似ているので、予測値はこの値とする」という言明は、法則性とは異なる種類の予測の根拠とみなせる可能性はありますね。さらには、予測根拠の解釈は不要で、ただ汎化すれば何でも良いという立場もありえます。

加点对象の質問

私はユークリッド距離しか知らなかったのですが、マンハッタン距離を用いた方が良い場合はあるのでしょうか？

一般的なことを言えば、超高次元特徴量ではユークリッド距離と比べて「マシ」な傾向はあるはずですが……（今回お話しする「次元の呪い」が直接的に関係します）。今回をきっかけに調べてみたところ、「この分野ではマンハッタン距離が良い」と結論付けられるような強力な話は、意外に見つかりませんでした。理由の一端は、今回お話しする「類似度関数のための表現学習」の進歩にあるかも。

【参考】 Aggarwal et al. (2001). On the surprising behavior of distance metrics in high dimensional spaces. Proceedings of the 8th International Conference on Database Theory, 420–434. 【参考】 Parry et al. (2010). K-Nearest neighbor models for microarray gene expression analysis and clinical outcome prediction. The Pharmacogenomics Journal, 10(4), 292–309.

加点対象ではないその他の質問・コメント

学期末テストの形態について詳しく聞きたいです。

到達度評価について、正式な決定はまだ通知が来ていないので、もう少しお待ちください。

LETUS上で、小テストと同様のシステムで実施予定です。また、「オンライン同期」の形態を選択しているので、教室への出席は不要になる見込みです。

講義資料を見ることは可として実施します。問題の傾向は小テストと近いものの予定です。

とはいえ、どこに何の話が書いてあるか、全体像がわかっているほうが有利になると思います。

出席確認

本日の出席確認番号は……

2025

告知

- 小テストは月曜日に公開します

ロードマップ

