

第12回

手嶋毅志 (Takeshi Teshima)

質問と回答

加対象の質問

トークンの埋め込みについてなのですが、単語の意味は文脈で変わったりすることから言語によって難易度は変わったりしませんか？（例えば英語より日本語の方が難しいとか）

すごく面白い質問ですね。「日本語はハイコンテキストで難しい」などの話ですね！

「文脈」にもいくつか階層があると思います。いわゆる日本語の行間を読むのが難しいとされるのは、文化的文脈などを指しているように思います。
言語の難しさは多面的で、英語のほうが文脈依存になる面もあるかも。（続く）

質問（続き）

言語によって、意味が文脈に頼る度合いは異なります。
例えば英語には、語順を変えると意味が変わってしまうという側面があります。

The dog followed the officer. （犬が警察官についていった）

The officer followed the dog. （警察官が犬についていった）

意味が逆になってしまいました。これは、孤立語と呼ばれる種類の言語の特徴です。

（英語は主に屈折語に分類されますが、孤立語の特徴も持っています。もっと典型的な孤立語としては中国語などがあります。）

対して日本語のように「警察官に」「犬が」と文法的な役割のある接辞を付加して文を作る言語（膠着語）では、語順に左右されずに意味がある程度決まりますね。

質問（続き）

こういった言語の性質を考えていくと、一概に「この言語が難しい」ということは難しく、「この言語はこの側面においては難しい」というように、どの特性で難しいのかを考える必要がありそうに思えてきます。

ハイコンテキストさや、省略の多さ、多義性、などについて、何か良い定量化の方法を思い付けたら研究課題になりうるかもしれないぐらい、面白い疑問で良いですね。

ところで、実際に、現時点で英語と比べて日本語などの言語でモデルの性能が低い傾向があるということは実証的に知られています。こういった話（学習の難易度）で、まず議論に上がることが多いのはデータ量です。

性能差が、果たして言語自体の難しさから来るのか、それともデータ量の不足に起因するのか、ということはよく議論されています。

質問（続き）

これに対して、自然言語処理のトップクラスの国際学会の一つ「COLING 2025」の Best Long Paper賞 の Arnett and Bergen (2025) では次の結果が報告されました：

「形態的に複雑な言語に対して言語モデルの性能が低いのは、言語の難しさではなく、学習データ量の測定に偏りがあるからである。」

文字が複雑なため、日本語などでは英語などの言語と比べて「同じ内容を表現するためのバイト数」が異なります。そのため、思っているより実質的なデータの量が少ないことが起きていたようです。言語そのものの難易度というより、データ量ということのようですね。

【参考】 Arnett, C., & Bergen, B. (2025). Why do language models perform worse for morphologically complex languages? In Proceedings of the 31st International Conference on Computational Linguistics (pp. 6607–6623). Association for Computational Linguistics.