

# 第13回

---

手嶋毅志 (Takeshi Teshima)

# 質問と回答

# 加対象の質問

スマートフォンで撮影した写真が、自動的にアルバムに分類されたりタグ付けされたりする際、VAEのような技術が使われているのでしょうか。

また、「この写真は楽しそう」「これは悲しそう」といった写真の中の感情や状況をAIが正確に読み取り、それを元により高度な出力を行うことは可能でしょうか。

それらはいずれも、画像を入力とする分類系のタスクですね。

アルバムの分類やタグ付けは、複数のアプローチが併用されていると思います。

- ・アルバムへの分類……CNN等での画像分類など（画像のシーン分類タスク）
- ・人物のタグ付け……表現学習による類似度の学習（1:Nの顔認証タスク）


今は今回話す「マルチモーダルな共通埋め込み」も使われている可能性があります。

# 加対象の質問

BERT系について、事前学習で学習対象トークンからランダムに15%を選択とありますが、この15%には何か意図があるのですか？


BERTの学習方法は、詳しく説明しませんでしたでしたが、よく見ると次の通りです。

①まず訓練データのトークンから15%を選ぶ（仮にここでは訓練トークンと呼ぶ）




# 質問（続き）

- ②続いて，選ばれた訓練トークンを3種類にランダムに分ける：  
80%は[MASK]に置換，10%はランダムなトークンに置換，10%は元のまま変えない



- ③そして，訓練トークンで，本来のトークンを正解ラベルとして確率論的分類の学習



# 質問（続き）

では、15%にどのような意味があるか？あくまで経験則が広まった状態です。実装当時の著者らによる「文脈用の情報を十分に残せる」かつ「学習シグナルを十分に確保できる」という、ほどよい折衷だったようです。

比較的小さいモデルでは、現在も15%が標準なようです。一方、大きなモデルでは30～40%に引き上げると性能が良くなるという知見が出てきているようです。

なんと、この「15%が本当に良いのか？」を主題にした論文があるほどです。（大きいモデルでは40%のほうがよかった、という報告になっています）

【参考】 Wettig et al. (2023). Should you mask 15% in masked language modeling? In Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics (pp. 2985–3000). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2023.eacl-main.217>

# 加算対象ではないその他の質問・コメント

---

試験はオンライン同期形式とのことですが、教室での受験が必須でしょうか？自宅やその他の場所からの受験は認められていますか？

**積極的に自宅等での受験を推奨**します。教室は確保されていますが、講師含め教室にはいない予定ですので、教室での受験は**非推奨**です。（場所によらず、Zoomでの参加必須です）