

第14回

手嶋毅志 (Takeshi Teshima)

質問と回答

加対象ではないその他の質問・コメント

到達度評価について質問です。レジュメはパソコン上で見ても良いのですか？

はい、（印刷不可の設定となっているので）レジュメはパソコン上で見て頂ければと思います。通信速度に不安のある方は、事前にタブで開いておくともいかもしれません。

マルチモーダルモデルにはどのような限界や課題があるのか具体的に聞きたいです。

現在発展中の領域なので、より多くのモダリティを統合したり、性能を更に上げたりといったこと自体が基本的な課題だと思います。限界に直面する前の、未完成の時期ということです。

加点对象の質問

別の講義で、人間のホットスクリーク（高インパクトな結果が短期間に集中して生まれる現象）は「探索 → ホットスクリーク → 深化」の流れをたどるという話を聞きました。今回の授業で、大規模言語モデルの創発的能力が閾値を超えると突然出現するとありましたが、この能力は人間の創造性と似た側面があると考えられるでしょうか？この能力はその後深化したりするのでしょうか？

確かに、なんとなく似ている気がしますね。
どちらも「量的な変化が質的な変化を生む、という仕方で起きる相転移的現象」という点では似ているかもしれません。ただ、ここから意義のあるアナロジーを見出せるかどうかは、真の意味で背後のメカニズムに共通性があるのかどうか次第ですね。
良い疑問の入り口だと思いますが、そこはまだよく分かりません。

【補足】 このページは加点对象です。

【参考】 言語モデルの背後の仕組みについて考えるうえで、 <https://joisino.hatenablog.com/entry/physics> などの記事を読んでも面白いかもしれません。

加点对象の質問

マルチモーダルモデル関連について、今回の講義と直接関係ないかもしれませんが一点質問します。ChatGPTなどに教科書の写真を撮って尋ねたりするときに、.jpegのままだと文字を認識してくれないのでOCR加工などをしてひと手間加えています。画像データ内の文字をそのまま認識してくれたら楽だなと感じるのですが技術的には可能なのでしょうか？

はい，マルチモーダルモデルによるOCR（画像からの文字認識）は，すでに商用レベルの性能で実用化されています。

ChatGPTの場合に，うまく認識してくれない原因はいくつか考えられます。
（続く）

質問（続き）

①まず一番可能性が高そうなのは、写真の解像度の問題です。解像度は、dpi（1インチあたりの点の数）という単位で計ります。一般に300dpi程度あれば、大規模なマルチモーダルモデルでの読み取り性能が良いようですが、150dpiまで下げると厳しいようです。

では、写真を撮るときに解像度を上げるには？

一度に1ページ全体を撮影しようとせず、何枚かに分かれてしまってもよいので、文字が大きめに写るように近づいて撮影してみてください。最近のモデル（・チャット系の生成AIサービス）は複数枚の写真を一度に入力できるようになっています。

②分野自体が発展の過程にあるので、モデルによって得意・不得意があるかもしれません。傾向としては、GoogleのGeminiは比較的OCRが得意と言われています。